



**DOĞAL GAZ BORU HATTI İNŞAAT MALİYETLERİNİN ÖN TAHMİNİ
İÇİN BİR YÖNTEM ÖNERİSİ**

Coşkun ÇAKMAK

**DOKTORA TEZİ
İNŞAAT MÜHENDİSLİĞİ ANA BİLİM DALI**

**GAZİ ÜNİVERSİTESİ
FEN BİLİMLERİ ENSTİTÜSÜ**

OCAK 2025

ETİK BEYAN

Gazi Üniversitesi Fen Bilimleri Enstitüsü Tez Yazım Kurallarına uygun olarak hazırladığım bu tez çalışmada;

- Tez içinde sunduğum verileri, bilgileri ve dokümanları akademik ve etik kurallar çerçevesinde elde ettiğimi,
- Tüm bilgi, belge, değerlendirme ve sonuçları bilimsel etik ve ahlak kurallarına uygun olarak sunduğumu,
- Tez çalışmada yararlandığım eserlerin tümüne uygun atıfta bulunarak kaynak gösterdiğimi,
- Kullanılan verilerde herhangi bir değişiklik yapmadığımı,
- Bu tezde sunduğum çalışmanın özgün olduğunu,

bildirir, aksi bir durumda aleyhime doğabilecek tüm hak kayıplarını kabullendiğimi beyan ederim.

Coşkun ÇAKMAK

09/01/2025

DOĞAL GAZ BORU HATTI İNŞAAT MALİYETLERİNİN ÖN TAHMİNİ İÇİN BİR YÖNTEM ÖNERİSİ

(Doktora Tezi)

Coşkun ÇAKMAK

GAZİ ÜNİVERSİTESİ
FEN BİLİMLERİ ENSTİTÜSÜ

Ocak 2025

ÖZET

Doğal gaz boru hattı (DGBH) projelerinin maliyet tahmini, enerji altyapı projelerinin planlama ve bütçe yönetimi süreçlerinde doğru kararlar alınmasını sağlayan önemli bir adımdır. Bu çalışmada, DGBH inşaat maliyetlerini daha doğru bir şekilde tahmin edebilmek için çeşitli makine öğrenmesi modelleri geliştirilmiştir. Bu bağlamda, toplam 113 DGBH projesi incelenmiş ve bu projelere ait boru çapı, hat uzunluğu, hat vanası sayısı, take-off vanası sayısı ve pig istasyonu sayısı gibi bağımsız değişkenler kullanılmıştır. Veri seti, 90 proje eğitim ve 23 proje test verisi olarak ayrılmıştır. Modelleme çalışmaları Python programlama dili ile Jupyter Notebook ortamında gerçekleştirilmiştir. Seçilen bağımsız değişkenler kullanılarak Çoklu Doğrusal Regresyon (ÇDR), ElasticNet Regresyon (ER), K-En Yakın Komşu (KNN), Rastgele Ormanlar (RF) ve XGBoost (XGB) algoritmaları uygulanmıştır. Modellerin başarıları, test verisi ile hesaplanan R^2 ve RMSE değerleri üzerinden değerlendirilmiştir. Analiz sonuçlarına göre, tüm model denemeleri arasında XGBoost modeli ($R^2 = 0,89$ ve $RMSE = 23\ 472\ 275,50$ \$) en yüksek performans sergilerken, Rastgele Ormanlar modeli ($R^2 = 0,83$ ve $RMSE = 28\ 318\ 044,95$ \$) ikinci sırada yer almıştır. KNN modeli ise ($R^2 = 0,82$ ve $RMSE = 29\ 218\ 117,97$ \$) üçüncü sırada gelmiştir. ÇDR ($R^2 = 0,61$ ve $RMSE = 43\ 370\ 642,30$ \$) ve ER ($R^2 = 0,74$ ve $RMSE = 35\ 228\ 240,74$ \$) modelleri ise diğer yöntemlere kıyasla daha düşük performans göstermiştir. ÇDR ve ER modelleri için birer adet maliyet tahmini formülü geliştirilmiştir. Ayrıca, KNN, RF ve XGB modelleri için bağımsız değişkenlerin girilmesiyle tahmini maliyetlerin hesaplanabildiği web tabanlı bir tahmin aracı oluşturulmuştur. Sonuçlar, XGBoost ve RF algoritmalarının maliyet tahmini doğruluğunda öne çıktığını ve önerilen modellerin DGBH projelerinde ön maliyet tahmini için uygulanabilir olduğunu ortaya koymaktadır. Bu çalışma, enerji sektöründe maliyet tahmini süreçlerine katkı sağlamayı ve karar vericiler için daha etkin araçlar sunmayı amaçlamaktadır.

Bilim Kodu : 91115

Anahtar Kelimeler : Maliyet tahmini, doğal gaz boru hatları, makine öğrenmesi

Sayfa Adedi : 125

Danışman : Prof. Dr. Mürsel ERDAL

A METHOD PROPOSAL FOR EARLY ESTIMATION OF NATURAL GAS PIPELINE CONSTRUCTION COSTS

(Ph. D. Thesis)

Coşkun ÇAKMAK

GAZİ UNIVERSITY

GRADUATE SCHOOL OF NATURAL AND APPLIED SCIENCES

January 2025

ABSTRACT

The cost estimation of natural gas pipeline (NGP) projects is a crucial step in ensuring accurate decision-making during the planning and budget management processes of energy infrastructure projects. In this study, various machine-learning models were developed to provide more accurate estimations of NGP construction costs. In this context, a total of 113 NGP projects were analyzed, utilizing independent variables such as pipe diameter, pipeline length, number of line valves, number of take-off valves, and number of pigging stations. The dataset was divided into 90 training projects and 23 test projects. The modeling studies were conducted using the Python programming language within the Jupyter Notebook environment. Using the selected independent variables, Multiple Linear Regression (MLR), ElasticNet Regression (ER), K-Nearest Neighbors (KNN), Random Forests (RF), and XGBoost (XGB) algorithms were applied. The performance of the models was evaluated based on R^2 and RMSE values calculated using the test dataset. According to the analysis results, among all model trials, the XGBoost model ($R^2 = 0,89$ and $RMSE = \$23\,472\,275,50$) demonstrated the highest performance, while the Random Forests model ($R^2 = 0,83$ and $RMSE = \$28\,318\,044,95$) ranked second. The KNN model ($R^2 = 0,82$ and $RMSE = \$29\,218\,117,97$) came in third place. The MLR model ($R^2 = 0,61$ and $RMSE = \$43\,370\,642,30$) and the ER model ($R^2 = 0,74$ and $RMSE = \$35\,228\,240,74$) showed relatively lower performance compared to the other methods. For the MLR and ER models, one cost estimation formula was developed for each. Additionally, a web-based estimation tool was created for the KNN, RF, and XGB models, enabling users to calculate estimated costs by inputting independent variable values. The results indicated that the XGBoost and Random Forests algorithms stood out in terms of cost estimation accuracy and that the proposed models are applicable for preliminary cost estimation in NGP projects. This study aims to contribute to cost estimation processes in the energy sector and to provide decision-makers with more effective tools.

Science Code : 91115

Key Words : Cost estimation, natural gas pipelines, machine learning

Page Number : 125

Supervisor : Prof. Dr. Mürsel ERDAL

TEŞEKKÜR

Bu doktora çalışmasının gerçekleştirilmesi sürecinde, her aşamada bana rehberlik eden ve değerli katkılarıyla çalışmamın şekillenmesine öncülük eden danışman hocam Prof. Dr. Mürsel ERDAL'a sonsuz teşekkürlerimi sunarım. Ayrıca, çalışmamın niteliğini önemli ölçüde artıran destekleri ve yapıcı geri bildirimleri için tez izleme komite üyesi hocalarım Prof. Dr. Nihat Sinan IŞIK ve Doç. Dr. Latif Onur UĞUR'a teşekkür ederim. Tez yazma sürecinde her zaman yanında olan sevgili eşim Nur Demet DOĞANLAR ÇAKMAK'a ve tez yazımına zaman ayırabilmek için oyun saatlerinden, ileride ödemek koşuluyla, bir miktar ödünç aldığım sevgili oğlum Demir ÇAKMAK'a teşekkür ederim. Bu günleri görmelerini çok arzuladığım, üzerimdeki emeklerini bir ömür boyu unutmayacağım rahmetli annem Necla ERCİYAS'a ve rahmetli anneannem Mahi ŞAHİN'e teşekkürü bir borç bilirim.

İÇİNDEKİLER

	Sayfa
ÖZET	iv
ABSTRACT.....	v
TEŞEKKÜR.....	vi
İÇİNDEKİLER	vii
ÇİZELGELERİN LİSTESİ.....	ix
ŞEKİLLERİN LİSTESİ.....	x
RESİMLERİN LİSTESİ	xiii
HARİTALARIN LİSTESİ.....	xv
SİMGELER VE KISALTMALAR.....	xvi
1. GİRİŞ.....	1
2. GEÇMİŞTE YAPILMIŞ ÇALIŞMALAR.....	3
3. DOĞAL GAZ BORU HATLARI	9
3.1. Doğal Gaz Boru Hattı Yapım İşleri.....	11
3.1.1. Çalışma şeridinin tesviyesi ve hazırlanması.....	12
3.1.2. Boru dizgisi ve kazı yapılması	13
3.1.3. Kaynak işleri	16
3.1.4. Korozyon önlemleri.....	18
3.1.5. Boruların indirilmesi	21
3.1.6. Boru üzerinin kapatılması ve geri dolgu işlemleri	23
3.1.7. Hidrostatik test yapılması.....	24
3.2. Çevresel ve Ekonomik Etkiler.....	25
4. VERİ SETİ VE YÖNTEM.....	27
4.1. Veri Seti.....	27
4.1.1. Boru çapı	27
4.1.2. Hat uzunluğu	30

	Sayfa
4.1.3. Hat vanası.....	30
4.1.4. Take-off vanası.....	30
4.1.5. Pig istasyonu	31
4.1.6. Güncellenmiş maliyet.....	31
4.2. Veri Dağılımının İncelenmesi	39
4.2.1. Bağımsız değişkenlerin histogram grafikleri	40
4.2.2. Bağımlı değişken (güncellenmiş maliyet) veri görselleştirmeleri	42
4.2.3. Hat uzunluğuna göre boru çapı değişimi	45
4.2.4. Güncellenmiş birim maliyet veri görselleştirmeleri.....	46
4.3. Yöntem.....	50
4.3.1. Model başarı parametreleri.....	51
4.3.2. Kullanılan algoritmalar	52
5. BULGULAR VE TARTIŞMA.....	57
5.1. İstatistiksel Çıkarımlar	57
5.1.1. İhale türü	58
5.1.2. Çelik boru maliyeti oranı.....	61
5.2. Makine Öğrenmesi Algoritmalarının Uygulanması ve Maliyet Tahmini Sonuçları	63
5.2.1. Modelleme öncesi veri hazırlık süreçleri	63
5.3. Çoklu Doğrusal Regresyon (ÇDR) Tahmin Modeli.....	69
5.3.1. ÇDR modelinin oluşturulması.....	69
5.3.2. ÇDR modeli sonuçları	70
5.4. ElasticNet Regresyon (ER) Tahmin Modeli	75
5.4.1. ER modelinin oluşturulması.....	76
5.4.2. ER için hiperparametre ayarlaması ve GridSearchCV kullanımı	77
5.4.3. ER modeli sonuçları	80

	Sayfa
5.5. K-En Yakın Komşu (KNN) Tahmin Modeli.....	85
5.5.1. KNN modelinin oluşturulması	85
5.5.2. KNN için hiperparametre ayarlaması ve GridSearch CV kullanımı.....	86
5.5.3. KNN modeli sonuçları	88
5.6. Rastgele Ormanlar (RF) Tahmin Modeli	92
5.6.1. RF modelinin oluşturulması	93
5.6.2. RF için hiperparametre ayarlaması ve GridSearchCV kullanımı.....	94
5.6.3. RF modeli sonuçları	96
5.7. XGBoost (XGB) tahmin modeli.....	102
5.7.1. XGB modelinin oluşturulması	103
5.7.2. XGB için hiperparametre ayarlaması ve GridSearchCV kullanımı	104
5.7.3. XGB modeli sonuçları.....	106
5.8. Model Sonuçlarının Karşılaştırılması ve Dijital Tahmin Platformu	111
5.8.1. Maliyet tahminlerinin karşılaştırılması	111
5.8.2. Performans başarı metriklerinin karşılaştırılması	113
5.8.3. Dijital tahmin platformu	114
6. SONUÇ VE ÖNERİLER	117
KAYNAKLAR	119
ÖZGEÇMİŞ	125

ÇİZELGELERİN LİSTESİ

Çizelge	Sayfa
Çizelge 3.1. Doğal gaz boru hatlarının yapımı ve işletilmesine yönelik standartlar ve yönetmelikler	9
Çizelge 3.2. Boru çaplarına göre standart kazı kesitleri	15
Çizelge 4.1. Analizlerde kullanılan değişkenler	27
Çizelge 4.2. Örnek malzemeli (yapım işi ve çelik boru alımı) ihale bilgileri.....	32
Çizelge 4.3. Örnek malzemesiz yapım işi ihale bilgileri	33
Çizelge 4.4. Örnek çelik boru alımı ihale bilgileri	34
Çizelge 4.5. DGBH projelerinin değişken değerleri.....	35
Çizelge 4.6. Değişkenlerin tanımlayıcı istatistikleri	36
Çizelge 4.7. Birim maliyet ve boru maliyet yüzdeleri.....	37
Çizelge 4.8. Çalışma kapsamında kullanılan algoritmalar	50
Çizelge 5.1. 2002 yılı öncesi DGBH projelerinin tanımlayıcı istatistikleri.....	59
Çizelge 5.2. Modelde kullanılan değişken isimlendirmeleri ve metin içerisinde kısaltmaları	65
Çizelge 5.3. ÇDR model başarı metrikleri.....	73
Çizelge 5.4. ER model başarı metrikleri (hiperparametre ayarlama işlemi öncesi)	77
Çizelge 5.5. ER model başarı metrikleri (hiperparametre ayarlama işlemi sonrası)	84
Çizelge 5.6. KNN model başarı metrikleri (hiperparametre ayarlama işlemi öncesi)...	86
Çizelge 5.7. KNN model başarı metrikleri (hiperparametre ayarlama işlemi sonrası)..	91
Çizelge 5.8. RF model başarı metrikleri (hiperparametre ayarlama işlemi öncesi).....	94
Çizelge 5.9. RF model başarı metrikleri (hiperparametre ayarlama işlemi sonrası)	99
Çizelge 5.10. XGB model başarı metrikleri (hiperparametre ayarlama işlemi öncesi)..	104
Çizelge 5.11. XGB model başarı metrikleri (hiperparametre ayarlama işlemi sonrası).	108
Çizelge 5.12. Tüm modellerin başarı metrikleri (hiperparametre ayarlama işlemi sonrası)	113

ŞEKİLLERİN LİSTESİ

Şekil	Sayfa
Şekil 3.1. Doğal gaz boru hattı inşaatı aşamaları	11
Şekil 3.2. Yumuşak topraklı bir zeminde gerçekleştirilen boru hattı döşemesi için örnek kazı kesiti	14
Şekil 3.3. Kayalık bölgede gerçekleştirilen boru hattı döşemesi için örnek kazı kesiti	14
Şekil 3.4. Galvanik anot sistemi.....	20
Şekil 3.5. Dış akım kaynaklı katodik koruma sistemi.....	21
Şekil 4.1. Projelerin yıllara göre dağılımı	38
Şekil 4.2. Bağımsız değişkenlerin histogram grafikleri	40
Şekil 4.3. Güncellenmiş maliyet histogram grafiği.....	42
Şekil 4.4. Güncellenmiş maliyet dağılımı pasta grafiği	43
Şekil 4.5. Farklı çap ve hat uzunluklarına göre güncellenmiş maliyet değişimi.....	44
Şekil 4.6. Hat uzunluğuna göre boru çapı dağılımı.....	45
Şekil 4.7. Güncellenmiş birim maliyet histogram grafiği	46
Şekil 4.8. Güncellenmiş birim maliyet dağılımı grafiği.....	47
Şekil 4.9. Hat uzunluklarına göre güncellenmiş birim maliyet grafiği	48
Şekil 4.10. Farklı çap ve hat uzunluklarına göre güncellenmiş birim maliyet değişimi.....	49
Şekil 5.1. İhale türlerinin yıllara göre dağılım grafiği	58
Şekil 5.2. Boru hattı özelliklerine göre projelerin güncellenmiş ortalama birim maliyetleri	60
Şekil 5.3. Çapa göre çelik boru maliyet yüzdesi dağılımı.....	61
Şekil 5.4. Hat uzunluğuna göre çelik boru maliyet yüzdesi dağılımı	62
Şekil 5.5. Tüm değişkenlerin korelasyon matrisi.....	64
Şekil 5.6. Model kurma süreci ön hazırlık	68
Şekil 5.7. ÇDR modeli gerçek ve tahmin edilen güncellenmiş maliyetlerin karşılaştırılması	71

Şekil	Sayfa
Şekil 5.8. ÇDR modelinde tahmin edilen maliyet ve hatalar	72
Şekil 5.9. Beş katlı çapraz doğrulama	79
Şekil 5.10. ER modeli gerçek ve tahmin edilen maliyetlerin karşılaştırılması	81
Şekil 5.11. ER modeli tahmin edilen maliyet ve hatalar	82
Şekil 5.12. KNN modeli gerçek ve tahmin edilen maliyetlerin karşılaştırılması.....	88
Şekil 5.13. KNN modeli tahmin edilen maliyet ve hatalar	89
Şekil 5.14. RF modeli gerçek ve tahmin edilen maliyetlerin karşılaştırılması	96
Şekil 5.15. RF modeli tahmin edilen maliyet ve hatalar	97
Şekil 5.16. RF modeli için örnek bir karar ağacı (50 numaralı ağaç)	100
Şekil 5.17. XGB modeli gerçek ve tahmin edilen maliyetlerin karşılaştırılması.....	106
Şekil 5.18. XGB modeli tahmin edilen maliyet ve hatalar	107
Şekil 5.19. XGB modeli için örnek bir karar ağacı (1 numaralı ağaç).....	109
Şekil 5.20. Tüm modeller gerçek ve tahmin edilen maliyetlerin karşılaştırılması.....	112

RESİMLERİN LİSTESİ

Resim	Sayfa
Resim 3.1. Çalışma şeridinin hazırlanması ve kazı güzergâhının işaretlenmesi.....	12
Resim 3.2. Boru dizgisi ve kazı işlemi.....	13
Resim 3.3. Boru birleşimi için yapılan kaynak işlemi	17
Resim 3.4. Kaynak işlemleri sırasında kullanılan çadır	18
Resim 3.5. Polipropilen kaplı çelik borular.....	19
Resim 3.6. Doğal gaz borularının hendeğe indirilmesi	23
Resim 3.7. Geri dolgu sürecinde olan boru hatları.....	24
Resim 5.1. Model başarı metriklerini hesaplama fonksiyonu	65
Resim 5.2. Veri seti model hazırlık işlemleri	66
Resim 5.3. ÇDR model nesnesi oluşturulması ve başarı metriklerinin hesaplanması ..	69
Resim 5.4. ÇDR model denklemi kodu ve cevap satırı	70
Resim 5.5. ER model nesnesi oluşturulması ve hiperparametre ayarlama işlemi öncesi başarı metriklerinin hesaplanması	76
Resim 5.6. ER modelinde GridSearchCV kullanımı.....	78
Resim 5.7. ER modeli için en iyi hiperparametre çağırma kodu ve cevap satırı	80
Resim 5.8. ER model denklemi kodu ve cevap satırı.....	80
Resim 5.9. ER modelinde hiperparametre ayarlama işlemi sonrası başarı metriklerinin hesaplanması	83
Resim 5.10. KNN model nesnesi oluşturulması ve hiperparametre ayarlama işlemi öncesi başarı metriklerinin hesaplanması	85
Resim 5.11. KNN modelinde GridSearchCV kullanımı.....	87
Resim 5.12. KNN modeli için en iyi hiperparametre çağırma kodu ve cevap satırı	87
Resim 5.13. KNN modelinde hiperparametre ayarlama işlemi sonrası başarı metriklerinin hesaplanması	90
Resim 5.14. RF model nesnesi oluşturulması ve hiperparametre ayarlama işlemi öncesi başarı metriklerinin hesaplanması	93
Resim 5.15. RF modelinde GridSearchCV kullanımı	95

Resim	Sayfa
Resim 5.16. RF bölümü için en iyi hiperparametreleri çağırma kodu ve cevap satırı...	95
Resim 5.17. RF modelinde hiperparametre ayarlama işlemi sonrası başarı metriklerinin hesaplanması.....	98
Resim 5.18. XGB model nesnesi oluşturulması ve hiperparametre ayarlama işlemi öncesi başarı metriklerinin hesaplanması	103
Resim 5.19. XGB modelinde GridSearchCV kullanımı.....	105
Resim 5.20. XGB bölümü için en iyi hiperparametreleri çağırma kodu ve cevap satırı	105
Resim 5.21. XGB modelinde hiperparametre ayarlama işlemi sonrası başarı metriklerinin hesaplanması.....	108
Resim 5.22. Dijital tahmin platformu örnek sonuç çıktısı	115

HARİTALARIN LİSTESİ

Harita	Sayfa
Harita 3.1. Türkiye doğal gaz iletim sistemi haritası	10

SİMGELER VE KISALTMALAR

Bu çalışmada kullanılmış simgeler ve kısaltmalar, açıklamaları ile birlikte aşağıda sunulmuştur.

Simgeler

Açıklamalar

\$	Amerikan doları
₺	Türk lirası
M\$	Milyon dolar
km	kilometre
R ²	Belirleme katsayısı

Kısaltmalar

Açıklamalar

ABD	Amerika Birleşik Devletleri
API	Amerikan Petrol Enstitüsü
BOTAŞ	Boru Hatları İle Petrol Taşıma Anonim Şirketi
CPI	Consumer Price Index
ÇDR	Çoklu Doğrusal Regresyon
DGBH	Doğal gaz boru hattı
EKAP	Elektronik Kamu Alımları Platformu
ER	ElasticNet Regresyon
KNN	K-En Yakın Komşu
MAE	Ortalama mutlak hata
MAPE	Ortalama mutlak yüzdesel hata
RMSE	Hataların ortalama karekökü
RF	Rastgele Ormanlar
XGB	XGBoost

1. GİRİŞ

Günümüzde, artan enerji ihtiyacı ve bu ihtiyacı karşılamak amacıyla sürdürülebilir ve verimli yöntemlerin arayışı, enerji sektörünü sürekli bir evrim sürecine sokmuştur. Bu bağlamda, çevre dostu ve verimli bir enerji kaynağı olarak doğal gaz, modern toplumların enerji gereksinimlerini karşılama konusunda kilit bir role sahiptir. Uluslararası Enerji Ajansı'nın (IEA) 2023 yılı raporuna göre, doğal gaz tüketimi son beş yılda küresel ölçekte %10 oranında artış göstermiş, bu artış doğal gazın ekonomik ve stratejik önemini daha da pekiştirmiştir [1]. Doğal gazın üretim noktalarından tüketim alanlarına güvenli ve etkili bir şekilde iletimi karmaşık altyapı projelerini zorunlu kılmaktadır [2]. Özellikle boru hatları, bu iletimin omurgasını oluştururken, proje maliyetlerinin tahminleri konusunda yaşanan zorluklar, planlama ve yönetim süreçlerini karmaşık hâle getirmekte, bu da projelerin zamanında ve belirlenen bütçe dâhilinde tamamlanmasını zorlaştırmaktadır.

Dünya üzerinde, bu çalışmanın yapıldığı tarih itibari ile yaklaşık 193,9 milyar Amerikan doları değerinde doğal gaz boru hattı (DGBH) inşaatı yapılmaktadır [2]. Global anlamda böylesine büyük bir maliyet hacmine sahip boru hattı inşaatı sürecinde oluşabilecek maliyet verileri üzerinde yapılacak her çalışmanın literatüre ciddi bir katkı sunacağı düşünülmektedir. Üst yapı inşaatı maliyet verilerinin elde edilebilme kolaylığı, altyapı maliyet verilerinin elde edilmesine oranla daha kolaydır. Bunun yanında, üst yapı inşaat hacminin yaygın ve maliyet olarak pastada en büyük dilime sahip olması gibi nedenlerle de azımsanmayacak düzeyde bir maliyet tahmini verisine sahiptir [3-15]. Boru hatları özelinde limitli bir bilgi birikimine sahip olan yerel literatürümüzde DGBH'lerin maliyet tahminine yönelik yeterli düzeyde bir araştırma bulunmamaktadır.

Bir projede maliyet tahmininin kabul edilebilir sınırlar içerisinde kalabilme durumu projenin toplam başarısında kritik bir faktördür [16, 17]. Bu çalışma, DGBH projelerinde maliyet tahminlerinin doğruluğunu artırmak ve bu tahminleri daha etkili bir şekilde yönetmek amacıyla, yapay zekâ ve makine öğrenmesi tekniklerini merkeze alan yenilikçi bir yaklaşım önermektedir. Araştırmanın temel amacı, özellikle proje başlangıcında sınırlı bilgiye sahipken, maliyet tahminlerinin güvenilirliğini ve doğruluğunu artırarak enerji sektöründe karar verme süreçlerini desteklemektir. Bu yaklaşımın, hem kamu hem de özel sektördeki enerji projesi çalışmalarında bulunan paydaşlar için maliyet tahminleri konusunda

karşılaşılan zorlukları azaltarak, daha etkin bütçe planlaması ve proje yönetimi sağlayacağı öngörülmektedir.

Literatürdeki benzer çalışmalar, yapay zekanın maliyet tahminleri konusunda önemli başarılar sağlayabileceğini göstermiştir; ancak, DGBH'lere özgü zorluklar ve dinamikler göz önüne alındığında, bu alanda spesifik olarak geliştirilmiş yöntemlerin eksikliği dikkat çekmektedir. Bu çalışma, projeye özgü bilgilerin elde edilmesi noktasında mevcut olan zorluğa rağmen bu boşluğu doldurmayı hedefleyerek, DGBH'ler için özelleştirilmiş bir maliyet tahmini modeli geliştirmeyi amaçlamaktadır. Modelin geliştirilme süreci, veri toplama, model eğitimi ve validasyon aşamalarını içerecek, bunun yanında modelin doğruluğu, gerçek dünya verileriyle test edilerek değerlendirilecektir. Bu çalışma sonuçlarının, DGBH'lerin planlanması ve inşası sürecinde karşılaşılan maliyet tahmini zorluklarının üstesinden gelinmesinde önemli bir kaynak oluşturacağı ve böylece enerji sektöründe daha sürdürülebilir ve etkin projelerin hayata geçirilmesine katkı sunabileceği düşünülmektedir. Ayrıca yatırım planlanması aşamasında işverenlerin, tedarik sürecinde ise özel sektörün bu çalışmanın çıktılarından faydalanması beklenmektedir.

2. GEÇMİŞTE YAPILMIŞ ÇALIŞMALAR

Uluslararası literatürde oldukça fazla sayıda DGBH'ler ile ilgili bilimsel araştırma yer almaktadır. Bu araştırmaların büyük kısmının enerji, çevre ve siyasi alanlarda yoğunlaştığı görülmektedir. DGBH inşaatlarının maliyet yönünden ele alındığı, daha tutarlı tahminler ortaya koyabilmek adına çalışmaların planlandığı çok az sayıda çalışmaya rastlanmıştır. Bu çalışmaların da neredeyse tamamına yakınının Amerika Birleşik Devletleri (ABD) merkezli olduğu görülmektedir. Bu çalışma, Türkiye Cumhuriyeti sınırları içerisinde DGBH'lerin ön maliyet tahmini kapsamında yapılmış ilk çalışma olma özelliğindedir. Çalışmanın yapılmasına ön ayak niteliği taşıyan, inşaat sektörünün farklı alanlarında gerçekleştirilmiş inşaat faaliyetlerinin maliyet tahmini konusunu merkeze alan çalışmalar da bu bölümde sunulmuştur.

Zhao (2000) çalışmasında Avrupa, Asya ve ABD'de bulunan DGBH'lerin lokasyon bağlamında dağılımlarını açıklayarak her bölgeye özel maliyetlerin zamanla değişiminden bahsetmiştir. Araştırmacı, bulgularında, DGBH inşaat maliyetlerinde kara üzerinde yapılanlar için %80, kara üzerinde olmayanlar için ise %84'lük bir payı, malzeme ve işçilik ücretlerinin oluşturduğunu belirtmiştir. Çalışmasında öğrenme kavramının maliyet üzerine etkisini de araştıran Zhao, 1985-1998 yılları arasında ABD sınırlarında ve karada yapılan DGBH'lerde bu etkinin düşük olduğunu ancak karada olmayan boru hatlarında öğrenme etkisinin maliyetleri zamanla %24 oranında düşürdüğü sonucuna $R^2 = 0,6334$ belirleme katsayısı ile ulaşmıştır. Öğrenme kavramının maliyete etkisinin DGBH inşaatı tecrübesi daha az olan Asya kıtası ülkelerinde yapılacak yeni boru hattı projelerinde daha net görülebileceğinin vurgulandığı çalışmada araştırmacı, Asya'da doğal gaz dolaşımının bir süre daha ağırlık olarak sıvılaştırılmış doğal gaz (LNG – Liquefied Natural Gas) şeklinde yapılacağını belirtmiştir. Ayrıca çalışmada, düşük nüfuslu bölgelerde yapılan geniş çaplı ve daha büyük hat uzunluğuna sahip boru hatlarının, düşük nüfuslu bölgelerde yapılan küçük çaplı ve daha küçük hat uzunluğuna sahip boru hatlarına göre daha az maliyetli olduğu sonucuna varılmıştır [18].

Parker (2004) çalışmasında, doğal gaz, akaryakıt ve petrol boru hatlarının maliyetlerinden yola çıkarak hidrojen iletim hatlarında ne tür maliyet farklılıkları olabileceğini araştırmıştır. Çalışma kapsamında ABD'de bulunan 893 doğal gaz, akaryakıt ve petrol iletim hattının

maliyet verileri incelenmiş ve bu incelemeler neticesinde belirli uzunluk ve çapa sahip iletim hatlarının, maliyet kalemlerini açıklayabilecek denklemler elde edilmiştir. Parker, yaptığı araştırma ile birlikte DGBH inşaat maliyetlerinin;

- %26 malzeme ücreti,
- %45 işçilik ücreti,
- %22 irtifak hakkı bedeli,
- %7 çeşitli (araştırma, inceleme, sigortalar, izinler vb.) giderler

kalemlerinden oluştuğu sonucuna varmıştır. Aynı uzunluk ve çaptaki DGBH'lerin uygulandığı bölgeye göre maliyet anlamında 5 kata kadar fark edebileceğini belirttiği çalışmasının sonunda Parker, elde ettiği denklemlerin belirli katsayılarla çarpılarak hidrojen boru hatları için kullanılabileceğini ortaya koymuştur [19].

Yılmaz (2005), Türkiye'de doğal gaz kullanımının günümüzdeki kullanım seviyesinde olmadığı bir dönemde yapmış olduğu çalışmada, petrol ve DGBH'ler ile ilgili genel bir değerlendirme yapmıştır. Çalışmada, mevcut boru hatlarının yanı sıra inşası devam eden ve planlanan boru hatlarının detaylı bir analizi yapılmıştır. Araştırmacı, çalışmada yer verdiği boru hatlarının, Türkiye ekonomisine önemli katkılar sağlayabileceğini ve ülkenin enerji ihtiyacını karşılamada kritik bir rol oynayabileceğini belirtmiştir. Ayrıca çalışmada; valilik, belediye ve üniversite gibi kurumların bu alana daha fazla ilgi göstermesinin ve boru hatlarının inşası ve bakımı konusunda daha fazla yatırım yapılmasının gerekliliği üzerinde durulmuştur [20].

Rui, Metz, Reynolds, Chen ve Zhou (2011a) yaptıkları çalışmada, ABD'de farklı bölgelerde bulunan 1992-2008 yılları arasında yapılmış 412 adet DGBH projesinin bölgesel düzeyde maliyet farklılıklarını ortaya koymayı amaçlayan bir çalışma yapmışlardır. 15 adet veriyi Kanada sınırları içerisinde yapılmış proje bilgilerinin oluşturduğu çalışmada, maliyet bileşenleri malzeme, işçilik, irtifak hakkı ve genel giderler olarak belirlenmiştir. Bu gider kalemlerine bağlı olarak her bölgede ayrı ayrı toplam maliyet tanımlanmış ve her bir maliyet bileşeninin toplam maliyet üzerindeki etkisi bölgesel olarak hesaplanmıştır. Çalışma kapsamında ABD; Batı, Merkez, Güney Batı, Güney Doğu, Orta Batı ve Kuzey Doğu olarak bölünmüştür. ABD topraklarında en uygun maliyetlere Merkez bölgede ulaşıldığı

belirlenmiştir. Kanada ise tüm maliyet kalemlerinde bütün ABD bölgelerinden daha uygun maliyetlerle DGBH inşa edebilen bir ülke konumunda görünmektedir. Güney Batı bölgesinde malzeme, Kuzey Batı bölgesinde ise işçiliğin toplam maliyeti en çok etkilediğinin tespit edildiği çalışma sonucunda araştırmacılar, büyük ölçekli DGBH projelerinin daha uygun birim maliyetlere sahip olduğunu belirlemişlerdir [21].

Rui, Metz, Reynolds, Chen ve Zhou (2011b) çalışmalarında boru hattı inşaatlarında oluşan maliyetleri kronolojik olarak sunmuşlardır. Her bir maliyet kaleminin ayrı ayrı yıllara göre miktarlarının belirtildiği çalışmada, 1992-2008 yılları arasında 412 adet tamamlanmış projenin maliyetlerine göre değerlendirmeler yapılmıştır. Yapılan çalışmada, maliyet kalemleri malzeme, işçilik, geçiş hakkı ve genel/çeşitli giderler üzerinden değerlendirilmiştir. Çalışmada ayrıca, işin tekrarlanılarak öğrenilmesinin işçilik maliyetlerini zamanla aşağıya çektiği belirtilmiştir [22].

Rui, Metz ve Chen (2012) çalışmalarında boru hattı inşaatlarındaki maliyet hatalarını istatistiksel olarak sunmuşlardır. 1992-2008 yılları arasında 412 adet tamamlanmış projenin tahmini ve gerçekleşmiş maliyetlerine göre değerlendirmeler yapılan araştırmada, maliyet kalemleri malzeme, işçilik, geçiş hakkı ve genel/çeşitli giderler üzerinden değerlendirilmiştir. En yüksek maliyet tahmin hatalarının işçilik kalemi ile ilgili olduğunun belirtildiği çalışmada araştırmacılar, proje ölçeğinin büyümesiyle yapılan tahmin hatalarının da arttığını ve zamanla bu tarz tahmin hatalarının düzelmediğini vurgulamışlardır [23].

Rui ve diğerleri (2012) boru hattı basınç istasyonu inşaatlarındaki maliyet hatalarını istatistiksel olarak sundukları bir çalışma gerçekleştirmişlerdir. 1992-2008 yılları arasında tamamlanmış 220 adet projenin, tahmini ve gerçekleşmiş maliyetlerine göre değerlendirmeler yapılan çalışmada maliyet kalemleri malzeme, işçilik, arazi ve genel/çeşitli giderler üzerinden değerlendirilmiştir. Bu değerlendirmeleri proje mâlî büyüklüğüne, istasyon kapasitesine, bölgelere vb. değişkenlere göre detaylı bir şekilde açıklamışlardır. Tahmin hatalarının proje büyüklüğü ile ilgili orantılı olmadığını tespit edildiği çalışmada, araştırmacılar zamanla bu tarz tahmin hatalarının düzeldiğini belirtmişlerdir [24].

Thaduri (2012) çalışmasında, 2000-2008 yılları arasında ABD ve Kanada sınırları içerisinde tamamlanmış 180 adet DGBH'ye ve 136 adet basınç istasyonuna ait verileri toplamış ve tanımlayıcı istatistiki veriler sunmuştur. Yapılan değerlendirmeler sonucunda, DGBH

maliyetlerinde en yüksek paya sahip maliyet kalemlerinin %40 ile işçilik ve %31 ile malzeme maliyeti olduğu belirtilmiştir. Thaduri, ABD topraklarını 6 bölge, Kanada'yı ise ayrı bir bölge olarak belirlemiş ve toplam 7 bölgede boru hattı ve basınç istasyonu uygulamasının maliyet kalemlerini karşılaştırmıştır. Bu karşılaştırmalar sonucunda farklı bölgelerde toplam maliyet kapsamında farklı sonuçlara ulaşıldığını belirtmiştir [25].

Bai, Li ve Yuan (2013) çalışmalarında, mevcut literatürden de destek olarak CO₂'nin tedariki aşamasında gerekli olan boru hatları için yıllık maliyet tahmininde bulunmuşlardır. Çin'in iki farklı bölgesinde benzer özelliklere sahip iki ayrı rotanın seçildiği çalışmada araştırmacılar, yıllık maliyetlerin ortalama 57,80 Çin yuanı olacağını tahmin etmişlerdir. Bai ve diğerleri, tercih edilen rotalarda boruların aynı seviyede ilerleyeceği ve yükseklik farkı oluşmayacağı öngörüsünde bulunmuşlardır. Araştırmacılar, literatüre göre bir miktar farklılık gösteren sonuçlar için ana neden olarak, geçiş hakkı maliyetlerinin bu çalışmada kapsama alınmış olmasını göstermişlerdir [26].

Matthews, Allouche ve Sterling (2015) çalışmalarında "sosyal maliyet" kavramı kapsamında alt yapı projelerini değerlendirmişlerdir. Özellikle kazı işlemi uygulanan alt yapı veya iyileştirme projelerinde yolun kullanılamaması, oluşan gürültü, kazı nedeniyle tozlaşma vb. durumların da bir maliyeti olduğunun belirtildiği çalışmada araştırmacılar, her bir sosyal maliyet kategorisi için hesaplama yöntemleri önermişlerdir. Ayrıca bu yöntemler iki vaka çalışmasıyla desteklenmiş ve sosyal maliyetin proje maliyetine oranla %1-9 arasında olduğu belirlenmiştir. Matthews ve diğerleri, sosyal maliyeti hesaplama işleminin sonucu olarak, mühendislerin, bu maliyeti düşürmeye katkı sağlayacak yüksek teknolojileri kullanmaları yönünde teşvik edilmesi gerektiğini belirtmişlerdir [27].

Tayefeh Hashemi, Ebadati ve Kaur (2020) genel inşaat maliyet tahmin yöntemleri ile ilgili yapmış oldukları yeniden gözden geçirme çalışmalarında 1985-2020 yılları arasında yapılmış ve Google Scholar'dan veya Elsevier dergilerinden taranabilen yayımlarla ilgili özet bilgiler sunmuşlardır. Makine öğrenmesi algoritmaları olan yapay sinir ağları ve regresyon analizinin ağırlıklı olarak literatürü oluşturduğunun belirtildiği çalışmada araştırmacılar, derin öğrenme metodunun çalışmanın gerçekleştirildiği tarihe kadar maliyet tahminlerinde hiç kullanılmadığı tespitini yapmışlardır. Araştırmacıların, 40 tanesini bina projelerinin, 8 tanesini ise raylı sistem projelerinin oluşturduğu toplam 92 yayını yeniden değerlendirdiği çalışmada, yapay sinir ağlarının 39 çalışmada, regresyon analizinin ise 21

çalışmada kullanıldığını belirtmişlerdir. Yeniden gözden geçirme çalışmasının sonuç bölümünde araştırmacılar, inşaat sektörü özelinde yapılan maliyet tahmini çalışmalarında, inşaatın gerçekleştirildiği coğrafi konumun maliyete etkisinin araştırmalarda sıkça yer aldığı bilgisini de paylaşmışlardır [28].

Kaiser (2021) çalışmasında, ABD'de yapılmış olan DGBH inşaatı ve devre dışı bırakma maliyetlerini detaylı bir şekilde irdelemiştir. Araştırmada, boru üretim süreçleri ve bu süreçte uyulması gereken teknik yeterlilikler, bu süreçlerin maliyete olan etkileri vb. bilgiler yer almıştır. Çalışmada, Federal Enerji Düzenleme Komisyonu'nun yayınladığı boru hattı projelerinde toplam maliyetin %13'ünü malzeme, %48'ini işçilik, %30'unu çeşitli gideler ve %9'unu da arazi edinimi kalemlerinin oluşturduğu belirtilmiştir. Ayrıca çalışmada, 2014-2019 yıllarında yapılmış olan 99 adet proje verisiyle regresyon analizi gerçekleştirilmiştir. Hat uzunluğu ve boru çapı parametrelerinin bağımsız değişken olarak seçildiği analizde 0,83 - 0,92 arasında önemli R^2 değerlerine ulaşılmıştır. Boru hatları özelinde, güzergâh, nüfus yoğunluğu, geçilmesi ve/veya aşılması gereken köprü, nehir vb. yapıların maliyete oldukça ciddi etkilerinin olabileceğinin belirtildiği çalışmada Kaiser, veri setinin yetersiz nicelikte olmasının, veri setinde benzer ve tekrarlayan değerlerin varlığının analizlerde sonucu etkileyebileceği görüşüne yer vermiştir [29].

Erdal (2021) çalışmasında, boru hattı projelerinin maliyet tahmini için makine öğrenmesi algoritmalarının başarı düzeyini araştırmıştır. Erdal, veri seti olarak Rui ve diğerlerinin (2012) çalışmasında yer verdiği 412 boru hattı proje bilgilerinden rastgele 50 adedini kullanmıştır. Seçilen 50 proje bilgisinin tanımlayıcı istatistiklerinin de sunulduğu çalışmada 6 farklı makine öğrenmesi algoritması denenmiş ve bu denemelerde 10 katlı çapraz doğrulama tekniği uygulanmıştır. Uygulanan tüm yöntemlerde 0,79 ve üzerinde R^2 değeri elde edilen araştırmada ağaç tabanlı öğrenme algoritmalarından birisi olan Model Trees Regression yönteminin, bu veri seti için en başarılı yöntem olduğu sonucuna varılmıştır [30].

Sueri ve Erdal (2022) çalışmalarında, kanalizasyon hattı maliyetlerinin erken tahmini için regresyon analizini kullanmışlardır. Bu kapsamda, 2014-2020 yılları arasında ihaleleri yapılmış olan 182 farklı projeye ait boru çapı, hat uzunluğu, kazı derinliği, kazı hacmi, dolgu hacmi ve kazı klas katsayısı değişkenlerini içeren veriler toplanmış ve analiz edilmiştir. Araştırmacılar, bağımlı değişken olarak kanalizasyon hattı maliyeti ve bağımsız değişkenler olarak belirlenen faktörleri kullanarak çoklu regresyon analizi yapmışlardır. Analiz

sonucunda elde edilen denklemin R^2 değeri 0,911 olarak hesaplanmıştır. Çalışma sonucunda araştırmacılar, elde ettikleri matematiksel modelin, kanalizasyon hattı projelerinin henüz tasarım aşamasında veya proje başlangıç adımıda olduğu dönemlerde dâhi, erken maliyet tahmini için etkili ve güvenli bir araç olarak kullanılabileceğini belirtmişleridir [31].

Elhegazy ve diğerleri (2022) çalışmalarında, çok katlı binaların kompozit döşeme sistemleri için yapay sinir ağları (ANN- Artificial Neural Network) kullanarak ön maliyet tahminleri geliştirmişlerdir. Araştırmada, aks aralık mesafeleri, toplam yük ve yerel malzeme birim maliyetleri gibi değişkenler bağımsız değişken olarak kullanılmış ve ANN modellerinin doğruluğu %99,5 gibi yüksek bir regresyon değeriyle ölçülmüştür. Çalışma, geleneksel yöntemlere kıyasla ANN tabanlı tahmin modellerinin daha hızlı ve doğru sonuçlar verdiğini ortaya koymuştur. Veri setinin sınırlı olması, analizlerde belirli kısıtlamalar yaratmış olsa da araştırmacılar, modelin, tasarım sürecinin erken aşamalarında karar alma mekanizmasına hız ve doğruluk kazandıran etkin bir araç olduğunu vurgulamışlardır [32].

3. DOĞAL GAZ BORU HATLARI

Doğal gaz, son yıllarda artan enerji ihtiyaçları ve çevre bilincinin yükselmesiyle birlikte temiz bir enerji kaynağı olarak öne çıkmıştır. Fosil yakıtların çevreye olan olumsuz etkileri göz önüne alındığında, doğal gaz; düşük karbon emisyonu, verimliliği ve geniş kullanım alanı sayesinde önemli bir alternatif enerji kaynağı olarak değerlendirilmektedir. Özellikle sanayi, konut ısıtma ve elektrik üretimi gibi pek çok sektörde yaygın şekilde kullanılan doğal gaz, karbondioksit (CO₂) salınımını büyük oranda azaltarak hava kalitesinin korunmasına katkıda bulunmaktadır. Bu temiz enerji kaynağının dünya çapında yaygınlaşması ve ülkelerin sürdürülebilir enerji hedeflerine ulaşılmasındaki rolü büyüktür [33].

DGBH'ler, doğal gazı tüketicilere ulaştırmakta kritik bir rol oynamaktadır. Türkiye gibi enerji arz güvenliğini sağlamak için çeşitli kaynaklara bağlı olan ülkelerde, DGBH'ler stratejik bir öneme sahiptir [34]. Boru hatlarının tasarımı, inşası ve işletimi, enerji arzının kesintisiz sürdürülebilmesi için büyük önem taşımaktadır. Boru hattı tasarımı; mühendislik ve çevresel parametreler, güvenlik önlemleri ve ekonomik değer değerlendirmeleri gibi pek çok kritik unsuru kapsamaktadır. Boru hatlarının güvenli bir şekilde inşaatının yapılması ve işletilmesi için, çok sayıda yönetmelik ve ulusal/uluslararası standart dikkate alınmaktadır. Bu yönetmelik ve standartların bazıları Çizelge 3.1'de sunulmuştur.

Çizelge 3.1. Doğal gaz boru hatlarının yapımı ve işletilmesine yönelik standartlar ve yönetmelikler

Yönetmelik/Standart Adı	Kapsamı ve Amacı
API (American Petroleum Institute) Standartları	Boru hattı tasarımı, malzeme seçimi ve güvenlik gereklilikleri
ASME B31.8 (Gas Transmission and Distribution Piping Systems)	Doğal gaz boru hattı sistemleri için tasarım ve işletim gereksinimleri
ISO 13623 (Petroleum and natural gas industries - Pipeline transportation systems)	Boru hattı taşıma sistemleri için genel gereksinimler
EN 1594 (Gas supply systems - Pipelines for maximum operating pressure over 16 bar)	Yüksek basınçlı doğal gaz hatları için güvenlik ve işletim standartları
TS EN ISO 3183 (Petrol ve doğalgaz sanayileri-Boru hattı ile taşıma sistemleri için çelik borular)	Doğal gaz ve petrol taşıma amaçlı kullanılan çelik boruların özellikleri
Boru Hatları İle Petrol Taşıma Anonim Şirketi (BOTAŞ) Ham Petrol ve Doğal Gaz Boru Hattı Tesislerinin Yapımı ve İşletilmesine Dair Teknik Emniyet ve Çevre Yönetmeliği	Boru hatlarının yapımı, işletimi ve çevresel güvenlik önlemleri ile ilgili teknik gereklilikler
Türkiye Boru Hattı Sistemleri ve Sıvı Depolama Tankları Deprem Yönetmeliği	Boru hattı ve sıvı depolama tanklarının deprem etkilerine karşı dayanıklılık gereklilikleri

2024 yılının Mayıs ayı itibarı ile Türkiye’de 20 000 km’yi aşan bir uzunlukta DGBH bulunmaktadır [35]. Türkiye doğal gaz iletim hattını sunan görsel Harita 3.1’de gösterilmiştir [36].




Harita 3.1. Türkiye doğal gaz iletim sistemi haritası

Harita 3.1’de görülen ve Türkiye’nin doğal gaz iletim sisteminde yer alan ana hatlar, ülkenin enerji arz güvenliği ve bölgesel enerji dağıtımını açısından kritik bir öneme sahiptir. Stratejik konuma sahip bu hatlar, hem ulusal hem de uluslararası enerji akışının verimli ve güvenli bir şekilde sağlanmasında temel rol oynamaktadır. Türkiye’de DGBH altyapısı, BOTAŞ gibi kurumlar öncülüğünde genişletilmektedir. Boru hatları, genellikle çelik borular kullanılarak üretilir ve ihtiyaca uygun olarak yer altına döşenmektedir. DGBH’lerin yönetmeliklere uygun olarak tasarlanması ve şartnamelere uygun biçimde inşa edilmesi, hem güvenlik hem de sürdürülebilirlik açısından büyük önem arz etmektedir. DGBH projelerinde maliyet, çevresel etki, inşaat teknikleri ve operasyona dair detaylar, doğal gazın nihai kullanıcıya ulaştırılması için belirleyici faktörlerdir.

Çalışmanın bu bölümünde DGBH inşaat süreçleri hakkında genel bilgiler sunulmuş, ardından bu hatların kullanımının çevresel ve ekonomik etkilerine değinilmiştir. Bölüm başlıkları içeriğinde, güzergâh belirleme sürecinden başlayarak boru hattı inşaatının tamamlanmasını müteakip hat boyunca çevre düzenlemesi gibi tüm aşamalara odaklanılmış ve DGBH inşaatının farklı adımlarına ayrıntılı olarak yer verilmiştir.

3.1. Doğal Gaz Boru Hattı Yapım İşleri

DGBH inşası, oldukça karmaşık ve çok aşamalı bir süreç olup, her aşamanın kendine özgü zorlukları, teknik gereksinimleri ve titizlikle yürütülmesi gereken operasyonel detayları vardır. Bu süreç, güzergâhın belirlenmesinden inşaatın tamamlanmasına ve hattın işletmeye alınmasına kadar farklı adımları kapsar [37]. Bu adımların görsel bir temsili Şekil 3.1’de sunulmuştur [38].



Şekil 3.1. Doğal gaz boru hattı inşaatı aşamaları

Güzergâh belirleme, çalışma şeridinin tesviyesi, boru dizgisi ve kazı işlemleri, boruların kaynaklanması ve indirilmesi gibi aşamaların her biri, kendine özgü mühendislik uygulamaları ihtiva etmekte ve belirli standartlara uygun olarak yapılması gerekmektedir. Bu nedenle, DGBH projelerinin inşası, çevresel ve teknik gereksinimlerin titizlikle dikkate alınmasını ve çeşitli aşamalar arasında güçlü bir koordinasyonun sağlanmasını zorunlu kılmaktadır.

3.1.1. Çalışma şeridinin tesviyesi ve hazırlanması

DGBH inşaatında ilk adım, çalışma şeridinin uygun şekilde tesviye edilmesi ve inşaatı hazır hâle getirilmesidir. Bu süreç, boru hattının geçeceği güzergâh boyunca bitki örtüsünün temizlenmesi, arazi tesviyesi, toprağın stabilize edilmesi ve çalışma alanının inşaat ekipmanlarının kullanımı için uygun hâle getirilmesini içermektedir. Bu aşama, inşaatın sonraki adımlarının daha verimli ve güvenli bir şekilde gerçekleştirilmesi açısından kritik öneme sahiptir. Tesviye işlemleri sırasında çevresel etkiler dikkate alınarak, doğal yaşamın en az düzeyde etkilenmesi ve çevresel sürdürülebilirliğin sağlanması hedeflenmelidir. Tesviye işleminin tamamlanıp kazı güzergâhının belirlenmiş olduğu bir çalışma alanı görüntüsü Resim 3.1’de verilmiştir.



Resim 3.1. Çalışma şeridinin hazırlanması ve kazı güzergâhının işaretlenmesi

Çalışma şeridinin hazırlanması aşamasında, özellikle yüksek eğimli araziler veya sulak alanlar gibi zorlu coğrafi koşullar için ek önlemler alınması gerekebilir. Bu alanlarda, erozyon kontrol önlemleri, drenaj sistemleri kurulumu ve geçici stabilize yöntemleri

uygulanarak çalışma güvenliğinin sağlanması amaçlanmalıdır. Tesviye ve hazırlık aşamasının tamamlanmasının ardından, boru hattının döşeneceği güzergâh üzerinde güvenli bir çalışma ortamı sağlanmış olur.

3.1.2. Boru dizgisi ve kazı yapılması

Boru dizgisi ve kazı işlemleri, DGBH inşaatının kritik aşamalarından biridir ve dikkatli mühendislik uygulamaları gerektirir. Bu aşamada, boruların çalışma şeridinde uygun şekilde dizilmesi, kaynak işlemlerinin yapılması ve ardından bu boruların yerleştirileceği hendeğin kazı işlemleri gerçekleştirilir. Öncelikle, boru dizgisi işlemleri sırasında borular, güzergâh üzerinde dikkatle düzenlenir ve her bir boru, kaynak işlemi öncesinde uygun pozisyonda yerleştirilir. Bu süreçte, boruların hizalanması ve doğru açıda konumlandırılması önemlidir. Bu durum kaynaklama ve indirme işlemlerinin güvenliğini doğrudan etkilemektedir.

Kazı işlemleri ise boruların yerleştirileceği hendeklerin kazılması işlemidir. Bu işlem sırasında güzergâhın coğrafi ve topografik koşulları dikkate alınarak uygun kazı yöntemleri belirlenir. Kazı işleminde hendeklerin doğru derinlikte ve genişlikte açılması sağlanmalı, bu esnada toprak stabilitesini korumak amacıyla şevlendirme veya destekleme teknikleri uygulanmalıdır. Boru dizgisi ve kazı işlemlerine dair örnek fotoğraflar Resim 3.2'de gösterilmiştir [39].




(a)

(b)

Resim 3.2. Boru dizgisi ve kazı işlemi (a) Boru dizgisi (b) Kazı yapılması


Boru dizgisi ve kazı işlemleri hem iş güvenliği açısından hem de inşaat kalitesi açısından oldukça önemlidir ve belirli mühendislik standartlarına uygun olarak yürütülmelidir. DGBH

inşaat süreçlerinde uygulanan ve yumuşak toprakta gerçekleştirilen örnek bir kazı kesiti Şekil 3.2’de gösterilmiştir.



Şekil 3.2. Yumuşak topraklı bir zeminde gerçekleştirilen boru hattı döşemesi için örnek kazı kesiti

Şekil 3.2’de gösterilmiş olan kesitte, zeminin yumuşak toprak olması sebebiyle hendek tabanına temas edecek şekilde boru yerleştirildiği görülmektedir. Kayalık zeminde yapılacak uygulamalarda ise kazı kesiti için uyulması gereken detaylar Şekil 3.3’te sunulmuştur.



Şekil 3.3. Kayalık bölgede gerçekleştirilen boru hattı döşemesi için örnek kazı kesiti

Her iki kesitte de yer alan ölçü metrikleri, topografik koşullara göre ya da yerinde alınması gerekli olan farklı kararlarla paralellik gösterecek şekilde değişebilir. Kazı işleri için belirlenmiş olan standart ölçüler Çizelge 3.2’de sunulmuştur.

Çizelge 3.2. Boru çaplarına göre standart kazı kesitleri

D	W	H
Boru çapı (inç)	Taban Kazı Genişliği (cm)	Boru üstündeki en küçük örtü kalınlığı (cm)
6-8-10	70	120
12-14	80	120
16	90	120
18-20	100	120
24	110	120
30	130	120
36	140	120
40-42	150	130
48	170	130

Çizelge 3.2’de sunulan değerler yumuşak toprakta yapılan kesitler için geçerlidir. Kayalık bölgelerde taban kazı genişliği en az 20 cm daha geniş oluşturulmalıdır. Ayrıca boru üstündeki örtü kalınlığı da kayalık bölgelerde 20 cm daha düşük değer alabilir. Zemin tipi fark etmeksizin, kazı içerisine yerleştirilen borunun üst kotu ile geri dolgu arasında 20 cm ince malzeme dolgusu yer almalıdır. Kanal şevinin açısı ise,

- Kayalık zemin $\rightarrow 90^\circ$
- Normal toprak $\rightarrow 60^\circ$
- Gevşek toprak $\rightarrow 45^\circ$
- Kum $\rightarrow 30^\circ$

şeklinde uygulanmalıdır.

Kayalık zeminde kanal kesiti açıldığı takdirde, Şekil 3.3’te gösterildiği gibi çelik boru için 20 cm kalınlığında ek bir kum yatak oluşturulmalı, böylelikle boru ile kayalık zemin arasında güvenli bir mesafe bırakılmalıdır.

3.1.3. Kaynak işleri

DGBH'lerin güvenli ve uzun ömürlü olmasını sağlamak için kaynak işlemleri, inşaat sürecinin en kritik aşamalarından birini oluşturur. Boruların sızdırmaz bir şekilde birleştirilmesini sağlayan bu işlem, hem yapısal dayanıklılık hem de gaz iletiminin güvenliği açısından hayati bir öneme sahiptir.

Kaynak işlemleri sırasında uygulanan yöntemlerin uluslararası standartlara uygun olması, boru hattının ömrünü doğrudan etkileyen önemli bir faktördür. Bu bağlamda API 1104 ve benzeri standartlar, kaynak işlemlerinin tasarım ve uygulama süreçlerinde bir rehber niteliğindedir [40-42]. Ayrıca, bu standartlara uygun olarak işlemlerin gerçekleştirilmesi, kaynak noktalarının dayanıklılığını artırarak boru hattında olası gaz kaçaklarını önlemek ve sistemin bütünlüğünü korumak adına kritik bir rol oynar.

Kaynak işlemi, DGBH'lerin güvenli ve dayanıklı bir şekilde inşa edilmesi için titizlikle uygulanması gereken bir süreçtir. İlk aşamada, boruların kaynaklanacak yüzeyleri hazırlanır. Bu hazırlık süreci, kaynak bölgelerindeki yüzeylerin yağ, kir ve pas gibi materyallerden arındırılmasını kapsar. Kaynak yüzeyinin bu tür maddelerden arındırılması, kaynak dikişlerinin sağlamlığını doğrudan etkiler ve hatalı birleşimleri en aza indirir. Temizliğin ardından, kaynak işlemi için yüzeylere uygun açılar verilmesi ve kenarların şekillendirilmesi gibi ek hazırlıklar yapılır. Özellikle boruların birbirine uygun açısı ve kenar özellikleriyle birleştirilmesi, kaynak işleminin kalitesini artırır ve yapısal bütünlüğü güçlendirir. Bu işlemler, kaynak bağlantısının dayanıklılığını artırmak ve hatasız bir birleşim sağlamak amacıyla yapılır. Yüzey hazırlığı sırasında kullanılan ekipman ve yöntemlerin uluslararası standartlara uygun olması, hem kaynak kalitesini hem de boru hattının uzun ömürlü olmasını doğrudan etkiler.

DGBH projelerinde, çelik borular kaynakçılar tarafından birleştirilir. Kaynak işlemlerinde kullanılan güvenlik ekipmanları ve alınan güvenlik önlemleri büyük önem taşır. Kaynak işlemi sırasında yayılan aşırı sıcaklık, yoğun ışık ve zararlı gazlar nedeniyle uygun kaynak maskeleri, eldivenler ve koruyucu giysilerin kullanılması gereklidir. Kaynak işlemini gerçekleştiren personel, standartlara uygun kişisel koruyucu donanımlarla donatılmalı ve sahada sürekli gözetim altında tutulmalıdır. Ayrıca, çalışma alanında ilk yardım ekipmanlarının ve prosedürlerin hazır bulundurulması, olası kazaların etkilerini en aza

indirmek için kritik bir gerekliliktir. Bu önlemler, yalnızca çalışan güvenliğini sağlamakla kalmaz, aynı zamanda kaynak işleminin kalitesini ve sürekliliğini garanti altına alır. Örnek bir kaynak işlemi fotoğrafı Resim 3.3'te verilmiştir.



Resim 3.3. Boru birleşimi için yapılan kaynak işlemi

DGBH'lerde yaygın olarak kullanılan ark kaynağı yöntemi, boru uçları arasında elektrik arkı oluşturarak yüksek sıcaklıkta birleştirme işlemini gerçekleştirir. Bu yöntem, uluslararası standartlara uygun olarak uygulandığında, yüksek sızdırmazlık ve dayanıklılık sağlaması nedeniyle güvenilir bir tercihtir. Kaynak işlemi sırasında boruların doğru pozisyonda hizalanması, kaynak dikişinin düzgün bir şekilde uygulanması ve kaynak parametrelerinin hassasiyetle kontrol edilmesi, işlemin başarısını belirleyen temel unsurlar arasında yer alır. Ayrıca, kaynak işlemi sürecinin kalitesini artırmak için yapılan uygulamalar, genellikle korunaklı alanlarda ya da uygun hava koşulları altında gerçekleştirilir.

Kaynak işleminin tamamlanmasını müteakip kalite kontrol süreci başlar. Bu süreçte, kaynak dikişlerinin iç ve dış yapısal bütünlüğü ile gaz sızdırmazlık performansı titizlikle test edilir. Görsel kontroller, yüzeyde meydana gelebilecek hataların hızlı bir şekilde tespit edilmesini sağlarken, daha derin kusurların belirlenmesi için radyografik muayene gibi ileri teknikler kullanılır. Radyografik muayene, kaynak dikişinin iç yapısını detaylı bir şekilde analiz ederek potansiyel çatlak veya gözenek gibi kusurların belirlenmesine olanak tanır. Tüm bu kalite kontrol aşamalarında ulusal ve uluslararası standartlara uyumun sağlanması, boru hattının dayanıklılığını ve işletme güvenliğini artırmada kritik bir rol oynar [40].

Kaynak işlemleri sırasında sahadaki çevresel ve operasyonel koşullar, sürecin güvenliği ve kalitesi üzerinde kritik bir etkiye sahiptir. Özellikle dış mekânda gerçekleştirilen kaynak işlemlerinde, rüzgâr, yağış ve aşırı sıcaklık gibi çevresel faktörler kaynağın kalitesini olumsuz yönde etkileyebilir. Bu tür durumların olası etkilerini en aza indirmek için, kaynak işlemleri genellikle, Resim 3.4'te bir örneği gösterilmiş olan ve özel olarak tasarlanmış kaynak çadırlarında gerçekleştirilir.



Resim 3.4. Kaynak işlemleri sırasında kullanılan çadır

Bu çadırlar, kaynak alanını dış ortam koşullarından izole ederek stabil bir çalışma ortamı sağlar. Stabil ortam sayesinde kaynak sırasında meydana gelebilecek deformasyonlar, kaynak hataları veya kalite kayıpları önemli ölçüde azaltılmış olur. Bunun yanı sıra, kaynak çadırları kaynak ekipmanının ve kaynak yapan kişinin korunmasına da katkı sağlayarak iş güvenliği standartlarına uygun bir çalışma ortamı yaratır [43].

3.1.4. Korozyon önlemleri

DGBH'lerin uzun ömürlü olmasını sağlamak ve korozyona karşı dayanıklılığını artırmak için fiziksel kaplama ve katodik koruma olmak üzere iki temel koruma yöntemi kullanılmaktadır. Bu yöntemler, boru hattının yapısal bütünlüğünü koruyarak güvenli ve sürdürülebilir bir iletim sağlamaya yönelik uygulamalardır. Korozyona karşı koruma süreci, boruların fabrikada özel kaplamalarla kaplanması ve sahada yapılan kaynak işlemleri sonrasında gerekli kaplama yenilemelerini içeren aşamalardan oluşur. Borular, fabrikada korozyona dayanıklı bir kaplama ile kaplanarak sahaya getirilir. Bu kaplama, genellikle

polietilen, epoksi veya polipropilen gibi malzemelerden yapılır ve borunun çevresel etkilerden korunmasını sağlar. Kaplamanın amacı, borunun toprağın kimyasal bileşenleriyle doğrudan temasını engelleyerek korozyona karşı bir bariyer oluşturmaktır [44]. Kaplama işlemleri tamamlanmış ve uygulama öncesi istiflenmiş çelik borulara örnek bir fotoğraf Resim 3.5’te sunulmuştur.




Resim 3.5. Polipropilen kaplı çelik borular

Sahada, boruların birleştirilmesi sırasında kaynak işlemleri gerçekleştirilir. Bu kaynak noktaları, kaplamanın bozulduğu yerlerdir ve bu bölgelerin de korozyona karşı korunması gereklidir. Bu nedenle, kaynak işlemi tamamlandıktan sonra, borunun bu açıktaki kalan bölgeleri sahada tekrar kaplanır. Bu kaplama işlemi, fabrikada kullanılan malzeme ile uyumlu özel bir koruyucu malzeme kullanılarak yapılır ve boru hattının tüm uzunluğu boyunca koruyucu kaplamanın sürekliliği sağlanır. Bu sayede borunun hem fabrikada kaplanan hem de sahada yenilenen bölgeleri eşit şekilde korunur ve hattın genel dayanıklılığı artırılır. Boru hatlarının korozyona karşı korunmasında kullanılan diğer bir yöntem ise katodik korumadır.

Katodik koruma, boru hattının korozyon riskine karşı elektrokimyasal bir yöntemle korunmasını sağlar. Bu yöntem, borulara koruyucu bir elektriksel potansiyel uygulayarak borunun korozyona uğramasını önler. Katodik koruma genellikle galvanik anot sistemi ve dış akım uygulanarak yapılan koruma olmak üzere iki şekilde uygulanır.

Galvanik anotlu katodik koruma

Galvanik anot sistemi, daha aktif (daha negatif potansiyele sahip) bir metalin, korunan boruya bağlanmasıyla çalışır. Bu aktif metal anot olarak kullanılır ve boru hattı boyunca meydana gelebilecek korozyon, bu anotlar üzerinde toplanarak borunun zarar görmesi engellenir. Bu yöntemde kullanılan anotlar genellikle magnezyum veya çinko gibi metallerdir. Anot malzemelerinin seçimi sırasında, hem boru hattının bulunduğu bölgenin toprak direnci hem de anotların kimyasal dayanıklılığı dikkate alınır. Hattın gömülü olduğu toprak koşullarına bağlı olarak seçilen bu malzemeler, boru hattının uzun ömürlü olmasını sağlamak amacıyla belirli aralıklarla yerleştirilir. Galvanik anot sistemlerinin tasarımında, boru hattının geometrisi ve çevresel koşulları dikkate alınarak en uygun yerleşim planı yapılır. Sistemin etkinliği, düzenli aralıklarla yapılan kontroller ve bakımlar ile sağlanır. Galvanik anot sisteminin görseli Şekil 3.4'te verilmiştir.




Şekil 3.4. Galvanik anot sistemi

Dış akım kaynaklı katodik koruma

Dış akım uygulanarak yapılan katodik koruma yöntemi ise bir doğru akım kaynağı kullanılarak boru hattına düşük voltajlı bir elektrik akımı uygulanması prensibine dayanır. Bu yöntem, özellikle uzun mesafeli boru hatlarında ve korozyon riskinin yüksek olduğu bölgelerde tercih edilir. Akım kaynağı, boru hattına bağlanan ve borunun her zaman katodik (yani korunan) durumda kalmasını sağlayan bir dış güç kaynağından beslenir. Bu sayede

borunun metalik yapısı, dış çevredeki kimyasal reaksiyonlara karşı korunur ve korozyon süreci minimize edilir. Dış akım kaynaklı katodik koruma sisteminin görseli Şekil 3.5'te sunulmuştur.



Şekil 3.5. Dış akım kaynaklı katodik koruma sistemi

Kaplama ve katodik koruma yöntemlerinin her ikisi de boru hattının güvenliğini ve uzun vadeli dayanıklılığını sağlamak açısından kritik bir öneme sahiptir. Kaplama işlemlerinin kalitesi ve sürekliliği, boru hattının korozyona karşı ne kadar dayanıklı olacağını belirleyen temel unsurlardır. Katodik koruma ise borunun tüm yüzeyinde sürekli bir koruma sağlamak amacıyla kullanılır. Bu nedenle, her iki koruma yöntemi de dikkatle uygulanmalı ve periyodik olarak kontrol edilmelidir. Kaplamanın düzgün bir şekilde uygulanması ve katodik korumanın etkin çalışması, boru hattının ömrünü uzatan ve işletme sırasında karşılaşılabilecek potansiyel sorunları azaltan önemli birer adımdır.

3.1.5. Boruların indirilmesi

Boruların indirilmesi, DGBH inşasında kritik bir aşamayı temsil eder. Bu aşama, inşaat sürecinin genel verimliliği ve güvenliği açısından önemli olduğu kadar, boruların fiziksel bütünlüğünü koruma noktasında da belirleyicidir. Boruların indirilmesi sırasında kullanılan yöntemler, iş sahası koşulları, çevresel faktörler ve teknik gereklilikler göz önünde bulundurularak belirlenir. Sürecin başarılı bir şekilde yönetilmesi, boru hattının uzun vadeli performansı üzerinde doğrudan etkilidir [45, 46].

Boruların indirilmesi işlemine başlamadan önce, çalışma alanı detaylı bir şekilde incelenmeli ve gerekli hazırlıklar tamamlanmalıdır. Boruların indirileceği hendeklerin kazı ölçüleri, yerel zemin yapısına ve borunun teknik özelliklerine göre belirlenir. Bu kapsamda, kazı derinliği ve genişliği gibi parametreler uluslararası standartlar ve proje gereksinimlerine uygun olmalıdır. Örneğin, gevşek zeminlerde hendek yanlarına destek yerleştirilmesi veya şevlendirme yapılması gerekebilir. Bu tür önlemler, hem iş güvenliğini artırır hem de boru hattının uzun vadeli stabilitesine katkı sağlar. Bu hazırlıklar tamamlanmadan yapılan indirme işlemleri, projede hem gecikmelere hem de olası yapısal sorunlara yol açabilir.

Boru hattı güzergâhındaki coğrafi farklılıklar, indirme sırasında kullanılacak ekipman ve yöntemlerin seçiminde belirleyici bir rol oynar. Örneğin, eğimli arazilerde veya sulak alanlarda, stabilizeyi sağlamak ve erozyonu önlemek amacıyla ek önlemler alınması gerekebilir. Boruların indirilmesinden önce, güzergâh üzerinde işaretleme yapılır ve alanın temizliği sağlanır. Bu süreçte, toprak stabilizasyonu ve güvenlik tedbirleri titizlikle uygulanır.

Boruların indirilmesi işlemi, genellikle aşağıdaki adımları içerir:

- **Ekipman Hazırlığı ve Konumlandırma:** Boruların indirileceği alanda, uygun vinç veya benzeri kaldırma ekipmanları önceden hazırlanır ve yerleştirilir. Kullanılacak ekipman, boruların çapı, uzunluğu ve ağırlığı dikkate alınarak seçilir. Ekipmanların, borulara zarar vermeyecek şekilde tasarlanmış bağlantı noktaları ve destek sistemleriyle donatılması gereklidir.
- **Boru Taşınması ve Pozisyonlama:** Borular, çalışma alanına taşındıktan sonra dikkatlice hizalanır ve indirilecek pozisyona getirilir. Bu işlem sırasında, boru yüzeyindeki kaplamaların zarar görmesini engellemek için özel taşıma aparatları kullanılır. Borular, hendek içine indirildikten sonra gerekli pozisyona yerleştirilir ve eksen hizalaması yapılır.
- **İndirme ve Yerleştirme:** İndirme işlemi sırasında, boruların hendek kenarlarına veya diğer yapısal elemanlara çarpmasını önlemek için vinç hareketleri dikkatle koordine edilir. Borular, kontrollü bir şekilde hendek tabanına yerleştirilir ve önceden hazırlanan destek yapılarına uygun şekilde oturtulur. Boruların düzgün bir şekilde yerleştirilmesi, sonraki bağlantı süreçlerinde olası sorunların önüne geçmek açısından kritik bir önem taşır.

DGBH projelerinde boruların indirilme sürecini gösteren örnek fotoğraflar Resim 3.6’da paylaşılmıştır.



(a)



(b)

Resim 3.6. Doğal gaz borularının hendeğe indirilmesi

3.1.6. Boru üzerinin kapatılması ve geri dolgu işlemleri

Boru üzerinin kapatılması ve geri dolgu işlemleri, DGBH inşaatının son aşamalarından biridir. Bu aşama, boruların hendek içerisine yerleştirildikten sonra uygun şekilde kapatılması ve stabilizasyonunun sağlanması amacıyla gerçekleştirilir. Bu süreç, boru hattının fiziksel bütünlüğünün korunması, çevresel etkilerden izole edilmesi ve uzun ömürlü bir yapı oluşturulması açısından büyük önem taşır.

Geri dolgu işlemi, genellikle hendek açılırken çıkarılan zeminin yeniden kullanılmasıyla gerçekleştirilir. Bu yöntem, doğal yapının korunmasını sağlamak ve maliyetleri düşürmek açısından avantajlıdır. İlk olarak, borular hendek tabanına yerleştirildikten sonra, hendekten çıkarılan uygun malzeme borunun etrafına kademeli olarak geri doldurulur. Bu dolgu sırasında, borunun hemen çevresinde daha hassas bir koruma tabakası oluşturmak adına borunun etrafına ince ve taşsız bir malzeme, örneğin ince taneli kum, uygulanabilir. Bu koruma tabakası genellikle borunun üst kısmında 20-30 cm kalınlığında bir bölgeyi kapsar.

Geri dolgu sırasında sıkıştırma işlemi aşamalı olarak gerçekleştirilir. Her dolgu katmanı yaklaşık 30-50 cm olacak şekilde dökülür ve uygun ekipmanla sıkıştırılır. Bu kademeli sıkıştırma işlemi, boru hattının uzun vadeli stabilitesini sağlamak, toprağın zamanla çökmesini engellemek ve olası boşlukların oluşmasını önlemek için kritik bir adımdır.

Özellikle derin hendeklerde, bu işlem daha dikkatli ve kademeli olarak yapılmalıdır. Dolgu işlemi sırasında kullanılan malzeme, keskin taşlar veya boruya zarar verebilecek iri maddeler içermemelidir. Hendekten çıkarılan zemin uygun değilse, bu durumda borunun üzerine gelecek ilk katman için dışarıdan uygun nitelikte malzeme getirilmesi gerekebilir. Bu malzeme borunun üzerine uygulandıktan sonra, geri kalan dolgu işlemi hendekten çıkarılan orijinal zeminle tamamlanabilir. Bu sayede, borunun zarar görmesi ve korozyona uğraması önlenmiş olur.

Son aşamada, dolgu işlemi tamamlandıktan sonra hendek yüzeyi orijinal arazi seviyesiyle hizalanacak şekilde düzeltilir. Bu aşamada, boru hattının güvenliğinin sağlanması amacıyla bir ikaz şeridi yerleştirilir. Bu ikaz şeridi, borunun üzerine yaklaşık 30-50 cm dolgu yapıldıktan sonra, hattın konumunu belirlemek ve olası kazılarda borunun zarar görmesini önlemek amacıyla kullanılır. Bu düzenleme, hem hattın çevresel olarak entegre edilmesini sağlar hem de toprak kaymalarını ve yüzeysel erozyonu önler. Ayrıca, geri dolgu sırasında alınan erozyon kontrol önlemleri ve yüzeyin bitkilendirilmesi gibi uygulamalar, çevresel etkilerin en aza indirilmesi ve hattın uzun vadeli dayanıklılığının sağlanması açısından önemlidir. Geri dolgu işlemine örnek teşkil eden fotoğraflar Resim 3.7’de sunulmuştur.



(a)

(b)

Resim 3.7. Geri dolgu sürecinde olan boru hatları (a) Koruma dolgusu yapılması (b) İkaz şeridi uygulaması

3.1.7. Hidrostatik test yapılması

Hidrostatik test, DGBH projelerinde, boru hattının sızdırmazlık ve yapısal dayanıklılığını değerlendirmek amacıyla gerçekleştirilen kritik bir prosedürdür. Bu test, hattın işleme alınmadan önce gerekli güvenlik standartlarına uygun şekilde kontrol edilmesini sağlar ve uzun vadeli performansı doğrular. Hidrostatik test süreci, boru hattının temizlenmesi, suyla

doldurulması, basınçlandırılması ve testin ardından tahliye ile kurutma işlemlerini içerir [47].

Test sürecinde ilk adım, boru hattının kapsamlı bir şekilde temizlenmesidir. Temizlik işlemi, boru iç yüzeyinde birikmiş yabancı maddelerin ve inşaat kalıntılarının giderilmesini amaçlar. Ardından, boru hattı teknik gerekliliklere uygun şekilde hazırlanmış suyla doldurulur ve hava tahliye valfleri yardımıyla içerideki hava tamamen boşaltılır. Hava tahliyesi, test sonuçlarının doğruluğunu sağlamak ve basınç kayıplarını önlemek için kritik bir adımdır. Kullanılan suyun, partiküllerden arındırılmış ve pH seviyesinin belirli sınırlar içinde (örneğin, 6,5-10,5 aralığında) tutulmuş olması gerekir. Düşük sıcaklıklarda test yapılacaksa, suya antifriz eklenerek donma riski bertaraf edilir.

Boru hattı tamamen doldurulduktan sonra, tasarım basıncını aşan bir test basıncı uygulanır. Genellikle bu basınç, hattın maksimum çalışma basıncının %25-50 fazlası olarak belirlenir. Basınç kademeli olarak artırılır ve en az 24 saat süreyle sabit tutulur. Bu süre boyunca basınç ve sıcaklık değişimleri hassas ölçüm cihazları yardımıyla sürekli izlenir. Özel geçiş bölgeleri, kot farkları veya yüksek riskli alanlar gibi spesifik koşullarda, basınç değerleri bu alanlara göre uyarlanır ve test sırasında gerekli ek önlemler alınır. Hidrostatik test tamamlandığında, hattaki su tahliye edilir ve boru hattının iç yüzeyi tamamen kurutulur. Kurutma işlemi, hattın işleme alınmadan önce nemden tamamen arındırılmasını sağlamak amacıyla yapılır. Kurutma tamamlandıktan sonra, hattın iç yüzeyindeki sızdırmazlık ve geometrik yapıya ilişkin ek kontroller gerçekleştirilir. Bu kontroller, boru hattının hem güvenlik hem de performans açısından işleme hazır olduğunu doğrular.

Sonuç olarak, hidrostatik test, DGBH projelerinin güvenlik ve dayanıklılık açısından en kritik aşamalarından biridir. Hattın güvenli bir şekilde işleme alınabilmesi için bu testlerin standartlara uygun şekilde yapılması gerekmektedir.

3.2. Çevresel ve Ekonomik Etkiler

DGBH projeleri, geniş kapsamlı çevresel ve ekonomik etkiler yaratan karmaşık mühendislik süreçlerini içerir. Bu tür projeler, doğal kaynakların kullanımı, habitatların korunması ve yerel topluluklara olan etkileri gibi çok yönlü bir değerlendirme gerektirir. Aynı zamanda, enerji arz güvenliğini sağlamak ve ekonomik büyümeye katkıda bulunmak amacıyla büyük

ölçekli yatırımları temsil eder. Bu nedenle, projelerin çevresel ve ekonomik etkilerinin dikkatlice ele alınması, hem sürdürülebilirlik ilkelerine uygunluğu hem de projelerin uzun vadeli başarısını garanti altına almak için kritiktir.

DGBH yapımı sırasında oluşan çevresel etkiler arasında, özellikle doğal habitatların bozulması, toprak erozyonu ve su kaynaklarına yönelik tehditler ön plana çıkmaktadır. Boru hattı güzergâhında gerçekleştirilen kazı ve inşaat faaliyetleri, yerel ekosistemlerin dengesini bozabilir ve flora ile hayvan varlığı üzerinde olumsuz etkiler yaratabilir. Örneğin, toprağın hareketi, yüzey suyu akışını etkileyebilir ve su kirliliğine yol açabilir. Bununla birlikte, çevresel etkileri en aza indirmek için proje başlangıcında kapsamlı bir çevresel etki değerlendirmesi (ÇED) yapılması gereklidir. Bu raporlar, potansiyel zararların belirlenmesine ve bu zararların önlenmesi için gerekli stratejilerin geliştirilmesine olanak tanır. Ayrıca, kullanılan malzemelerin geri dönüşümlü olması ve inşaat atıklarının uygun şekilde bertaraf edilmesi gibi çevre dostu politikalar da çevresel sürdürülebilirliği artırabilir.

Ekonomik açıdan bakıldığında, DGBH projeleri genellikle büyük maliyetli yatırımları içerir. Yapım aşamasında kullanılan malzemeler, iş gücü ve teknolojik altyapılar, önemli bir başlangıç sermayesi gerektirir. Bununla birlikte, bu tür projeler, bölgesel kalkınmayı teşvik eden önemli bir ekonomik etki yaratır. Örneğin, boru hattı yapım süreçleri sırasında yerel istihdam olanaklarının artması ve inşaat sektörünün canlanması, yerel ekonomiye doğrudan katkı sağlar. Aynı zamanda, enerji taşımacılığına ilişkin maliyetlerin düşürülmesi ve enerji güvenliğinin artırılması gibi dolaylı ekonomik faydalar, DGBH projelerinin stratejik önemini daha da pekiştirir. Ancak, bu maliyetlerin etkin yönetimi ve bütçe planlamasının doğru yapılması, projenin ekonomik sürdürülebilirliği açısından büyük bir önem taşır.

Sonuç olarak, DGBH projeleri çevresel ve ekonomik etkileri itibarıyla dikkatle ele alınması gereken kapsamlı süreçlerdir. Proje planlama aşamasında çevre ve ekonomi arasındaki dengenin gözetilmesi, hem çevresel sürdürülebilirliği hem de ekonomik faydayı artırabilir. Bu tür projelerin, çevreye duyarlı uygulamaların benimsenmesi ve yerel ekonomiye katkı sağlayacak stratejilerle yürütülmesi, uzun vadede daha verimli ve etkili bir enerji altyapısı oluşturulmasına olanak tanır.

4. VERİ SETİ VE YÖNTEM

4.1. Veri Seti

Çalışma kapsamında, Türkiye Cumhuriyeti sınırları içerisinde yer alan DGBH projelerine ait maliyet verileri kullanılmıştır. Veri seti içerisinde, büyük su kütleleri içerisinde geçen veya ülke sınırları dışında hat uzunluğunun önemli bir kısmını barındıran projelere yer verilmemiştir. Veri seti, projelerine 1997 - 2024 yılları arasında başlanmış veya bu tarihler arasında projesi tamamlanmış olan toplamda 113 adet DGBH bilgisi içermektedir. Proje bilgilerine, çoğunlukla Elektronik Kamu Alımları Platformu (EKAP) üzerinden erişilmiştir. Bu platformdan erişilemeyen proje bilgilerine ise proje yüklenicisi olan firma internet siteleri, Türk Mühendis ve Mimar Odaları Birliği (TMMOB) kaynakları, Türkiye Büyük Millet Meclisi (TBMM) oturumlarının tutanakları, bölgesel internet siteleri vb. ikincil kaynaklardan ulaşılmıştır. Yekûn maliyet, BOTAŞ tarafından ihalesi yapılan, yapım işleri ve çelik boru alımı ihalelerinin toplam bedeli olarak kabul edilmiştir. Bazı ihaleler “boru bedeli dâhil” yapıldığından bu ihalelerin sonuçları direkt olarak proje bedeli olarak değerlendirilmiştir.

Veri setinde yer alan, çalışma kapsamında bağımlı ve bağımsız değişken olarak kullanılan parametreler Çizelge 4.1’de verilmiştir.

Çizelge 4.1. Analizlerde kullanılan değişkenler

Bağımsız Değişkenler	Bağımlı Değişken
Boru Çapı (inç)	
Hat uzunluğu (km)	
Hat vanası sayısı (adet)	Güncellenmiş maliyet (\$)
Take-off vana sayısı (adet)	
Pig istasyonu sayısı (adet)	

4.1.1. Boru çapı

Boru çapı değişkeni proje boyunca kullanılan boruların inç birimiyle ifade edilen çapını belirtmektedir. Projelerde boru çapı aynı olsa dâhi boru et kalınlıkları, borunun kullanılacağı

alanın topografik özelliklerine göre değişebilmektedir. Bu çalışma kapsamında boru çapı tek bir değer olarak ele alınmış ve et kalınlıklarına göre ayrı ayrı değerlendirme yapılmamıştır. Bazı projelerde farklı uzunluklara ve farklı ebatlarda çaplara sahip borular kullanılabilmektedir. Bu tipteki projeler için bazen tek bir ihale yapılmakta ve alınan teklif değerlendirilip ihale bir firmaya bırakılmaktadır. Firmaların hangi teklif hazırlama algoritması ile projeler için teklif verdiği bilinmediğinden boru hattında taşınabilecek gaz hacmi ortak bir referans noktası olarak belirlenmiştir. Bu nedenle bahsi geçen farklı çaplarda boruların yer aldığı 23 adet projede çap bilgisi, ağırlıklı ortalama alınarak belirlenmiş ve veri setinde tek bir gözlem olarak yer almıştır. Bu işlemler sırasında aşağıda, Eş. 4.1 – Eş. 4.4 arasında yer alan denklemler kullanılmıştır.

$$V_i = A_i \times L_i = \frac{\pi \times D_i^2}{4} \times L_i \quad (4.1)$$

$$V_{toplamlam} = V_1 + V_2 + \dots V_n \quad (4.2)$$

$$L_{toplamlam} = L_1 + L_2 + \dots + L_n \quad (4.3)$$

$$D_{ort} = \sqrt{\frac{V_{toplamlam} \times 4}{\pi \times L_{toplamlam}}} \quad (4.4)$$

Yukarıda yer verilen eşitliklerde;

V_i (m³) → D_i çapına ve L_i hat uzunluğuna sahip boru hattının hacimsel kapasitesini,

A_i (m²) → D_i çapına sahip boru kesitinin alanını,

L_i (m) → D_i çapına sahip boru hattının uzunluğunu,

D_{ort} (inç) → Uzunluğu $L_{toplamlam}$ olan, farklı çap değerlerine sahip çelik borulardan oluşan boru hattının ortalama çap değerini

göstermektedir. Eş. 4.1 ile farklı çaplara sahip olan boru hattı bölümlerinin ayrı ayrı hacimleri belirlenmiştir. Eş. 4.2’de paylaşılmış olan denklem ise ayrı ayrı hesaplanan hacim değerlerini toplamak için kullanılmıştır. Ardından Eş. 4.3 ile farklı boru çapı değerine sahip olan boru hatlarının hat uzunlukları toplanarak toplam hat uzunluğu belirlenmiş ve Eş. 4.4’deki değerler yerine yazılarak boru hattının tamamını temsil eden ortalama bir çap değeri

elde edilmiştir. Aşağıda, bu hesaplama yöntemine göre, iki farklı boru çapı değerine sahip olan hatlardan oluşan DGBH'nin örnek bir D_{ort} hesaplama süreci anlatılmıştır.

Toplam 300 km uzunluğunda bir DGBH'nin 100 km'si boyunca 8 inç, kalan 200 km mesafe boyunca ise 10 inç çapında borular kullanılıyor olsun. Bu tipte bir projenin makine öğrenmesi algoritmaları yardımıyla model oluşturma aşamasında eğitim veya test verisi olarak kullanılabilmesi için proje temsil kabiliyetini düşürmeden verilerin düzenlenmesi gerekmektedir. Bu noktada boru hattının tamamen gaz ile dolu olduğu düşünüldüğünde elde edilecek hacim bilgisi tüm DGBH projeleri için ortak bir referans noktası oluşturacaktır. Yukarıda örnek olarak verilen proje bilgilerinde, 100 km'lik hat kısmının hacimsel kapasitesi (V_1) ile 200 km'lik kısmın hacimsel kapasitesi (V_2) değerleriyle örnek bir ortalama boru çapı hesabı yapılmıştır. Hesaplamalarda;

$$1 \text{ inç} = 0,0254 \text{ m}$$

$$1 \text{ km} = 1\,000 \text{ m}$$

olarak alınmış ve aşağıdaki sonuçlar elde edilmiştir.

$$V_1 = A_1 \times L_1 = \frac{\pi \times D_1^2}{4} \times L_1 = \frac{\pi \times (8 \times 0,0254)^2}{4} \times (100 \times 1\,000) = 3\,242,93 \text{ m}^3$$

$$V_2 = A_2 \times L_2 = \frac{\pi \times D_2^2}{4} \times L_2 = \frac{\pi \times (10 \times 0,0254)^2}{4} \times (200 \times 1\,000) = 10\,134,15 \text{ m}^3$$

Yukarıda yer alan işlemlerde iki ayrı hattın ayrı ayrı hacimsel kapasiteleri belirlenmiştir. Bu durumda;

$V_{toplam} = V_1 + V_2 = 13\,377,08 \text{ m}^3$ hacim kapasitesine sahip olan 300 km'lik bir boru hattı sisteminin ortaya çıktığı görülmektedir.

Tez kapsamında bu özelliklere sahip bir DGBH projesinin tek bir boru çapı ve tek bir hat uzunluğu ile ifade edilebilmesi için çap bilgilerinin ağırlık ortalamaları alınmış ve kullanılmıştır. Örnek proje için hesaplama yapıldığında;

$$D_{ort} = \sqrt{\frac{V_{toplam} \times 4}{\pi \times L_{toplam}}} = \sqrt{\frac{13\,377,08 \times 4}{3,14 \times 300}} = 9,38 \text{ inç}$$

sonucu elde edilmektedir. Bu durumda örnek değişken değerleri ile oluşturulan proje bilgisi tek bir boru çapı ve toplam hat uzunluğu verisi kullanılarak tek bir gözlem şeklinde veri setinde değerlendirilmiştir. Bu durumda örnek proje veri girdisi;

- D = 9,38 inç
- L = 300 km

şeklinde hesaplanmıştır. Bu değerler veri setinde kullanılarak, 300 km hat uzunluğuna sahip proje bilgileri, eğitim ve test veri setleri içerisinde tek bir gözlem olarak yer almıştır.

4.1.2. Hat uzunluğu

Hat uzunluğu, boru hattının km cinsinden uzunluğunu ifade etmektedir. Burada yer alan veri, proje yapımı sürecinde küçük miktarlarda değişiklik göstermiş olsa dâhi çalışma kapsamında ihaleye konu olan ve ihale bedeline tâbi olan veriler değerlendirmeye alınmış ve veri setinde o şekilde kullanılmıştır.

4.1.3. Hat vanası

Hat vanası, DGBH projelerinde hattın belirli bölümlerini izole etmek veya gaz akışını kesmek için kullanılan önemli bir kontrol ünitesidir [37]. Boru hattının uzunluğu, coğrafi koşullar vb. risk faktörlerine göre sayısı belirlenen bu vanalar elektrikli veya hidrolik eyleyiciler aracılığıyla uzaktan kontrole imkân verecek şekilde tasarlanabilirler. Çalışma kapsamında bağımsız değişkenlerden birisi olarak değerlendirilen hat vanası, DGBH projelerinde güzergâh boyunca konumlanmış hat vanalarının adet bilgisidir.

4.1.4. Take-off vanası

Take-off vanası, DGBH projelerinde ana hattın yan hatlara gaz akışını kontrol etmek üzere tesis edilen kontrol ekipmanlarıdır [47]. Hat vanaları ile benzer şekilde uzaktan kontrol

edilecek şekilde tasarlanabilen bu vana türünün adet bilgisi çalışma kapsamında kullanılan diğer parametrelerden biridir.

4.1.5. Pig istasyonu

Pig istasyonu, çelik boru hatlarında pig operasyonlarının yürütülebilmesi için tesis edilen istasyondur [47]. Pigler aracılığıyla boru hattı iç yüzeyinin temizlenmesi ve yapısal inceleme yapılması gibi işlemler gerçekleştirilmektedir. Çalışma kapsamında ele alınan pig istasyonu parametresi, DGBH boyunca kurulan pig istasyonu sayısının adet olarak bilgisidir.

4.1.6. Güncellenmiş maliyet

Güncellenmiş maliyet, malzemeli olarak ihale edilmiş projelerin ihale bedelinin, Temmuz 2024 Amerikan Doları değerine göre güncellenmiş toplam maliyet verisini ifade etmektedir. Amerikan Dolarının alım gücü göz önünde bulundurularak maliyet verilerinin aynı düzlemde karşılaştırılabilmesini sağlamak amacıyla ABD Tüketici Fiyat Endeksi (CPI- Consumer Price Index) verileri kullanılmıştır. CPI, ABD’de genel enflasyonun yansıması olarak kullanılan bir endekstir [48].

Malzemesiz olarak ihale edilen DGBH projelerinde ise güncellenmiş maliyet, o proje özelinde gerçekleştirilen çelik boru ihale bedelinin yine Temmuz 2024 Amerikan doları değerine göre güncellenmiş hâli ile yapım işi için elde edilen ve aynı tarihe göre güncellenen Amerikan Doları cinsinden maliyet verilerinin toplamını ifade etmektedir. Aşağıda örnek bir güncellenmiş maliyet hesaplama işlemi gerçekleştirilmiştir. Hesaplamalarda kullanılan dolar kurları, Türkiye Cumhuriyet Merkez Bankası’nın (TCMB) Elektronik Veri Dağıtım Sistemi (EVDS) üzerinden görüntülenen günlük döviz alış kuru raporundan çekilen kurlardır [49].

Malzemeli DGBH ihale örneği

Malzemeli ihale, kısaca, boru hattını meydana getirecek olan hat borularının yüklenici tarafından temin edildiği ihale türüdür. Bu şekilde işveren tarafı, hem çelik boru malzeme temin yükümlülüğünü hem de yapım işini yükleniciye bırakmakta ve tek bir ihale ile süreci tamamlamaktadır. Çizelge 4.2’de malzemeli bir ihale veri seti örnek olarak sunulmuş ve örnek veri seti kullanılarak güncellenmiş bir maliyet verisi hesaplanmıştır.

Çizelge 4.2. Örnek malzemeli (yapım işi ve çelik boru alımı) ihale bilgileri

Proje Adı	Doğal Gaz Boru Hattı I
İhale Bedeli	15 600 000,00 ₺
Sözleşme Tarihi	01.12.2017

Güncellenmiş proje maliyetinin hesaplanabilmesi için gerekli bilgiler şunlardır;

- İhale Bedeli (₺) = 15 600 000,00 ₺
- Sözleşme Tarihi = 01.12.2017
- Sözleşme Tarihinde Dolar Kuru = 3,9390 ₺
- Sözleşme Tarihinde ABD CPI değeri = 247,805
- Güncellenmiş Maliyet için Kullanılacak CPI Değeri (Temmuz 2024) = 313,534

Öncelikle sözleşme tarihindeki Türk lirası cinsinden olan sözleşme değerinin, aynı tarihteki Amerikan doları karşılığı, aşağıda Eş. 4.5'te sunulmuş denklem aracılığıyla hesaplanır.

$$\text{İhale Bedeli (\$)} = \frac{\text{İhale Bedeli}}{\text{Dolar kuru}_{\text{sözlş. tarihi}}} \quad (4.5)$$

$$\text{İhale Bedeli (\$)} = \frac{15\,600\,000,00}{3,9390} = 3\,960\,396,04 \$$$

Hesaplama sonucunda örnek verilerle oluşturulmuş olan projenin sözleşme tarihindeki Amerikan doları cinsinden maliyeti 3 960 396,04 \$ olarak hesaplanmıştır. Sıradaki işlem ise bu maliyet değerinin CPI değerleri dikkate alınarak 2024 yılının Temmuz ayına tekabül eden alım gücünün hesaplanmasıdır. Bu işlemi gerçekleştirmek için Eş. 4.6'daki denklem kullanılmıştır.

$$\text{Güncellenmiş Maliyet (\$)} = \frac{\text{İhale Bedeli (\$)} \times \text{CPI}_{\text{Tem.2024}}}{\text{CPI}_{\text{sözlş. tarihi}}} \quad (4.6)$$

$$\text{Güncellenmiş Maliyet (\$)} = \frac{3\,960\,396,04 \times 313,534}{247,805} = 5\,010\,870,69 \$$$

Örnek olarak verilen ihale verilerine göre sözleşmenin imzalandığı tarihte 3 960 396,04 \$ olan projenin finansman bedeli, CPI verileri göz önüne alındığında günümüz koşullarında 5 010 870,69 \$ değerine sahip olduğu görülmektedir. Diğer bir ifadeyle “bu proje 2024 yılının Temmuz ayında ihale edilmiş olsaydı yaklaşık olarak 5 010 870,69 \$ bedel karşılığında yükleniciye bırakılacaktı” şeklinde yorumlanabilir.

Malzemesiz DGBH ihale örneği

Malzemesiz gerçekleştirilen ihaleler, “kapsamları değişken olmakla birlikte” boru alımlarının ayrı olarak yapıldığı ve yükleniciden çelik boru harici diğer tüm malzeme alımı ve işçilik kalemlerinin talep edildiği ihalelerdir. Bu bölümde bu ihale türüne örnek olarak iki ayrı tablo oluşturulmuş ve örnek hesaplamalar yapılarak güncellenmiş maliyet verisine ulaşılmıştır. Çizelge 4.3’te boru harici diğer malzeme ve işçilikler bazında yapılan ihaleye örnek teşkil eden bilgiler sunulmuştur. Ardından bu örnek verilere dayanarak yapılmış bir güncellenmiş maliyet verisi hesaplaması gerçekleştirilmiştir.

Çizelge 4.3. Örnek malzemesiz yapım işi ihale bilgileri

Proje Adı	Doğal Gaz Boru Hattı II
İhale Bedeli	11 745 000,00 ₺
Sözleşme Tarihi	01.10.2018

Güncellenmiş proje maliyetinin hesaplanabilmesi için gerekli bilgiler şunlardır;

- İhale Bedeli (₺) = 11 745 000,00 ₺
- Sözleşme Tarihi = 01.10.2018
- Sözleşme Tarihinde Dolar Kuru = 5,9767 ₺
- Sözleşme Tarihinde CPI değeri = 252,772
- Güncellenmiş Maliyet için Kullanılacak CPI Değeri (Temmuz 2024) = 313,534

Malzemesiz ihale edilen DGBH projelerinde güncellenmiş maliyet verisinin ilk kısmı, bir önceki örnekte yer aldığı şekliyle hesaplandığında;

Güncellenmiş Maliyet (\$) $_{\text{yapım işi}} = 2\,437\,514,69 \$$

değeri elde edilmiştir. Bu bedel yalnızca yapım işi kısmının maliyetini ortaya koymaktadır. Projenin toplam maliyet verisinin elde edilebilmesi için DGBH projesi için alımı yapılan çelik boruların ihale bilgilerinin de hesaba katılması gerekmektedir. Bu kapsamda Çizelge 4.4'te çelik boru alımı ihalesine örnek teşkil edebilecek şekilde bilgiler verilmiş, ardından yapım işi özelinde yapılan hesaplamalara benzer şekilde güncellenmiş maliyet hesaplaması yapılmıştır. CPI değerleri her ayın birinci günü özelinde açıklanmaktadır. Bu nedenle sözleşme tarihlerine en yakın olan ayın ilk günü sözleşme tarihindeki CPI değeri olarak kabul edilmiştir.

Çizelge 4.4. Örnek çelik boru alımı ihale bilgileri

Proje Adı	Doğal Gaz Boru Hattı II için Çelik Boru Temini
İhale Bedeli	15 000 000,00 ₺
Sözleşme Tarihi	19.10.2018

Güncellenmiş maliyet için gerekli bilgiler şunlardır;

- İhale Bedeli (₺) = 15 000 000,00 ₺
- Sözleşme Tarihi = 19.10.2018
- Sözleşme Tarihinde Dolar Kuru = 5,5498 ₺
- Sözleşme Tarihinde CPI değeri (en yakın tarih 01.11.2018) = 252,594
- Güncellenmiş Maliyet için Kullanılacak CPI Değeri (Temmuz 2024) = 313,534

Bu veriler, Eş. 4.5 ve Eş. 4.6'da paylaşılmış denklemlere yerleştirildiğinde;

Güncellenmiş Maliyet (\$) $_{\text{çelik boru alımı}} = 3\,354\,868,79 \$$ şeklinde hesaplanmıştır. Son durumda projenin toplam güncellenmiş maliyeti aşağıda verilen Eş. 4.7'deki denklem kullanılarak hesaplanmıştır.

$$\text{Güncellenmiş Maliyet } (\$)_{\text{toplam}} = \text{Güncellenmiş Maliyet } (\$)_{\text{yapım işi}} + \text{Güncellenmiş Maliyet } (\$)_{\text{çelik boru alımı}} \quad (4.7)$$

Güncellenmiş Maliyet (\$) = 2 432 021,31 \$ + 3 354 868,79 \$ = 5 786 890,10 \$ şeklinde hesaplanmıştır.

Veri setinde yer alan, malzemeli veya malzemesiz olarak ihale edilen tüm DGBH proje maliyet verileri yukarıdaki hesaplamalar ışığında belirlenmiştir. Elde edilen bu maliyet verileri tüm gözlemlerin (projelerin) bağımlı değişken veri kümesini oluşturmaktadır.

Çalışmanın bu bölümüne kadar açıklanan değişken belirleme ve hesaplama adımlarının sonucunda ortaya çıkan veri setinin ilk 25 gözlemine ait değerler Çizelge 4.5'te sunulmuştur.

Çizelge 4.5. DGBH projelerinin değişken değerleri

#	İhale tipi	Boru çapı (inç)	Hat uzunluğu (km)	Hat vanası (adet)	Take- off vanası (adet)	Pig istasyonu (adet)	Güncellenmiş maliyet (milyon \$)	Güncellenmiş birim maliyet (bin \$)
1	Malzemeli	48	290,7	10	4	2	337,12	1 159,83
2	Malzemeli	33,57	318,6	10	2	4	190,87	599,18
3	Malzemeli	40	320,0	9	3	2	169,90	530,94
4	Malzemeli	48	256,0	9	2	2	228,95	894,32
5	Malzemeli	36	239,6	13	5	5	114,17	476,60
6	Malzemeli	48	306,2	9	2	2	294,32	961,16
7	Malzemeli	48	501,0	17	4	4	636,85	1 271,16
8	Malzemeli	40	76,0	4	0	0	28,90	380,22
9	Malzemeli	40	75,0	2	1	1	36,57	487,56
10	Malzemeli	36	62,0	2	0	1	24,08	388,58
11	Malzemeli	36	63,0	2	2	1	23,19	368,07
12	Malzemeli	6	31,0	1	2	1	5,47	176,56
13	Malzemeli	20	117,4	19	16	2	24,94	212,52
14	Malzemesiz	38,09	123,6	3	2	3	52,54	425,04
15	Malzemesiz	6	60,0	2	1	1	7,68	128,03
16	Malzemesiz	10	258,0	1	1	1	35,90	139,14
17	Malzemesiz	14	164,5	6	2	2	27,11	164,81
18	Malzemesiz	16,90	264,0	9	10	5	35,19	133,28
19	Malzemeli	13,23	79,3	1	2	4	15,92	200,76
20	Malzemesiz	31,64	53,6	0	0	2	21,43	399,67
21	Malzemesiz	35,69	76,7	2	3	1	35,60	464,12
22	Malzemesiz	40	57,2	2	1	1	27,87	486,94
23	Malzemesiz	40	57,2	2	1	1	30,22	527,94
24	Malzemesiz	14,83	170,5	5	7	4	49,60	290,89
25	Malzemesiz	10,90	93,4	1	3	6	14,90	159,63

Bir kısmı Çizelge 4.5'te sunulan veri seti içerisinde makine öğrenmesi algoritmalarıyla maliyet tahmini aşamasında kullanılacak olan bağımsız ve bağımlı değişken gözlemlerinin tanımlayıcı özet istatistikleri ise Çizelge 4.6'da gösterilmiştir.

Çizelge 4.6. Değişkenlerin tanımlayıcı istatistikleri

Değişkenler	Adet	Ortalama	En küçük	Alt çeyrek	Medyan	Üst çeyrek	En büyük	Standart Sapma
Çap (inç)	113	19,71	6,00	8,00	13,23	31,64	48,00	13,92
Hat uzunluğu (km)	113	92,32	5,60	35,49	62,95	120,02	501,00	84,18
Hat vanası (adet)	113	2,83	0,00	1,00	2,00	4,00	19,00	3,37
Take-off vanası (adet)	113	1,92	0,00	1,00	1,00	2,00	16,00	2,30
Pig istasyonu (adet)	113	2,23	0,00	1,00	2,00	2,00	8,00	1,36
Güncellenmiş maliyet (milyon \$)	113	36,7	0,4	4,4	12,9	32,8	636,9	79,1

Tanımlayıcı istatistiklerin sütun başlıklarında yer alan,

- Ortalama → Gözlem değerlerinin aritmetik ortalamasını,
- En küçük → Gözlem değerleri arasında en küçük sayısal değere sahip veriyi,
- Alt çeyrek → Küçükten büyüğe doğru sıralanmış veri setinde %25'inci gözlem değerini,
- Medyan → Küçükten büyüğe doğru sıralanmış veri setinde tam ortada yer alan gözlem değerini,
- Üst çeyrek → Küçükten büyüğe doğru sıralanmış veri setinde %75'inci gözlem değerini,
- En büyük → Gözlem değerleri arasında en büyük sayısal değere sahip veriyi,
- Standart sapma → Veri değerlerinin ortalamadan ne kadar uzaklaştığını belirten istatistiksel değeri

ifade etmektedir. Çizelge 4.6'da verilen değişkenlerin tanımlayıcı istatistikleri incelendiğinde değişken değerlerindeki aralıkların oldukça geniş bir yelpazede olduğu görülmektedir. En küçük güncellenmiş maliyetli proje yaklaşık 400 000 \$ tutarında bir tamamlanma bedeline sahipken diğer yanda yaklaşık 640 M\$ maliyetli ve dev proje olarak

adlandırılabilir gözlemler de veri setinde yer almaktadır. Hat uzunluğu değişkeni de güncellenmiş maliyet değişkenine benzer şekilde oldukça geniş bir aralıkta değerler almaktadır. Bu durum farklı büyüklükteki projelerin maliyetlerine, hangi değişkenlerin ne derece etki ettiğinin tespiti noktasında faydalı çıkarımların yapılmasına zemin hazırlamaktadır. Diğer taraftan bu bilgiler üzerinde çalışılırken farklı parametre setleri de hesaplanarak DGBH projelerinin doğası hakkında farklı perspektiflerden istatistikler de ortaya çıkmıştır. Özellikle iki parametrenin DGBH projeleri hakkında fikir verebileceği öngörülmüştür. Bu parametreler şu şekildedir;

- DGBH projelerinin km başına denk gelen güncellenmiş birim maliyet bilgisi
- Proje özelinde toplam maliyet içerisinde çelik boru maliyetinin yüzdelik dilimi.


Özellikle güncellenmiş birim maliyet bilgisi bu çalışmanın bir sonraki başlığı olan veri dağılımlarının incelenmesi aşamasında üzerinde durulan parametrelerden birisidir. Çelik boru maliyetinin yüzdelik dilim bilgisi ise çapa, hat uzunluğuna ve diğer parametrelere göre projelerin işçilik ve malzeme maliyetlerinin dağılımlarının tespiti açısından önemli bir değişken olarak görünmektedir. Boru maliyet yüzdeliği bilgisi, yalnızca malzeme ve işçilik ihaleleri ayrı ayrı gerçekleştirilmiş olan ihale bilgileriyle elde edilebilmiş bir parametredir. Elbette malzeme dâhil ihalelerde de böyle bir hesaplama yapmak mümkündür. Ancak bu çalışma kapsamında malzemeli ihalelerde yüklenicilerin hangi kaleme ne kadar teklif verdiği bilgisi elde edilemediğinden belirtilen şekliyle hesaplamalar yapılmış ve güncellenmiş birim maliyet bilgileri ile birlikte Çizelge 4.7’de sunulmuştur.

Çizelge 4.7. Birim maliyet ve boru maliyet yüzdelikleri

Değişkenler	Adet	Ortalama	En küçük	Alt çeyrek	Medyan	Üst çeyrek	En büyük	Standart sapma
Güncellenmiş birim maliyet (bin \$)	113	280,8	67,9	115,1	155,6	388,6	1 271,2	263,8
Boru maliyet yüzdeliği (%)	91	47	8	36	44	57	76	14

Sunulan bilgiler ışığında veri setinin hem güncellenmiş birim maliyet hem de projelerde boru bedelinin kapladığı alan göz önünde bulundurulduğunda kapsam bakımından çok geniş bir yelpazeye yayılan gözlemleri temsil ettiği görülmektedir. Projelerin güncellenmiş birim

maliyetlerinin yaklaşık 280 000 \$ olarak hesaplandığı veri setinde, projelerin ortalama olarak yaklaşık %47 oranında çelik boru maliyeti barındırdığı görülmektedir. Veri setini oluşturan projelerin, sözleşme tarihlerine göre yıllık bazda dağılımı Şekil 4.1’de sunulmuştur.



Şekil 4.1. Projelerin yıllara göre dağılımı

2005 yılı ve sonrasında yapılmış olan DGBH proje bilgilerine EKAP üzerinden erişim sağlanabildiğinden bu tarih itibariyle çalışmaya dâhil edilmiş proje sayısı daha fazladır. Bu tarih öncesi proje bilgilerine ise TMMOB raporlarının, TBMM oturum tutanaklarının ve bu projeleri konu eden eski tarihli haber sitelerinin içerdiği bilgilerin tutarlılıkları sayesinde yer verilebilmiştir. Bu kapsamda;

- Doğubayazıt-Erzurum DGBH,
- Kayseri-Konya-Seydişehir DGBH,
- Kayseri-Ankara DGBH,
- İmranlı(Sivas)-Kayseri DGBH,
- Karacabey-İzmir DGBH,
- Erzurum-(Sivas) İmranlı DGBH,
- Samsun-Ankara DGBH,
- Mihalıççık-Eskişehir DGBH,
- Eskişehir-Bozüyük DGBH,

- Bozüyük-Adapazarı DGBH Faz-1,
- Bozüyük-Adapazarı DGBH Faz-2,
- Samsun-Çorum DGBH,
- Konya-Karaman DGBH,
- Adıyaman-Urfa-Elazığ-Diyarbakır DGBH Faz-1

olmak üzere toplamda 14 adet proje farklı kaynaklardan maliyet detaylarına erişilebildiği ve doğrulanabildiği için veri setine eklenmiştir.

Toplamda 22 adet proje bilgisi,

- Malzemeli veya malzemesiz ihale edildiğinin tespit edilememesi,
- Faz-1 ve faz-2 çalışmaları benzer özellikler gösterse de oldukça farklı km başına maliyet verisine sahip olması,
- Faz-1 ve faz-2 çalışmaları aynı çapta borularla yapılmış olmasına rağmen boru maliyetlerinin oldukça farklı değerlere sahip olması,
- Proje maliyet verisinin çeşitli kaynaklarca doğrulanamaması


gibi sebeplerle veri setinden çıkarılarak maliyet tahmini çalışmalarında ele alınmamıştır. Bu projelerin tamamı 2007 yılı ve öncesine aittir.

4.2. Veri Dağılımının İncelenmesi

Bu bölümde makine öğrenmesi algoritmaları ile maliyet tahmin sürecine başlamadan önce veri seti ile ilgili ön fikir verebilecek, ne tür bir veri topluluğuyla maliyet tahmini için model kurulmaya çalışıldığının anlaşılmasına olanak sağlayabilecek veri görselleştirmeleri sunulacaktır. Bağımsız ve bağımlı değişkenlerin yanı sıra ikili karşılaştırmaların yer aldığı grafiklere de bu bölümde yer verilecektir. Bu grafiklerin ortaya koyduğu istatistiksel çıkarımlara değinilecek ancak bulguların daha derinlemesine yorumlanma kısmı 5. bölümde yer alan tartışma ve sonuç bölümünde aktarılacaktır. Değişkenlerin birbirleri ile olan ilişkileri ve veri setinin genel yapısı hakkında değerli bilgilerin yer aldığı bu bölüm, modelleme öncesinde kritik bir ön adım niteliğindedir. Bu nedenle, çalışma içerisinde oluşturulan modelleme aşamalarının genel doğruluğunu ve güvenilirliğini destekleyici çıkarımlar bu başlık altında paylaşılmıştır.

4.2.1. Bağımsız değişkenlerin histogram grafikleri

Çalışma kapsamında kullanılan bağımsız değişkenlerin dağılımlarını görsel olarak anlamayı ve veri setinin temel özelliklerini değerlendirmeyi mümkün kılan histogram grafikleri Şekil 4.2’de verilmiştir.



Şekil 4.2. Bağımsız değişkenlerin histogram grafikleri a) Boru çapı histogram grafiği b) Hat uzunluğu histogram grafiği c) Hat vanası histogram grafiği d) Take-off vanası histogram grafiği e) Pig istasyonu histogram grafiği

Şekil 4.2’de görüleceği üzere bağımsız değişkenlerin histogram grafikleri sağa çarpık bir eğilim göstermektedir. Çarpıklık, veri setinin daha küçük değerlere eğilimli olduğunu ve veri setindeki bazı değişkenlerin standart dışı değerler içerebileceğini ortaya koymaktadır. Bu durum projelerde genel olarak standart ve daha düşük değerlere sahip parametre değerleri (küçük çaplar, kısa hat uzunlukları vb.) ile inşaat süreçlerinin ilerletildiğine ve daha büyük (daha karmaşık) DGBH projelerinin ise nadiren hayata geçirildiğine işaret etmektedir. Histogram grafikleri, veri setinde sıklıkla kullanılan özelliklerin ve nadiren gözlemlenen değerlerin ayrımını yaparak, modelleme sürecindeki öncelikli alanların belirlenmesine rehberlik etmektedir. Ayrıca, bu tür bir görselleştirme, değişkenler arasındaki olası ilişkilerin ve bağımsız değişkenlerin veri setindeki etkilerinin daha derinlemesine yorumlanmasına

zemin hazırlamakta ve modelleme sürecinin daha sağlam temellere oturmasını sağlamaktadır.

Şekil 4.2.a'da farklı boru çapı ebatlarında olan çelik boruların, DGBH projelerinde kullanılma sıklığı gösterilmiştir. Projelerde kullanılan boru çapları yüksek oranda 16 inç ve daha düşük değerlerde çapa sahip olan çelik borularla oluşturulmaktadır. 6-16 inç arasında boru çapı değerine sahip olan projeler veri setinin yarısından fazlasını oluşturmaktadır. Bu durum projelerin önemli kısmında standart çaplarda çelik boru kullanımının yoğun olduğu konusunda fikir vermektedir.

Şekil 4.2.b'de ise çalışmaya konu olan DGBH projelerinin hat uzunluğu frekansı gösterilmiştir. Görüldüğü üzere kısa hat uzunluğuna sahip proje sayısı büyük bir alanı kaplamaktadır. Özellikle 5 ila 100 km arası hat uzunluğuna sahip olan DGBH'ler, veri setinde yoğun bir şekilde yer almakta ve bu da kısa ve orta mesafeli hatların ülke genelinde daha yaygın olarak ihale edildiğine işaret etmektedir.


DGBH projelerinde hat vanası uygulama sıklığını gösteren grafik Şekil 4.2.c'de sunulmuştur. Hat vanası uygulamasının yapılmadığı DGBH projeleri de bulunmaktadır. Onun dışında en fazla 2 hat vanasının tesis edildiği proje sayısı oldukça fazla iken, 2'den fazla vana içeren projelerin sayısı oldukça azdır. Bu durum, genellikle vana sayısının minimal tutulduğu projelerin daha yaygın bir şekilde inşa edildiğini göstermektedir.

DGBH projelerinde tesis edilen take-off vanalarının dağılımı Şekil 4.2.d'de verilmiştir. Hat vanası uygulamasına benzer tanımlayıcı istatistiklere sahip olan bu histogram grafiğinde görüldüğü üzere en fazla görülen take-off vana sayısı 0 ila 2 arasında yoğunlaşmaktadır.

Şekil 4.2.e'de DGBH projelerindeki pig istasyonu sayısının dağılımı gösterilmiştir. Pig istasyonları bir atıcı ve bir alıcı kovan olacak şekilde, genellikle hattın başlangıcı ve sonuna kurulmaktadır. Bu yaklaşım, boru hatlarında pig operasyonlarının verimli bir şekilde gerçekleştirilmesine imkân tanımaktadır. Bu nedenle grafikte en fazla 2 adet pig istasyonu kurulmasının gerçekleştirildiği DGBH proje sayısının daha fazla olduğu görülmektedir.

4.2.2. Bağımlı değişken (güncellenmiş maliyet) veri görselleştirmeleri

DGBH projelerinin, bu çalışmanın hazırlandığı tarihteki alım gücüne göre hesaplanmış olan güncellenmiş maliyet bilgisinin dağılım grafiği Şekil 4.3'te sunulmuştur.




Şekil 4.3. Güncellenmiş maliyet histogram grafiği

Şekil 4.3 incelendiğinde projelerin çoğunluğunun 100 M\$ altında tamamlanma bedeline sahip olduğu görülmektedir. Bunun dışında dev proje olarak adlandırılabilir birkaç projenin de 200 M\$ üzerinde maliyet değerlerine sahip olduğu görülmektedir. Güncellenmiş maliyet grafiğinde de bağımsız değişkenlerin histogram grafiğine benzer şekilde sağa çarpık bir yapı söz konusudur. Çarpıklık, veri setinde yer alan güncellenmiş maliyet verilerinin daha küçük değerlere eğilimli olduğunu ortaya koymaktadır. Bu durum veri seti özelinde düşük maliyetli projelerin yaygın, istisnai sayılabilecek azınlıkta projenin ise yüksek maliyetli olduğu sonucunu ortaya çıkarmaktadır.

Şekil 4.3'te sunulan grafiğin geniş aralığı, projelerin toplam maliyet eğilimlerini genel olarak ortaya koymaktadır. Bununla birlikte, düşük maliyetli projelerin belirgin yoğunluğu, projelerin büyük bir kısmının ekonomik ve erişilebilir çözümlerle tamamlandığını

göstermektedir. Ancak, bu genel eğilimler, farklı maliyet kategorilerindeki projelerin yüzdesel dağılımlarını daha net anlamak için dar aralıklarla yapılan ek analizleri gerektirebilir. Bu bağlamda, projelerin toplam maliyet aralıklarına göre yüzdelik dağılımlarını göstermek amacıyla Şekil 4.4'te bir pasta grafiği sunulmuştur.



Şekil 4.4. Güncellenmiş maliyet dağılımı pasta grafiği


Şekil 4.4'te görüleceği üzere gözlemlerin;

- %28,3'ü en fazla 5 M\$,
- %19,5'i 5-10 M\$ arası,
- %36,3'ü 10-50 M\$ arası,
- %8'i 50-100 M\$ arası,
- %8'i en az 100 M\$

tamamlanma maliyetlerine sahip projelerden oluşmaktadır. Bu dağılım, projelerin büyük bir kısmının 10-50 M\$ aralığında yoğunlaştığını ve orta ölçekli DGBH projelerinin daha yaygın

olduğunu göstermektedir. Düşük maliyetli projelerin toplam projeler içinde önemli bir paya sahip olması, bu tür projelerin daha fazla erişilebilirlik ve uygulanabilirlik sunduğuna işaret etmektedir. Buna karşılık, 100 M\$ üzerindeki projelerin sınırlı sayıda olması, büyük ölçekli yatırımların daha az sıklıkla tercih edildiğini veya hayata geçirildiğini göstermektedir

Şekil 4.5'te farklı boru çapları ve farklı hat uzunluklarına sahip DGBH projeleri özelinde toplam proje maliyetinin nasıl değiştiğini gösteren bir kabarcık grafiği sunulmuştur.




Şekil 4.5. Farklı çap ve hat uzunluklarına göre güncellenmiş maliyet değişimi

Projelerde boru çapı ve hat uzunluğu arttıkça beklentiye paralel olacak şekilde maliyetlerde de bir artış eğilimi olduğu Şekil 4.5'te açıkça görülmektedir. Özellikle boru çapı değerinin 30 inçten büyük olduğu projelerde bu gözlem standartlaşmış da denebilir. Ancak 200 km altında hat uzunluğuna sahip projelerde benzer bir standartlaşma durumundan söz edilemez. Burada maliyetler farklılaşabilmektedir. Bu da projelerin kendi doğaları gereği alınan mühendislik kararlarının proje bedelini etkileyebileceği konusunda bir ön fikir vermektedir.

4.2.3. Hat uzunluğuna göre boru çapı değişimi

Bu bölümde boru çapı ile hat uzunluğu arasındaki ilişki irdelenmiştir. Farklı hat uzunluklarına sahip DGBH projelerinde kullanılan boru çaplarının dağılımı, bu iki parametre arasındaki çeşitliliği anlamak açısından önemli bir veri sunmaktadır. Bu ilişkilerin görselleştirildiği grafik Şekil 4.6’da paylaşılmıştır.




Şekil 4.6. Hat uzunluğuna göre boru çapı dağılımı

Şekil 4.6’da görüleceği üzere kısa hat uzunluğuna sahip projelerde küçük boru çapı değerleri daha yoğun olarak görülse de bunu bir genelleme olarak sunmak doğru değildir. Boru hattı uzunluğu 100 km’den az olan ancak boru çapı 48 inç olan DGBH projeleri görülmekle birlikte 200 km’den büyük hat uzunluğuna sahip olup boru çapı 14 inçten küçük olan projeler de göze çarpmaktadır. Bu bulgu, DGBH projelerinin belirli bir altyapı standardına bağlı kalmadan, ihtiyaca özel olarak şekillendirilebildiği noktasında bir temel oluşturmaktadır. Aynı zamanda boru çapı ve hat uzunluğundaki bu çeşitlilik, projelerin tasarımında hem ekonomik hem de teknik gerekliliklerin önemli bir rol oynadığını ortaya koymaktadır. Proje gereksinimlerine göre şekillenen bu farklılıklar, boru hatlarının işlevselliği ve maliyet optimizasyonu açısından dikkate alınması gereken bir durumdur. Bu analizler, DGBH

projelerinde mühendislik kararlarının genel standartlara bağıllık zorunluluğu olmadan, projeye özgü koşullara göre alınabildiği sonucunu desteklemektedir.

4.2.4. Güncellenmiş birim maliyet veri görselleştirmeleri


Bu bölümde projede önemli bir parametre olduğu düşünülen ve hem yüklenici hem de işveren tarafından nakit akışını organize etmek üzere kullanılması muhtemel olan güncellenmiş birim maliyet verisi ve buna bağlı olarak projelerin nasıl şekillendiği grafiklerle sunulmuştur. İlk olarak veri setinin tamamında güncellenmiş birim maliyet verisini gösteren histogram grafiği Şekil 4.7’de verilmiştir.



Şekil 4.7. Güncellenmiş birim maliyet histogram grafiği

Projelerin ağırlıklı olarak km başına 250 000 \$ maliyete sahip olduğu görülmektedir. Bunun yanında km başına maliyeti 1 M\$ ve üzerinde olan projeler de veri setinde yer almaktadır. Güncellenmiş birim maliyet grafiği, bu bölüme kadar sunulmuş olan ve model aşamalarında bağımsız/bağımlı değişken olarak kullanılacak olan parametrelerin grafiklerine benzer şekilde sağa çarpık bir görsel sunmaktadır. Bu çarpıklık DGBH inşaatlarında ortaya çıkan birim maliyet verilerinin daha küçük değerlere meyilli olduğu sonucunu ortaya koymaktadır.

Şekil 4.7’de yer alan grafik, projelerde birim maliyetlerin nasıl bir dağılım sergilediğini genel hatlarıyla ortaya koymaktadır. Bununla birlikte, düşük birim maliyetli projelerin yoğunluğu, projelerin çoğunun ekonomik çözümlerle hayata geçirildiğine işaret etmektedir. Bununla birlikte, farklı maliyet kategorilerindeki projelerin daha ayrıntılı bir şekilde analiz edilebilmesi adına dar aralıklar üzerinden oluşturulacak olan ek görsellerin faydalı olacağı açıktır. Bu doğrultuda, projelerin güncellenmiş birim maliyet aralıklarına göre yüzdesel dağılımını daha net şekilde yansıtmak amacıyla Şekil 4.8’de bir pasta grafiği sunulmuştur.



Şekil 4.8. Güncellenmiş birim maliyet dağılımı grafiği


Pasta grafiği projelerin güncellenmiş birim maliyet aralıklarına göre dağılımını daha anlaşılır bir biçimde sunmaktadır. Şekil 4.8’deki grafikten de görüleceği üzere gözlemlerin,

- %18,6’sı en fazla 100 000 \$/km,
- %41,6’sı 100 000 - 200 000 \$/km arası,
- %15,9’u 200 000 - 400 000 \$/km arası,
- %13,3’ü 400 000 - 600 000 \$/km arası,
- %6,2’si 600 000 \$ - 1 M\$/km arası

- %4,4'ü en az 1 M\$/km

güncellenmiş birim maliyetlerine sahip projelerden oluşmaktadır.

Projelerde güncellenmiş birim maliyetlerin hat uzunluğuna göre nasıl değiştiğini gösteren grafik Şekil 4.9'da verilmiştir. Bu grafik hat uzunluklarına göre ortaya çıkabilecek güncellenmiş birim maliyet verisi için önemli bir kaynak oluşturmaktadır.




Şekil 4.9. Hat uzunluklarına göre güncellenmiş birim maliyet grafiği

Şekil 4.9 incelendiğinde projelerin yaklaşık %39,8'ini oluşturan ve en fazla 50 km hat uzunluğuna sahip projelerin yaklaşık olarak 180 000\$ güncellenmiş birim maliyete sahip olduğu sonucu ortaya çıkmaktadır. 50 - 100 km arasında hat uzunluğuna sahip projeler için bu değer yaklaşık 340 000 \$ iken, 100 - 200 km arasında hat uzunluğuna sahip projelerde ise yaklaşık 240 000 \$ düzeylerinde bir güncellenmiş birim maliyet verisi ortaya çıkmaktadır. Benzer çıkarımların daha büyük hat uzunluğuna sahip olan projeler içinde yapılması mümkündür, ancak 200 km üzerinde hat uzunluğuna sahip projeler için örneklem sayısının düşük kaldığı görülmektedir. Bu projeler, tüm veri seti içerisinde kendilerine %10'luk bir pay bulamamışlardır. Bu durum, özellikle kısa ve orta hat uzunluklu projelerde, maliyetin belirli bir aralıkta sabitlenmiş olabileceğine işaret etmektedir. Yine de grafikten

hat uzunluđu arttıkça gncellenmiř birim maliyet verisinin artıř gsterdiđi sonucu ıkarılabilir. 200 km zerindeki projelerde gzlenen veri eksikliđinin gelecekteki alıřmalar iin nemli bir arařtırma alanı sunduđu da ayrıca deđerlendirilmektedir.

řekil 4.10'da farklı ebatlarda boru aplarına sahip olan, bunun yanında farklı hat uzunlukları boyunca inřa edilen DGBH'lerin km bařına gncellenmiř maliyetini gsteren kabarcık grafiđi sunulmuřtur.



řekil 4.10. Farklı ap ve hat uzunluklarına gre gncellenmiř birim maliyet deđiřimi

řekil 4.10 incelendiđinde, hattı oluřturan boruların apı bydke ve hat uzunluđu arttıka gncellenmiř birim maliyetin artma eđiliminde olduđu aık bir řekilde grlmektedir. Ancak boru hattı uzunluđuına karřılık gelen boru apı grafiđinde yapılan yoruma benzer řekilde, bu durumun standartlařma dzeyinde olmadıđını belirtmek gerekir. Benzer aplara sahip ancak farklı hat uzunluklarına sahip projelerde, hat uzunluđu daha byk olan projenin gncellenmiř birim maliyet deđerinin daha yukarıda olması beklentisi yksek olsa da, grafik ierisinde bu durumu dođrulamayan rnekleri de grmek mmkndr. Aynı durum benzer hat uzunluklarına sahip olan ancak farklı ebatlarda boru apı ile inřa edilen DGBH

projelerinin güncellenmiş birim maliyet verisi için de geçerlidir. Sonuç olarak literatüre benzerlik gösterecek şekilde çap ve hat uzunluğu bilgilerinin maliyet ile ilişkili parametreler üzerinde etkisinin olduğu görülmektedir. Bu durum, maliyet tahmini öncesinde bu parametrelerin model kurma sürecinde ön plana çıkabileceği noktasında fikir vermektedir. Bu bölüme kadar sunulan grafikler ve çizelgeler, veri setinin temel özelliklerini ve projeler arasındaki maliyet farklılıkların daha iyi anlaşılmasını sağlamak amacıyla sunulmuştur. Bu bilgiler, maliyet tahmin modellerinin geliştirilmesi ve projelerin yapısal farklılıklarının maliyet üzerindeki etkilerini daha derinlemesine analiz etmek için bir temel oluşturacaktır.

4.3. Yöntem

Bu çalışmada DGBH'lerin proje bilgilerinden faydalanılarak, makine öğrenmesi algoritmaları kullanılarak proje maliyetlerinin, henüz detaylı analizler ortada yok iken tahmin edilmesine imkân verecek düzeyde bir model oluşturulması amaçlanmıştır. Bu kapsamda doğrusal, doğrusal olmayan ve ağaç tabanlı yöntemler kullanılarak 5 farklı makine öğrenmesi algoritması denenmiştir. Bu algoritmalar Çizelge 4.8'de verilmiştir.

Çizelge 4.8. Çalışma kapsamında kullanılan algoritmalar

Doğrusal algoritmalar	Çoklu Doğrusal Regresyon (ÇDR)
	ElasticNet Regresyonu (ER)
Doğrusal olmayan algoritmalar	K-En Yakın Komşu Regresyonu (KNN - K-Nearest Neighbors Regression)
Ağaç tabanlı algoritmalar	Rastgele Ormanlar (RF - Random Forests)
	XGBoost (XGB - Extreme Gradient Boosting)

Kullanılan algoritmalar ortaya çıkabilecek doğrusal ve doğrusal olmayan ilişkilerin yanı sıra ağaç tabanlı yöntemlerin de başarı düzeyini görebilmek amacıyla tercih edilmiştir. Model sonuçlarının başarı düzeylerini ölçmek amacıyla,

- Belirleme katsayısı (R^2),
- Hataların ortalama karekökü (RMSE-Root Mean Square Error),
- Ortalama mutlak hata (MAE-Mean Absolute Error),
- Ortalama mutlak yüzdesel hata (MAPE- Mean Absolute Percentage Error)

gibi dört farklı model başarı parametresi hesaplanmıştır. Modellerin performansı, eğitim ve test setleri için hiperparametre ayarlama işlemi (tune etmek) öncesi ve sonrasında değerlendirilmiştir. Başarı metriklerinin tamamı aynı değişkenlerle hesaplandığından değerlendirme aşamasında ağırlıklı olarak R^2 ve RMSE değerleri tercih edilmiştir.

4.3.1. Model Başarı Parametreleri

Belirleme katsayısı (R^2)

R^2 , bir tahmin modelinde yer alan bağımsız değişken(ler)in bağımlı değişkeni ne kadar iyi açıkladığını gösteren istatistiksel bir ölçüttür. 1'e yakın değerler, modelin daha iyi performans gösterdiğini, 0'a yakın değerler ise modelin zayıf olduğunu ifade etmektedir [50]. Bu katsayı, modelin genel doğruluğunu, bağımlı değişkenin varyansının ne düzeyde açıklanabildiğini anlamak için önemli bir metriktir. R^2 formülü Eş. 4.8'de gösterilmiştir.

$$R^2 = 1 - \frac{SS_{residual}}{SS_{total}} = 1 - \frac{\sum_{i=1}^n (y_i - \widehat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (4.8)$$

Hataların ortalama karekökü (RMSE)

RMSE değeri, model aşamasında elde edilen tahmin değerleri ile olması gereken gerçek değerler arasındaki farkların, karelerinin, toplamalarının, ortalamasının, karekökü olarak hesaplanan bir başarı metriğidir. R^2 değerinin aksine RMSE hesaplamalarında mümkün olan en düşük değerlere erişmek hedeflenmektedir. Model başarı göstergesi olarak sık sık başvuru metriklerden birisidir [51]. RMSE formülü Eş. 4.9'da gösterilmiştir.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \widehat{y}_i)^2} \quad (4.9)$$

Ortalama mutlak hata (MAE)

MAE, modelin tahmin ettiği değerler ile gerçek değerler arasındaki farkların, mutlak değerlerinin toplamının ortalaması olarak hesaplanmaktadır. MAE değeri de, RMSE değeri

gibi ne kadar düşük bir değere sahipse model o derece başarılıdır. MAE formülü Eş. 4.10'da verilmiştir.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (4.10)$$

Ortalama mutlak yüzdesel hata (MAPE)

MAPE, tahmin değerleri ile gerçek değerler arasındaki mutlak farkın, gerçek gözlem değerine oranlanması ile hesaplanan bir başarı metriğidir. Yüzdesel olarak ifade edilen MAPE modelin ortalama yüzde kaç hata ile tahmin yaptığı bilgisini sunmaktadır. MAPE formülü Eş. 4.11'de verilmiştir.

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100 \quad (4.11)$$

Yukarıda verilen formüllerde;

- y_i , bağımlı değişkenin gerçek değerini,
- $\hat{y}_i$, model sonucunda ortaya çıkan tahmin değerini,
- $\bar{y}$, gerçek değerlerin ortalamasını,
- n , toplam veri sayısını göstermektedir.

4.3.2. Kullanılan algoritmalar

Çoklu doğrusal regresyon (ÇDR)

ÇDR, birden fazla bağımsız değişkenin bir bağımlı değişken ile doğrusal ilişki içerisinde olduğunu varsayan bir regresyon çeşididir. Bu yöntem bağımsız değişkenlerin bağımlı değişken üzerindeki etkilerini tahmin etmek için kullanılır [52]. Bu modelin formülü Eş. 4.12'de gösterilmiştir.

$$y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n + \epsilon \quad (4.12)$$

Denklemden;

- y , modelin tahmin etmeye çalıştığı değişkendir. Bağımlı değişken veya hedef değişkeni olarak isimlendirilebilir.
- β_0 , modelin sabit terimidir.
- $\beta_1, \beta_2, \dots, \beta_n$ bağımsız değişkenlerin, bağımlı değişken üzerindeki etkisini gösteren katsayılarıdır.
- ϵ hata terimidir ve modelde yer alan, açıklanamayan rastgele hata bilgisini taşır.

ElasticNet regresyonu (ER)

ER, iki farklı regresyon yöntemi olan Lasso regresyonu ve Ridge regresyonu yöntemlerinin avantajlarını bir araya getiren bir regresyon yöntemidir. ElasticNet, Lasso'nun değişken seçme yeteneğini ve Ridge'in çoklu doğrusal bağlantıyı çözen gücünü bir arada sunar. Özellikle yüksek boyutlu veri setlerinde, çok sayıda bağımsız değişken olduğunda kullanışlıdır [53]. ER'nin temel formülü Eş. 4.13'te gösterilmiştir.

$$\min_{\beta} \left(\sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j X_{ij} \right)^2 + \lambda_1 \sum_{j=1}^p |\beta_j| + \lambda_2 \sum_{j=1}^p \beta_j^2 \right) \quad (4.13)$$

Bu denklemde;

- $\lambda_1 \sum_{j=1}^p |\beta_j|$, katsayıların mutlak değerlerinin toplamı, değişken seçimini sağlar. Katsayıların bazılarını sıfıra indirir (Lasso).
- $\lambda_2 \sum_{j=1}^p \beta_j^2$, katsayıların karelerinin toplamı ile ceza uygular ve katsayıların küçültülmesini sağlar (Ridge).
- Diğer parametreler önceki bölümlerde tanımlanmıştır.

K-En yakın komşu (KNN-K-Nearest neighbors)

KNN, doğrusal olmayan makine öğrenmesi algoritmalarından birisidir. Sınıflandırma ve regresyon problemlerinde sıkça başvurulan yöntemlerden birisi olan KNN, tahmin

aşamasında yeni verinin belirli bir yakınlık düzeyindeki benzerliğine dayanarak çalışır [54]. Yeni bir değer ile yapılacak tahmin için Eş. 4.14'te yer alan denklem kullanılır.

$$\hat{y} = \frac{1}{k} \sum_{i=1}^k y_i \quad (4.14)$$

Bu denklemde;

- y_i , k adet en yakın komşunun gerçek değerlerini temsil etmektedir.
- k , seçilen komşu sayısıdır.

KNN yönteminde en yakın komşu kavramı önemlidir. Küçük k değerleri modeli hassaslaştırırken, büyük k değerleri daha genel tahminler ortaya koyar. Genellikle en yakın komşular öklidyen mesafe formülü kullanılarak hesaplanmaktadır. Bu çalışma kapsamında öklidyen mesafesi kullanılmış ve mesafe hesabını gerçekleştiren denklem Eş. 4.15'te verilmiştir.

$$\text{Öklidyen Mesafesi} = \sqrt{\sum_{i=1}^n (x_i - x_j)^2} \quad (4.15)$$

Rastgele ormanlar (RF - Random forests)

RF, birden fazla karar ağacını bir araya getirerek daha güçlü bir model oluşturmayı amaçlayan bir topluluk yöntemidir [55]. RF algoritması, her bir ağacın eğitiminde rastgele bir özellik alt kümesi kullanır. Temelde, bir veri kümesi üzerinde rastgele örnekler alarak farklı karar ağaçları oluşturur ve bu ağaçların ortalaması alınarak son tahmin elde edilir. RF'nin tahmin denklemi Eş. 4.16'da paylaşılmıştır.

$$\hat{y} = \frac{1}{T} \sum_{t=1}^T f_t(x) \quad (4.16)$$

Bu denklemde;

- T ormanda bulunan toplam ağaç sayısını,
- $f_t(x)$ her bir karar ağacının tahmin fonksiyonunu

ifade etmektedir. RF, aynı zamanda değişkenler arasındaki doğrusal olmayan ilişkileri iyi öğrenme yeteneği ve aşırı öğrenmeye karşı dayanıklılığı ile de bilinmektedir. Ağaçların bağımsız olarak eğitilmesi, modelin genelleme kapasitesini artırmaktadır.

XGBoost (XGB-extreme gradient boosting)

XGB, sınıflandırma ve regresyon problemleri için kullanılan, karar ağaçlarına dayalı güçlü bir makine öğrenmesi algoritmasıdır. XGB, ardışık olarak birden fazla ağaç oluşturarak hataları minimize etmeye çalışır. Her yeni ağaç, önceki ağaçların yaptığı hataları öğrenerek modelin doğruluğunu artırmayı hedefler. Bu süreç, modelin iteratif olarak iyileştirilmesi prensibine dayanır. XGB algoritmasının en önemli özelliklerinden biri, düzenlemeler (regularization) uygulayarak modelin aşırı öğrenmeye karşı dirençli hale gelmesini sağlamasıdır. Bu düzenlemeler, L1 (Lasso) ve L2 (Ridge) olmak üzere iki farklı biçimde uygulanır. L1 düzenlemesi, bazı gereksiz ağaç dallarını sıfıra indirip modelin daha sade olmasını sağlarken, L2 düzenlemesi ağaçların karmaşıklığını kontrol ederek modelin genelleme yeteneğini artırır. Bir diğer önemli özellik ise kayıp fonksiyonudur. XGB, tahmin edilen değer ile gerçek değer arasındaki farkı minimize eden bir kayıp fonksiyonu kullanır. Bu kayıp fonksiyonuna, ağaçların karmaşıklığını kontrol eden ceza terimleri eklenir. Kayıp fonksiyonu denklemi Eş. 4.17’de sunulmuştur.

$$L(\theta) = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k) \quad (4.17)$$

Bu denklemde:

- $L(\theta)$, toplam hedef fonksiyonu,
- $l(y_i, \hat{y}_i)$, tahmin edilen değer ile gerçek değer arasındaki kayıp fonksiyonu,
- $\Omega(f_k)$, her bir ağacın karmaşıklığını düzenleyen ceza terimi ifadesini

temsil etmektedir. XGB hız ve bellek kullanımı açısından oldukça verimli bir yöntemdir [56]. Paralel hesaplama yeteneđi, hızlı sonuçlar alınmasını sağlar. Bu özellikleri sayesinde XGBoost, modern makine öğrenmesi problemlerinde en çok tercih edilen algoritmalarından birisi hâline gelmiştir.

5. BULGULAR VE TARTIŞMA

Bu çalışmada, Türkiye Cumhuriyeti sınırları içerisinde inşa edilmiş 113 adet farklı DGBH projelerine ait veriler irdelenmiştir. Maliyeti etkileyen parametreler değerlendirilerek çeşitli çıkarımlarda bulunulmuştur. Daha sonra 4. bölümde verilmiş olan 5 farklı makine öğrenmesi algoritması yardımıyla, proje maliyetlerinin ön tahminini yapabilmeye imkân sağlayacak modeller geliştirilmiştir. Grafikler, tanımlayıcı istatistikler, model algoritmaları vb. tüm işlemler Python programlama dili kullanılarak gerçekleştirilmiştir. Python, açık kaynak kodlu ve mühendislik dâhil birçok farklı alanda geniş kullanım alanına sahip olması nedeniyle tercih edilmiştir [57].


Veri analizi, makine öğrenmesi ve veri görselleştirmesi işlemleri için sıkça tercih edilen Python; NumPy, Pandas ve Scikit-Learn gibi güçlü kütüphaneleri ile bilimsel çalışmaların veri işleme ve model geliştirme süreçlerinde temel bir araç haline gelmiştir [58]. Bu kütüphaneler yardımıyla veri görselleştirme ve model geliştirme işlemleri yapılmıştır. Çalışmanın bu bölümü iki aşamada ele alınmıştır. İlk bölümde, veri setinin karakteri ve ortaya çıkardığı bulgular üzerinden değerlendirmeler yapılmış, ardından 5 farklı makine öğrenmesi algoritması aracılığıyla ön maliyet tahmini yapmaya yönelik model geliştirme süreci ilerletilmiş ve adım adım aktarılmıştır. Son olarak geliştirilmiş tüm modellerin performans karşılaştırmaları yapılmış ve bu çalışmanın 4. bölümünde tariflenmiş olan başarı metrikleri üzerinden değerlendirmelere yer verilmiştir.

5.1. İstatistiksel Çıkarımlar

Bu bölümde, veri setine dayalı istatistiksel çıkarımlar ve görselleştirmeler sunulmuştur. Projeler için düzenlenen ihale türlerinin yıllara göre dağılımı, bu türlerin projelerin toplam maliyetleri üzerindeki etkileriyle birlikte ele alınmıştır. Bunun yanı sıra, çelik boru maliyetlerinin projelerdeki toplam maliyet içindeki oranı detaylı bir şekilde incelenmiştir. Çelik boruların kullanımının maliyet üzerindeki belirleyici rolü, hem mühendislik kararlarının maliyete yansması hem de ekonomik verimlilik açısından önemli çıkarımlara temel oluşturmuştur. Bu analizler, projelerin ekonomik yapısını anlamak ve maliyet tahmin modelleri geliştirmek için sağlam bir temel oluşturmak amacıyla ele alınmıştır.

5.1.1. İhale türü

DGBH projeleri 4. bölümde bahsedildiği gibi malzemeli ve malzemesiz olmak üzere iki farklı yöntemle ihale edilebilmektedir. İhale türlerine göre ihalelerin yıllara göre dağılımı Şekil 5.1’de verilmiştir.



Şekil 5.1. İhale türlerinin yıllara göre dağılım grafiği

Şekil 5.1’deki grafik incelendiğinde veri setinde ihalesi malzemeli olarak gerçekleştirilen yalnızca 22 adet DGBH verisinin bulunduğu görülmektedir. Bu da tüm veri setinin yaklaşık %20’sinin, çelik boru alımı ve yapım işinin birlikte ihale edilerek gerçekleştirildiğini göstermektedir. İhalesi malzemeli olarak gerçekleştirilmiş bu 22 adet DGBH projesinin 13 tanesi ise, bu çalışmanın giriş bölümünde yer verildiği şekliyle ikincil kaynaklar aracılığıyla değişken değerlerine ulaşılabilen ve tamamı 2002 yılı öncesi başlangıç tarihli çalışmalardır. Bu tarihten sonra ise günümüze kadar araştırma kapsamında erişilebilen 100 farklı DGBH ihale bilgisinden yalnızca 9 adet DGBH projesinin malzemeli bir şekilde ihale edildiği görülmektedir. 2009 - 2018 yılları arasında ise yalnızca 1 adet DGBH projesi malzemeli şekilde ihale edilmiştir. Bu proje haricinde malzemeli bir şekilde gerçekleştirilmiş DGBH ihalesi ile ilgili herhangi bir veriye ulaşılamamıştır.

2002 yılı öncesi yapımına başlanan projelerin tanımlayıcı istatistikleri Çizelge 5.1’de sunulmuştur.


Çizelge 5.1. 2002 yılı öncesi DGBH projelerinin tanımlayıcı istatistikleri

Değişkenler	Adet	Ortalama	En küçük	Alt çeyrek	Medyan	Üst çeyrek	En büyük	Standart sapma
Çap (inç)	13,0	36,89	6,00	36,00	40,00	48,00	48,00	12,16
Hat uzunluğu (km)	13,0	204,33	31,00	75,00	239,55	306,22	501,00	143,54
Hat vanası (adet)	13,0	8,23	1,00	2,00	9,00	10,00	19,00	5,85
Take-off vanası (adet)	13,0	3,31	0,00	2,00	2,00	4,00	16,00	4,09
Pig İstasyonu (adet)	13,0	2,08	0,00	1,00	2,00	2,00	5,00	1,44
Güncellenmiş maliyet (milyon \$)	13,0	162,72	5,47	24,94	114,17	228,95	636,85	181,74
Güncellenmiş birim maliyet (bin \$)	13,0	608,21	176,56	380,22	487,56	894,32	1 271,16	352,25

Çizelge 5.1’de sunulan tabloda görülebileceği gibi projelerin güncellenmiş tamamlanma ve güncellenmiş birim maliyetleri yüksek standart sapma değerlerine sahiptir. Bu 13 projede, bağımlı/bağımsız değişken olarak kullanılan tüm parametrelerin en büyük değerleri, tüm veri setinin en büyük değerleri ile örtüşmektedir. Bu durum veri setinde yer alan bağımlı ve bağımsız değişkenlerin en büyük değerlerine ulaştığı projelerin, bu 13 proje içerisinde olduğu sonucunu ortaya çıkarmaktadır. Kalan istatistiki metriklerin tamamında ise pig istasyonu değişkeni dışında 2002 yılı öncesinde malzemeli olarak ihale edilmiş projelerin gözlem değerleri, tüm veri setine kıyaslandığında önde görünmektedir. Örneğin tüm veri setinde ortalama hat uzunluğu 92,32 km iken, 2002 yılı öncesinde yapılmış bu 13 projenin ortalama hat uzunluğu 204,3 km’dir. Benzer gözlemler diğer değişkenler ve diğer metrikler için de rahatlıkla yapılabilir. Bu durum, bu 13 projenin gerçek anlamda kapsamlı ve yüksek hacimli projeler olduğunu göstermektedir. Dolayısıyla maliyet değerlerinin yüksek olması bağımsız değişken olarak düşünülen parametrelerin maliyete etkisi noktasında bir ön fikir vermektedir. Bu aşamada bu değişkenler ile tamamlanma maliyeti ve birim maliyet parametreleri arasında pozitif bir korelasyon olabileceği değerlendirilebilir. Çizelge 5.1’deki istatistiklerin ortaya koyduğu potansiyel çıkarımlardan biri de, bu projelerin

şebekenin ana besleyici hatları konumunda olduğunu göstermektedir. Bu projeler çalışma kapsamında verilerine erişilebilen en eski projeler olduğu için süreçler başlangıç seviyesinde bir bakış açısıyla yürütülmüş gibi değerlendirilmektedir. Bu projelerin sonucunda ortaya çıkan maliyet verilerinin, malzeme ve işçilik ihalelerinin ayrı ayrı yapıldığı projelerin maliyetleri ile kıyaslandığında, daha uygun maliyetlerin ortaya çıkması sonucunun görülmesine vesile olduğu düşünülmektedir. Doğu Karadeniz DGBH için yürütülen adli süreç sonrasında bu bulguyu destekleyen bir kararın ortaya çıktığı da görülmektedir [59].

Şekil 5.2’de malzemeli ve malzemesiz ihalelerde ortaya çıkan güncellenmiş birim maliyetlerin grafiği gösterilmektedir.




Şekil 5.2. Boru hattı özelliklerine göre projelerin güncellenmiş ortalama birim maliyetleri

Malzemeli ihale edilmiş DGBH sayısının az olmasından dolayı geliştirilmiş çıkarımlar sunmak mümkün değildir. Dolayısıyla yapılan çıkarımların bu kısıt altında değerlendirilmesi gerekmektedir. Büyük hat uzunluğu ve büyük çaplı çelik borularla yapılan, malzemeli şekilde ihale edilmiş DGBH projelerinin, malzemesiz ihale edilmiş DGBH projelerine göre km başına yaklaşık 300 000 \$ daha maliyetli olduğu görülmektedir. Bu noktada işverenin bu tip büyük projelerde malzeme ve yapım işçiliğini ayrı ayrı ihale etme uygulamasının oldukça yerinde bir karar olduğu değerlendirilebilir. Bu durumda bir devlet kurumunun yüksek çaplı

çelik boru ihalesi gerçekleştirdiğinde, daha geniş bir üretici yelpazesine erişiminin bulunduğu, dolayısıyla ihale sürecinde gerekli rekabet ortamının oluştuğu sonucu çıkarılabilir. Hat uzunluğu 50-100 km aralığında olan ve boru çapı 20 inçten büyük projelerde ise ihalenin malzemeli olmasının daha uygun maliyetlere tekabül ettiği görülmektedir. Kalan projelerde malzemeli ve malzemesiz ihale süreçlerinin projelerin km başına maliyetlerinde önemli değişiklikler oluşturmadığı açıktır. İlave verilerle geliştirilebilir olan bu çıkarım kapsamında, işveren paydaşının, daha az evrak yükü ve insan gücü ile DGBH ihalelerinin bir kısmını yürütebileceği düşünülmektedir.

5.1.2. Çelik boru maliyeti oranı


Bu bölümde DGBH projelerinde hat boyunca yerleştirilen çelik boruların maliyeti üzerinden genel çıkarımlar ortaya konulmuştur. BOTAŞ tarafından ayrı bir şekilde gerçekleştirilen çelik boru alım ihalelerinde ortaya çıkan maliyetin, toplam proje maliyetine oranlanması ile elde edilen değer, çelik boru maliyet oranı olarak değerlendirilmiştir. Bu maliyetin DGBH projelerinin karakteristik özellikleri ile olan etkileşimi aşağıda verilmiştir. Bu kapsamda öncelikle çelik boru maliyet yüzdesinin boru çapı ile olan etkileşimi irdelenmiştir. Şekil 5.3'te çapa göre çelik boru maliyetinin yüzdeliğini gösteren dağılım grafiği sunulmuştur.



Şekil 5.3. Çapa göre çelik boru maliyet yüzdesi dağılımı

Şekil 5.3'ten görüleceği üzere projelerin büyük kısmının toplam maliyetlerinin %30 - 60 arasında yer alan bölümünü çelik boru maliyetleri oluşturmaktadır. Çap ebatları arasında ciddi farklar olmasına rağmen aynı yüzdelik dilim değerine erişen projeler dikkat çekmektedir. Dikkat çeken diğer bir bulgu ise 6 ve 48 inç haricinde boru çapına sahip bütün proje kümelerinde %50 - 60 arasında çelik boru maliyeti içeren projelerin yer almasıdır. Bu tespit, projeyi oluşturan boruların toplam maliyet içerisindeki yüzdesinin, çap bilgisiyle net bir uyumunun olmadığı sonucunu ortaya çıkarmaktadır. Öte yandan projede kullanılacak çelik boru çapının 30 inç ve üzerinde olduğu çoğu senaryoda çelik boru maliyetinin proje maliyetinin yarısından fazlasını kapladığı açık bir şekilde görülmektedir. Bu noktada proje için gerekli olan boru çapı 30 inç ve üzeri olduğunda, boru üretimi için gerekli olan çelik miktarı, lojistik süreci ve bölgesel faktörler gibi sebeplerle maliyet artışının ortaya çıktığı değerlendirilmiştir. İşçilik için gerekli olan maliyet kaleminin de arttığı ancak çelik boru temininde yaşanan artıştan daha düşük seviyede kalmasından dolayı çelik boru maliyet yüzdesinin yukarı yönlü olduğu belirlenmiştir.

Çelik boru maliyet yüzdesinin hat uzunluğu ile olan etkileşimini görselleştirmek amacıyla, farklı hat uzunluklarına göre çelik boru maliyet yüzdesindeki dağılımı gösteren grafik Şekil 5.4'te paylaşılmıştır.



Şekil 5.4. Hat uzunluğuna göre çelik boru maliyet yüzdesi dağılımı

Şekil 5.4'teki dağılım incelendiğinde boru hattının değişimiyle birlikte çelik boru maliyet yüzdelik dilimlerinde belirgin bir artış veya azalış gözlemlenmemektedir. Yani benzer hat uzunluklarına sahip projelerde çelik boru malzemesinin maliyetinin kaplayacağı alanın değişkenliği oldukça fazladır. Grafikten yapılabilecek en kayda değer çıkarım, 150 km ve üzerinde hat uzunluklarına sahip projelerin tamamında çelik boru maliyet oranının yaklaşık %35'in altına düşmemesidir. Dolayısıyla bu hat uzunluklarına sahip projelerde proje toplam maliyetinin en az 1/3'ünü çelik boru maliyetini oluşturduğu söylenebilir.

DGBH projelerinde, çelik boru temini için ayrılacak olan bütçenin hat uzunluğundan bağımsız değerlendirilmesi gerektiği ancak boru çapıyla kısmen ilişkili olabileceği değerlendirilmiştir. Çelik boru veya yapım işi ihalelerine katılan üreticiler ve yüklenici adayları için bu çıkarımın, teklif sürecinde yol gösterici olacağı düşünülmektedir.

5.2. Makine Öğrenmesi Algoritmalarının Uygulanması ve Maliyet Tahmini Sonuçları


DGBH projelerinin maliyet tahminlerini gerçekleştirmek amacıyla geliştirilen makine öğrenmesi algoritmalarının uygulama süreci bu bölümde ele alınmıştır. Bölümün amacı, farklı algoritmaların maliyet tahmin performansını analiz ederek proje yönetimi ve karar verme süreçlerine sağlayabileceği potansiyel katkıları ortaya koymaktır. Bu bağlamda algoritmaların nasıl çalıştığı, kod yapıları, parametre ayarları ve elde edilen başarı metrikleri sunulmuş ve çeşitli karşılaştırmalar yapılmıştır.

5.2.1. Modelleme öncesi veri hazırlık süreçleri

Makine öğrenmesi modellerini geliştirme adımı, verilerin eğitim ve test verisi olarak ayrılması, modelin performansını değerlendirebilmek için gerekli olan kritik bir adımdır. Bu ayırma işlemi yapılarak eğitim seti olarak ayrılmış veri kümesi ile modelin öğrenme süreci ilerletilir. Öğrenme aşamasının sonunda model oluşur ve ardından daha önce hiç karşılaşmamış olduğu test verileri ile model çalıştırılarak modelin başarı kapasitesi ölçülür. Bu yaklaşımla modelin yalnızca eğitim verileri ile değil gerçek dünya verileri ile kararlı sonuçlar üretebilmesi sağlanmaya çalışılır.

Bu çalışmada kullanılan veri seti, toplamda 113 adet gözlem, 5 bağımsız ve 1 bağımlı değişken içermektedir. Gözlem sayısının makine öğrenmesi süreçlerinde kullanılan büyük

veri setlerine kıyasla nispeten az olması, modelin performansını etkileyebilecek önemli bir faktördür. Bu nedenle tüm gözlemlerin modele dâhil edilmesinin uygun olacağı değerlendirilmiştir. Bağımsız değişken olarak kullanılacak olan parametreler de sınırlı sayıda olduğundan, hepsini model içerisinde tutmanın doğru bir yaklaşım olacağı düşünülmüştür. Bu kararın desteklenmesinde önemli bir rol oynayan korelasyon matrisi Şekil 5.5'te sunulmuştur.



Şekil 5.5. Tüm değişkenlerin korelasyon matrisi

Korelasyon matrisi oluşturularak bağımsız değişkenlerin birbirleriyle ve bağımlı değişken olan güncellenmiş maliyet ile pozitif veya negatif yönde mevcut olan potansiyel ilişkileri incelenmiştir. Şekil 5.5'teki tablo incelendiğinde bağımsız değişkenlerin tamamının hedef değişken ile pozitif bir korelasyona sahip olduğu görülmektedir. Take-off vana sayısı ve pig istasyonu sayısı değişkenlerinin güncellenmiş maliyet değeri ile korelasyonları zayıftır ancak pozitif yöndedir. Hat vanası ve hat uzunluğu değişkenleri arasında yüksek korelasyon bulunmaktadır. Bu durum değişkenler arasında çoklu bağlantı riski barındırdığı için dikkatle yaklaşılmalıdır [60].

Tüm değişkenlerin, model kodlarında ve doğrusal model denklemlerinde (ÇDR ve ER) nasıl isimlendirildiğini ve kısaltıldığını gösteren tablo Çizelge 5.2’de sunulmuştur.

Çizelge 5.2. Modelde kullanılan değişken isimlendirmeleri ve metin içerisinde kısaltmaları

Değişkenler	Model kodlarında kullanılan isim	Model denklemlerinde ve grafiklerde kısaltılmış kullanım
Boru çapı	diameter	D
Hat uzunluğu	length	L
Hat vanası sayısı	line_valve	LV
Take-off vanası sayısı	take_off_valve	TOV
Pig istasyonu sayısı	pigging_station	PS
Güncellenmiş maliyet	adj_cost	C

Model başarı metriklerini hesaplama fonksiyonu

Model oluşturma adımına geçilmeden önce 4. bölümde bahsedilmiş olan başarı metriklerinin hesaplanmasına yönelik bir fonksiyon yazılmıştır. Fonksiyonu meydana getiren kod parçası Resim 5.1’de gösterilmiştir.

```
#Gerekli kütüphanelerin içeri aktarılması
import pandas as pd
import numpy as np
from sklearn.metrics import mean_squared_error, mean_absolute_error, mean_absolute_percentage_error
from sklearn.metrics import r2_score

# Performans metriklerini hesaplama fonksiyonu
def calculate_metrics(y_true, y_pred):
    r2 = r2_score(y_true, y_pred)
    rmse = mean_squared_error(y_true, y_pred, squared=False)
    mae = mean_absolute_error(y_true, y_pred)
    mape = mean_absolute_percentage_error(y_true, y_pred) * 100
    return r2, rmse, mae, mape
```

Resim 5.1. Model başarı metriklerini hesaplama fonksiyonu

Resim 5.1’de gösterilen kod parçasığı ile “calculate_metrics” isimli bir fonksiyon oluşturulmuştur. Bu fonksiyonda; “y_true” gözlemlerin gerçek değerlerini “y_pred” ise modelin tahmin ettiği değerleri temsil etmektedir. Bu fonksiyon sayesinde “calculate_metrics” isimli fonksiyona gerçek ve tahmin edilen hedef değişkenleri gönderildiğinde “return” komutu aracılığıyla R², RMSE, MAE ve MAPE değerleri sonuç olarak dönmektedir.

Değişkenlerin tanımlanması, veri setinin eğitim ve test setleri olarak ayrılması

Bu aşamada modelleme sürecinde kullanılacak olan bağımsız ve bağımlı değişkenler tanımlanmıştır. Ardından modelin doğruluğunu ölçebilmek ve performansını değerlendirebilmek amacıyla veri seti %80 eğitim, %20 test verisi olarak ayrılmıştır. Toplam 113 verinin 90 tanesi model eğitimi için kullanılmış, 23 tanesi ise modelin gerçek dünya örnekleriyle ortaya çıkan başarısını ölçebilmek için test verisi olarak değerlendirilmiştir. Bu aşamaların gerçekleşmesini sağlayan kod parçası Resim 5.2’de gösterilmiştir.

```
#Gerekli kütüphanelerin içeri aktarılması
import pandas as pd
from sklearn.model_selection import train_test_split

# Veri dosyasını yükle
file_path = "G:\\Drive'ım\\*****\\*****\\*****\\*****\\ngpc_final2.xlsx"
df = pd.read_excel(file_path,
                  sheet_name = "final")

# Bağımsız değişkenleri belirle
independent_variables = ['diameter',
                        'length',
                        'line_valve',
                        'take_off_valve',
                        'pigging_station']

X = df[independent_variables]
y = df['adj_cost']

# Eğitim ve test setlerinin bölünmesi
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
```

Resim 5.2. Veri seti model hazırlık işlemleri

Resim 5.2’de gösterilmiş olan Python kodu oluşturulurken Pandas ve Scikit-Learn kütüphanelerinden yararlanılmıştır. Pandas’ın dosya okuma araçlarından birisi olan “read_excel” alt fonksiyonu kullanılmıştır. Bu fonksiyon excel dosyasındaki veriyi okur ve “dataframe” (veri çerçevesi) formatında döndürür. Bu alt fonksiyon içine, dosya yolu ve dosya yolunda yer alan excel dokümanı içerisindeki verilerin bulunduğu sayfa bilgisi, “sheet_name” parametresi ile verilir.

Bu çalışmada verilerle ilgili tüm hazırlık süreçleri “ngpc_final2.xlsx” isimli excel dokümanında gerçekleştirilmiştir. Model geliştirme süreçleri için düzenlenmiş olan veri seti ise bu dokümanın “final” isimli sayfasında yer almaktadır. Bu nedenle “sheet_name” alt fonksiyonuna sayfa ismi olan “final” karakterleri girilmiştir. Okunan veriler ise “df” olarak adlandırılmıştır.


Veri setinin yer aldığı excel sayfasında değişken isimleri üst başlık olarak ve ingilizce karşılıkları ile yer almaktadır. Kodlama sırasında bağımsız değişkenler *“independet_variables”* ismiyle tanımlanmıştır. Sonrasında ise *“df”* isimli *“dataframe”* içerisinde *“independent_variables”* listesinin içinde yer alan değişkenler bağımsız değişkenler olarak *“X”* değişkenine atanmıştır. Benzer şekilde, bağımlı değişken olan *“adj_cost”* parametresi de *“y”* değişkenine aktarılmıştır. Böylece model geliştirme adımları için gerekli olan bağımlı/bağımsız değişken atama işlemleri tamamlanmıştır.

Son aşamada ise verileri %80 eğitim ve %20 test verisi olarak ayırmak üzere Scikit-Learn kütüphanesinin *“train_test_split”* alt fonksiyonu kullanılmıştır. Kod parçasının bu kısmında;

- *“X_train”*, eğitim verisi olarak ayrılan veri seti bölümünde bağımsız değişkenleri,
- *“X_test”*, test verisi olarak ayrılan veri seti bölümünde bağımsız değişkenleri,
- *“y_train”*, eğitim seti olarak ayrılan veri seti bölümünde güncellenmiş maliyet değerini,
- *“y_test”*, test seti olarak ayrılan veri seti bölümünde güncellenmiş maliyet değerini

temsil etmektedir. Alt fonksiyon içerisinde yer alan *“test_size”* parametresi, veri setinin yüzde kaçının test için kullanılacağı bilgisini girdi olarak almaktadır. Çalışma kapsamında *“test_size”* parametresi 0,2 değerini (%20) almıştır.

Kod içerisinde yer alan bir diğer parametre ise *“random_state”* parametresidir. Bu parametre veri setinin eğitim ve test setlerine ayrılması sırasında tekrarlanabilirliği sağlamak amacıyla kullanılmaktadır. Bu parametreye atanan *“42”* değerinin ise özel bir anlamı yoktur. Çalışma sırasında incelenen kaynaklarda bu parametreye ağırlıklı olarak *“42”* değerinin verildiği görülmüştür. Bu parametre belirli bir değer aldığı anda, modelin her bir tekrar çalıştırılma sürecinde veri aynı şekilde bölünür, yani aynı 100 birim örneklemin, aynı 80 birimi eğitim ve aynı 20 birimi test verisi olarak ayrılır. Bu durum model sonuçlarının tutarlılığını sağlamakla birlikte farklı algoritmalar kullanıldığında eğitim ve test veri setinin değişmemesini sağlayarak model performanslarının başarılı bir şekilde karşılaştırılabilmesine olanak sağlar. Kod satırının başında *“#”* işareti olan satırlar ise not amaçlı yazılmış olup, bu işaretle başlayan kod satırları metin olarak algılandığından kod yapısını değiştirmemektedir. Süreci özetleyen şematik gösterim Şekil 5.6’da verilmiştir.



Şekil 5.6. Model kurma süreci ön hazırlık

5.3. Çoklu Doğrusal Regresyon (ÇDR) Tahmin Modeli

Bu çalışmada, DGBH projelerinin erken maliyet tahminine yönelik olarak ilk aşamada ÇDR analizi gerçekleştirilmiştir. İnşaat sektöründe maliyet tahmini amacıyla en sık başvuru alan yöntemlerden biri olan ÇDR, değişkenler ile maliyet arasındaki doğrusal ilişkileri belirlemeye yönelik bir tekniktir ve bu çalışmada gelişmiş modellerin temelini oluşturmak amacıyla ilk uygulanan makine öğrenmesi algoritmasıdır. ÇDR'nin ilk model olarak tercih edilmesinin temel nedeni basit yapısı ve sonuçların yorumlanabilirliğidir. Aynı zamanda veri seti ve elde edilen bulguların etkin bir biçimde değerlendirilmesine de olanak tanır.

5.3.1. ÇDR modelinin oluşturulması

ÇDR modelinin Jupyter notebook ortamında oluşturulmuş olan Python kodu Resim 5.3'te gösterilmiştir.

```
#Gerekli kütüphanelerin içeri aktarılması
import pandas as pd
from sklearn.linear_model import LinearRegression

# Çoklu doğrusal regresyon modelinin kurulması
linear_regression = LinearRegression()
linear_regression.fit(X_train, y_train)

# Tahmin yapılması
y_train_pred = linear_regression.predict(X_train)
y_test_pred = linear_regression.predict(X_test)

# Model başarı metriklerinin hesaplanması
r2_train, rmse_train, mae_train, mape_train = calculate_metrics(y_train, y_train_pred)
r2_test, rmse_test, mae_test, mape_test = calculate_metrics(y_test, y_test_pred)
```

Resim 5.3. ÇDR model nesnesi oluşturulması ve başarı metriklerinin hesaplanması

Resim 5.3'te kod parçası verilen ÇDR algoritmasının modelleme aşaması için Scikit-Learn kütüphanesinin “*LinearRegression*” sınıfı kullanılmıştır. Bu sınıf ÇDR modeli oluşturmak ve bağımlı değişken ile bir veya daha fazla bağımsız değişken arasındaki doğrusal ilişkiyi modellemek amacıyla kullanılır. Kod içerisinde yer alan ve “_train” ifadesi ile biten başarı parametreleri, eğitim seti ile geliştirilmiş olan modelin tahmin başarısını ölçen başarı parametreleridir. Kod içerisinde yer alan ve “_test” ifadesi ile bitenler ise modelin daha önce karşılaşmamış olduğu gözlemlerle test edilmesi sonucunda elde edilen performans ölçümlerini ifade eder.

5.3.2. ÇDR modeli sonuçları

ÇDR analizi sonucunda ortaya çıkan denklemin katsayılarını elde etmek ve modelin doğrusal yapısını incelemek üzere yazılan kod ve bu kodun çalıştırılmasıyla programın sunduğu çıktı Resim 5.4’te gösterilmiştir.

```
# Model denklemini yazdırma

# Model kesişim noktası
model_intercept = linear_regression.intercept_

# Model katsayıları
model_coefficients = linear_regression.coef_

# Sonuçların yazdırılması
model_intercept, model_coefficients

(-35884924.738334954,
 array([ 1043647.84144788,   396209.50152143, 11725703.73665858,
        -8885125.31565939, -130442.06738131]))
```

Resim 5.4. ÇDR model denklemi kodu ve cevap satırı

ÇDR modeli sonucunda elde edilen ve bu çalışma kapsamında DGBH proje maliyetlerinin ön tahmini ve analiz edilmesi amacıyla geliştirilmiş olan ilk model denklemi Eş. 5.1’de sunulmuştur.


$$C_{\text{ÇDR}} = -35\,884\,924,74 + 1\,043\,647,84 \times D + 396\,209,50 \times L + 11\,725\,703,74 \times LV - 8\,885\,125,32 \times \text{TOV} - 130\,442,07 \times \text{PS} \quad (5.1)$$

Elde edilen model denklemi, DGBH projelerinin tamamlanma maliyetini denklemden yer verilen değişkenler aracılığıyla tahmin etmeye yönelik bir araç sunmaktadır. Bu denklemin sabit terimi ve her bir değişkenin katsayıları, ilgili değişkenlerin maliyet üzerindeki etkisini göstermektedir. Değişken katsayıları, 5.2.1 bölümünün “Değişkenlerin tanımlanması ve veri setinin eğitim ve test setleri olarak ayrılması” başlığı altında bulunan Resim 5.2’de tanımlandığı sıra ile atanmıştır.

Eş. 5.1’de gösterilen denkleme göre pig istasyonu sayısı değişkeni en düşük, hat vanası sayısı değişkeni ise en büyük değişken katsayısı değerlerine sahip parametrelerdir. Bu durumda denkleme göre projelerin tamamlanma maliyetleri üzerinde en önemli değişken hat vanası sayısı olarak görünmektedir. Ancak bu değerlendirmeyi yaparken Şekil 5.5’te

gösterilen korelasyon matrisinde, hat vanası ile hat uzunluğu arasındaki yüksek korelasyonu göz ardı etmemek gerekir. Bu yüksek korelasyon sebebiyle model tarafından bu iki değişkenin maliyete olan etkileri ayrı ayrı süzilemiyor olabilir.

Bu aşamada modelin hiç karşılaşmadığı değişken değerleri ile nasıl bir performans gösterdiği, yani maliyet tahmini için ortaya çıkan model başarısının düzeyini görebilmek için 23 adet projeden oluşan test veri seti ile hesaplamalar yapılmıştır. Yapılan hesaplamalar sonucunda ortaya çıkan ve DGBH projelerinin gerçek maliyetleri ile ÇDR modeli tarafından tahmin edilen maliyet değerlerinin karşılaştırılmasına olanak veren grafik Şekil 5.7’de sunulmuştur. Toplamda 23 adet projeye 0’dan başlamak üzere 22 sayısına kadar kodlar atanmıştır. Dolayısıyla grafik yorumlarında, 0 numaralı proje ve/veya 12’nci proje vb. şekilde kodlamalar ile atıfta bulunulmuştur.




Şekil 5.7. ÇDR modeli gerçek ve tahmin edilen güncellenmiş maliyetlerin karşılaştırılması

Şekil 5.7’deki grafik, test veri setinde yer alan gerçek maliyet değerleri ile modelin tahmin ettiği maliyetleri kıyaslamaktadır. Grafikte büyük ölçüde, tahmin edilen maliyet grafiği çizgisinin (turuncu-kesikli), gerçek maliyet değeri çizgisini (mavi-düz) takip ettiği görülmektedir. Bu iki grafiğin ilgisiz rotalar seyretmedikleri açıktır. Bu durum aslında

modelin projeye özgü olan maliyet değişkenliklerini iyi bir kararlılık düzeyinde takip ettiğini ortaya koymaktadır. Bununla birlikte bazı örneklerde belirgin tahmin sapmaları gerçekleştiği de dikkat çekmektedir. Özellikle 1, 15 ve 22 numaralı projelerde tahmin edilen güncellenmiş maliyet ve gerçek güncellenmiş maliyet değerleri arasında ciddi farklılıklar ortaya çıktığı açık bir şekilde görülmektedir. Bu yöndeki bulgular, modelin yüksek maliyetli projelerde daha fazla hata yapma eğiliminde olduğuna işaret etmektedir.

Modelin tahmin hatalarının daha ayrıntılı bir şekilde gösterilmesi amacıyla oluşturulan kalıntı grafiği (residual plot) Şekil 5.8’de sunulmuştur.



Şekil 5.8. ÇDR modelinde tahmin edilen maliyet ve hatalar

Şekil 5.8’de sunulan grafikte X eksenini modelin ürettiği maliyet tahminlerini, Y eksenini ise tahmin edilen maliyet ile gerçek maliyet değeri arasındaki farkı temsil etmektedir. Görüldüğü üzere düşük maliyetli projelerde tahmin hataları 0 eksenini etrafında toplanmaktadır. Özellikle bir proje haricindeki büyük maliyetli projelerde modelin daha da büyük değerlerde maliyet tahmini yaptığı görülmektedir. Ayrıca bazı projelerde denklemin yapısından kaynaklı olarak negatif tahmin değerleri de ortaya çıkmıştır. Bu durum modelin başarısını aşağıya çeken örnekler olarak öne çıkmaktadır.

ÇDR modeli geliştirme sürecinde ortaya çıkan bulgular doğrultusunda model hakkında ön fikir edinilirken, model başarı metriklerinin incelenmesi ile model başarısı hakkında daha kapsayıcı bir çıkarım yapılabilir. Model sonucunda elde edilen başarı metriklerinin aldığı değerler Çizelge 5.3'te sunulmuştur.

Çizelge 5.3. ÇDR model başarı metrikleri

Başarı parametresi	Sonuç
R^2 (eğitim)	0,75
RMSE (eğitim)	40 091 313,32
MAE (eğitim)	24 707 889,55
MAPE (eğitim)	373,39
R^2 (test)	0,61
RMSE (test)	43 370 642,30
MAE (test)	30 486 681,79
MAPE (test)	335,94

Sonuçlar ÇDR modelinin DGBH projelerinin ön maliyet tahminlerinde nasıl bir performans gösterdiğini anlamak açısından önemlidir. Eğitim setindeki $R^2 = 0,75$ değeri, modelin bağımlı değişken üzerindeki değişkenliği %75 oranında açıklayabildiğini göstermektedir. Bu sonuç, modelin veri seti özelinde açıklayıcılık gücünün ve maliyet tahmini performansının iyi olduğu sonucunu ortaya çıkarmaktadır.

Test veri seti ile elde edilen ve modelin tahmin başarısının derecelendirilmesi için önemli bir metrik olan R^2 değeri 0,61 değerini almıştır. Bu değer, modelin hiç karşılaşmadığı verilerle yaptığı tahmin performansının, eğitim seti ile oluşan modelin doğru tahmin yapma kapasitesine göre düştüğünü göstermektedir. Ancak modelin hâlâ kabul edilebilir bir tahmin performansı gösterdiği söylenebilir. Test veri seti ile eğitim veri seti arasında oluşan bu farklılık modelin aşırı uyum (overfitting) problemi yaşadığına işaret edebilir. Aşırı uyum algoritmanın veri seti üzerinden öğrenme aşamalarını ilerletip, yalnızca öğrendiği veriler üzerinden oldukça başarılı tahminler ortaya koymasındır [61].

R^2 değeri üzerinden değerlendirme yapıldığında, aradaki farklılığın yalnızca küçük bir aşırı uyum işaretçisi olduğunu söylemek mümkündür. İlerleyen bölümlerde kurgulanan doğrusal olmayan ve ağaç tabanlı modeller, aşırı uyum sorunuyla kendi içsel algoritmaları düzeyinde

mücadele etmekte ve bu sayede aşırı uyumdan kaçınılmış daha genellenebilir sonuçlar üretebilmektedir.

Model hata oranlarını incelemek amacıyla kullanılan metriklerden olan RMSE değeri modelin hassasiyeti hakkında bir miktar daha fikir vermektedir. Bu metrik eğitim seti için yaklaşık 40,1 M\$ olarak hesaplanmış, test seti için ise yaklaşık 43,4 M\$ seviyelerinde değer almıştır. RMSE'nin eğitim setine kıyasla test setinde artış göstermesi, modelin gerçek maliyet ile tahmin edilen maliyet arasındaki farklarının test verisinde biraz daha yüksek olduğunu, dolayısıyla tahmin sapmalarının arttığını göstermektedir. Bu durum, genellikle modelin genellenebilirliğini artırmak için daha fazla gözleme ihtiyaç duyulduğuna veya veri seti üzerinde farklı düzenlemeler gerektiğine işaret etmektedir.

MAE açısından da sonuçlar değerlendirildiğinde RMSE ile benzerlik gösterecek şekilde iyi bir sonucun ortaya çıkmadığı açıktır.

MAPE değerlerine bakıldığında ise %370 ve %330 seviyelerinde tahmin hataları görülmektedir. Bu başarı metriğinin bu derece yüksek olması modelin özellikle büyük projeler veya maliyet farklılıklarının büyük olduğu durumlarda ciddi tahmin sapmalarına neden olabileceğini göstermektedir.

Bu bulgular neticesinde, maliyet ortalamasının yaklaşık 36,7 M\$ ve en büyük maliyetli projenin yaklaşık 636,9 M\$ olduğu bir veri setinde ÇDR modelinin maliyet tahminlerinde kısmi bir başarı sağladığı söylenebilir. Ancak R^2 haricindeki diğer başarı metriklerinde görülen görece yüksek hatalar modelin gelişime açık olduğuna işaret etmektedir. Özellikle bazı projelerdeki yüksek tahmin hatalarının çoklu bağlantı (multicollinearity) sebebiyle ortaya çıktığı değerlendirilebilir. Bu tür durumlarda ER gibi değişken katsayıları ile mücadele eden bir doğrusal regresyon modeli denemesi, değişkenler arasındaki yüksek korelasyon sorununun oluşturacağı hasarı azaltacaktır. Ayrıca KNN gibi doğrusal olmayan bir model bu tarz problemlere duyarlı olmadığından daha doğru tahmin performansları elde edebilmek amacıyla denenmiştir. Ayrıca RF ve XGB gibi ağaç tabanlı algoritmaların bu noktada fayda sağlayacağı değerlendirilmektedir. İlerleyen aşamalarda, bu gelişmiş algoritmalarla model performansının iyileştirilmesi amaçlanmıştır.

5.4. ElasticNet Regresyon (ER) Tahmin Modeli

ER, Lasso Regresyonu (LR) ve Ridge Regresyonlarının (RR) avantajlarını bünyesinde barındıran etkili bir doğrusal regresyon yöntemidir. Bu yöntem değişkenler arasındaki yüksek korelasyon problemiyle etkin bir şekilde başa çıkar. Önceki bölümde üzerinde durulan ÇDR modelinde, değişkenler üzerinde herhangi bir düzenleme uygulanmadığından, çoklu bağlantı problemleri, ortaya çıkan model denkleminin tahmin başarısını ciddi oranda etkileyebilmektedir. LR ve RR ise değişkenler üzerinde oluşturmaya çalıştıkları farklı etkilerle bu problemi aşarak daha kararlı modeller oluşturabilmektedirler.

LR (L1 normu) değişken seçimi yapmaya meyilli bir katsayı belirleme yaklaşımına sahiptir. Bu durum hedef değişken üzerindeki etki düzeylerine göre bağımsız değişkenlere katsayı ataması şeklinde yapılır. LR modelinde bazı değişkenlerin katsayıları tamamen 0'a inerse bu durumda o değişkenin hedef değişken üzerinde etkisi olmadığı sonucu ortaya çıkar ve modelde değişken seçimi yapılmış olur. LR'nin matematiksel formülü Eş. 5.2'de sunulmuştur.

$$\min_{\beta} \left(\sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j X_{ij} \right)^2 + \lambda_1 \sum_{j=1}^p |\beta_j| \right) \quad (5.2)$$

Eş. 5.2'de verilen denklemde λ_1 ceza parametresi olarak değişkenlerin seçimini sağlar. Katsayılar sıfıra indirilebilir ve böylece yalnızca hedef değişken üzerinde anlamlı olanlar modele dâhil edilir.

RR ise (L2 normu) katsayıların kareleri toplamına ceza terimi ekleyerek modeldeki hiçbir değişkeni tamamen sıfırlamaz, ancak katsayıları küçülterek çoklu bağlantı problemini çözmeye çalışır. Bu yaklaşım, modelin aşırı uyum problemine karşı dayanıklı olmasını sağlar [62]. RR'nin matematiksel formülü Eş. 5.3'te verilmiştir.

$$\min_{\beta} \left(\sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j X_{ij} \right)^2 + \lambda_2 \sum_{j=1}^p \beta_j^2 \right) \quad (5.3)$$

Eş. 5.3'te verilen denklemde λ_2 , katsayıların büyüklüğüne ceza uygulayarak aşırı uyumu engeller. Hiçbir değişken modelden çıkarılmasa da tüm değişkenlerin katsayıları küçültülerek modelin genelleme başarısı artırılır.

Bu bölümde modeli oluşturulan ER ise LR'nin değişken seçimi ve RR'nin değişken katsayılarını küçültme özelliğini birleştiren bileşik bir doğrusal regresyon yöntemi olarak değerlendirilebilir. L1 ve L2 ceza terimlerini bir arada kullanarak, modeldeki gereksiz değişkenleri dışlarken aynı zamanda değişkenler arasındaki korelasyonu da kontrol altında tutar. Bu sayede, model hem basit hem de kararlı hâle gelir.

5.4.1. ER modelinin oluşturulması

Bu bölümde ER modelinin oluşturulma süreci açıklanmıştır. ÇDR yönteminden farklı olarak bu aşamadan sonra oluşturulan modeller, hiperparametre ayarlaması (model tuning) işlemine tâbi tutulmuşlardır. Model başarı parametreleri, hiperparametre ayarlama öncesi ve sonrası olarak iki farklı aşamada sunulmuştur. Ancak, sonuçlar tartışılırken ağırlıklı olarak hiperparametre ayarlama işlemi sonrasında elde edilen test seti tahmin başarıları dikkate alınmıştır. Bu noktada, özellikle hiperparametre ayarlama işlemi sonrası elde edilen R^2 ve RMSE değerleri, modelin tahmin performansının değerlendirilmesinde temel ölçüt olarak kullanılmıştır.

ER modelinin Jupyter Notebook ortamında Python dili kullanılarak yazılan kodu Resim 5.5'te gösterilmiştir.

```
# Gerekli kütüphanelerin içeri aktarılması
from sklearn.linear_model import ElasticNet

# ElasticNet modelinin kurulması (Tune Öncesi)
elasticnet = ElasticNet()
elasticnet.fit(X_train, y_train)

# Tune öncesi tahmin yapılması
y_train_pred_BT = elasticnet.predict(X_train)
y_test_pred_BT = elasticnet.predict(X_test)

# Tune öncesi model başarı metriklerinin hesaplanması (BT: Before Tuning)
r2_train_BT, rmse_train_BT, mae_train_BT, mape_train_BT = calculate_metrics(y_train, y_train_pred_BT)
r2_test_BT, rmse_test_BT, mae_test_BT, mape_test_BT = calculate_metrics(y_test, y_test_pred_BT)
```

Resim 5.5. ER model nesnesi oluşturulması ve hiperparametre ayarlama işlemi öncesi başarı metriklerinin hesaplanması

ER modeli, bağımlı değişken ile bir veya daha fazla bağımsız değişken arasındaki doğrusal ilişkiyi modellemek amacıyla Scikit-Learn kütüphanesinin ElasticNet sınıfı kullanılarak geliştirilmiştir. Kod parçacığı içerisinde yer alan ve “*_train_BT*” ifadesi ile biten başarı parametreleri (“*r2_train_BT*”, “*rmse_train_BT*”, vd.) eğitim seti ile geliştirilmiş olan modelin hiperparametre ayarlama işlemi (tune) öncesinde elde edilen ve modelin tahmin başarısını gösteren metriklerdir. “*_test_BT*” ifadesi ile bitenler ise modelde herhangi bir hiperparametre ayarlama işlemi gerçekleştirilmeden modelin daha önce karşılaşmamış olduğu gözlemlerle test edilmesi sonucunda elde edilen performans ölçümlerini göstermektedir. “*BT*” ifadesi İngilizce “before tuning” kelime grubunun baş harflerini temsil etmektedir. Hiperparametre ayarlama işlemi öncesi hesaplanan tahmin performansı başarı metrikleri Çizelge 5.4’te gösterilmiştir.

Çizelge 5.4. ER model başarı metrikleri (hiperparametre ayarlama işlemi öncesi)

Başarı parametresi	Sonuç
R ² (eğitim)	0,75
RMSE (eğitim)	40 357 198,26
MAE (eğitim)	24 695 554,81
MAPE (eğitim)	386,39
R ² (test)	0,68
RMSE (test)	39 140 127,36
MAE (test)	27 910 032,49
MAPE (test)	327,96

Hiperparametre ayarlama işlemi öncesinde model performansının hesaplanması, modelin geliştirilmesi adına önemli bir referans noktası sağlar. Modelin performansını iyileştirmeye çalışmadan önce mevcut durumunun bilinmesi, hiperparametre ayarlama işlemi sonrasında gelişim seviyesinin ölçümlenebilmesi adına önemlidir.

5.4.2. ER için hiperparametre ayarlaması ve GridSearchCV kullanımı

ER ile beraber çalışmanın bu bölümünden sonra oluşturulan tüm modeller için hiperparametre ayarlama işlemi yapılmıştır. Hiperparametreler, modelin daha iyi sonuçlar vermesi için optimize edilmesi gereken sabit değerlerdir [63]. Her modelin kendi algoritmasına özgü bu tarz sabit değerleri bulunmaktadır. ER modelinin performansını

etkileyen ve bu algoritma ile gerçekleştirilen makine öğrenmesi uygulamalarında yaygın olarak hiperparametre ayarlaması için tercih edilen parametreler “*alpha*” ve “*l1_ratio*” değerleridir.

“*alpha*” hiperparametresi ER modelinin ceza terimi ağırlığını belirler. “*l1_ratio*” parametresi ise modelde LR ve RR modeline özgü normların ağırlıklarını belirler. Bu değer 0’a ne kadar yakınsa model o denli RR modeline, tersi durumda ise LR modeline yakın çıktılar üretir. Eğer “*alpha*” 0’a eşit olursa, model üzerinde herhangi bir düzenleme uygulanmaz, bu durumda model klasik ÇDR gibi çalışır.

GridSearchCV, hiperparametre ayarlaması sürecinde, kullanıcı tarafından belirlenen hiperparametre kombinasyonları arasından en uygun olanını bulmaya yarayan bir Scikit-Learn sınıfıdır. Bu sınıf, her bir hiperparametre kombinasyonunu çapraz doğrulama yöntemiyle değerlendirir ve en yüksek performansı sağlayan kombinasyonu seçer [64]. ER modelinde, GridSearchCV kullanılarak hiperparametre ayarlama işlemi için gerekli olan Python kodu Resim 5.6’da gösterilmiştir.

```
# Gerekli kütüphanelerin içeri aktarılması
from sklearn.model_selection import GridSearchCV

# ElasticNet Parametre Gridleri
elasticnet_params = {
    'alpha': [0.01, 0.1, 1, 10, 100, 1000],
    'l1_ratio': [0.1, 0.5, 0.7, 0.9]
}

# GridSearchCV ile ElasticNet modeli için en iyi hiperparametrelerin bulunması
elasticnet_grid = GridSearchCV(ElasticNet(), elasticnet_params, cv=5, scoring='r2')
elasticnet_grid.fit(X_train, y_train)


# En iyi parametreleri içeren tahminci için model nesnesi oluşturulması
best_elasticnet = elasticnet_grid.best_estimator_

# Modelin eğitilmesi
best_elasticnet.fit(X_train, y_train)
```

Resim 5.6. ER modelinde GridSearchCV kullanımı

Makine öğrenmesi uygulamalarında GridSearchCV kullanımları incelendiğinde, 10 katlı çapraz doğrulama uygulaması yaygın bir şekilde görülmektedir. Bu çalışma kapsamında ise veri setinde yer alan gözlem sayısının, makine öğrenmesi uygulamalarında kullanılan veri seti büyüklüklerine kıyasla az sayıda olmasından dolayı çapraz doğrulama sürecinin 5 katlı olarak ilerletilmesi planlanmıştır. Resim 5.6’da paylaşılan kod yapısında GridSearchCV sınıfı, 5 katlı çapraz doğrulama yöntemi kullanarak her bir hiperparametre kombinasyonu

için modelin tahmin performansını değerlendirir. Çapraz doğrulama, eğitim veri setini belirli sayıda alt kümeye ayırarak (bu çalışma kapsamında 5 alt küme), her bir alt kümeyi sırayla test seti olarak kullanır ve kalan verilerle modeli eğitir. Bu işlem sonucunda, her iterasyonda modelin başarısı hesaplanarak, ortalama performans belirlenir [65]. Bu süreci özetleyen görsel Şekil 5.9’da sunulmuştur.



Şekil 5.9. Beş katlı çapraz doğrulama

Çapraz doğrulama, veri setini belirlenen sayıda parçaya ayırarak, her bir parçayı sırasıyla test seti olarak kullanır ve kalan kısmı eğitim seti olarak değerlendirir. Veri seti 5 parçaya ayrıldığından her iterasyonda eğitim setini oluşturan verilerin farklı bir 1/5’lik (%20) kısmı test seti olarak kullanılarak model eğitilir ve performans sonuçları elde edilir. Böylece model farklı test verileri ile genellenebilirlik anlamında daha iyi bir performans gösterir. “cv”, İngilizce cross-validation kelime grubunun baş harflerinin birleşiminden oluşmaktadır.

Çapraz doğrulama işlemi, veri setini belirtilen sayıda parçaya ayırır ve her bir ayrılmış senaryoda modelin performansını ölçer. Bu şekilde aşırı uyum problemini de mümkün olduğunca minimize eder. “scoring” parametresi ise “r2” değerini alarak modelin R² değerine göre optimize edilmesini sağlar. “.best_estimator_” özelliği kullanılarak, yukarıda bahsedilen ölçütlere uygun olacak şekilde tüm hiperparametreler arasından en iyi R² değerini

verecek olan kombinasyon tespit edilir. “*best_estimator_*” özelliği kendi içerisinde en iyi hiperparametre kombinasyonunu barındırarak model oluşturma sürecinin ilerlemesini sağlar. Bu kombinasyonun hangi değerleri aldığı görülmek istenirse, “*best_params_*” özelliği kullanılabilir. ER modeli için hiperparametre ayarlama işlemi sonucunda ortaya çıkan en iyi hiperparametre kombinasyonunu görmek için kullanılan Python kodu ve bu kodun çalıştırılmasıyla ortaya çıkan sonuç, Resim 5.7’de sunulmuştur.

```
elasticnet_grid.best_params_  
{‘alpha’: 100, ‘l1_ratio’: 0.7}
```

Resim 5.7. ER modeli için en iyi hiperparametre çağırma kodu ve cevap satırı

Mevcut veri seti ve önerilen hiperparametre seçenekleri için kod çalıştırıldığında en iyi hiperparametre kombinasyonu “*alpha*” =100 ve “*l1_ratio*” = 0,7 olarak hesaplanmıştır.

5.4.3. ER modeli sonuçları

ER modeli, önceki bölümde GridSearchCV sınıfı kullanılarak belirlenen en uygun hiperparametre kombinasyonları ile eğitilmiştir. Eğitim süreci tamamlandıktan sonra, modelin tahmin performansını değerlendirebilmek için test verileri üzerinde uygulanmaya hazır hâle getirilmiştir. Eğitim veri seti ile eğitilmiş olan modelin, değişken katsayıları ve sabit terimi arka planda oluşmuş, böylece ER model denklemi elde edilmiştir. ER modeli sonucunda ortaya çıkan denklemin katsayılarını elde etmek ve modelin doğrusal yapısını incelemek üzere yazılan kod ve bu kodun çalıştırılmasıyla programın sunduğu çıktı Resim 5.8’de gösterilmiştir.


```
# Model denklemini yazdırma  
  
# Model kesişim noktası  
model_intercept = best_elasticnet.intercept_  
  
# Model katsayıları  
model_coefficients = best_elasticnet.coef_  
  
# Sonuçların yazdırılması  
model_intercept, model_coefficients  
  
(-51206793.22934407,  
 array([1426723.74409889,  640966.15906449,  428285.43361937,  
        -634589.30289256, -225207.27882209]))
```

Resim 5.8. ER model denklemi kodu ve cevap satırı

ER modeli sonucunda elde edilen ve bu çalışma kapsamında DGBH proje maliyetlerinin ön tahmini ve analiz edilmesi amacıyla geliştirilmiş olan ikinci modelin denklemi Eş. 5.4'te sunulmuştur.

$$C_{ER} = -51\,206\,793,23 + 1\,426\,723,74 \times D + 640\,966,16 \times L + 428\,285,43 \times LV - 634\,589,30 \times TOV - 225\,207,28 \times PS \quad (5.4)$$


Eş. 5.4'te gösterilen denklem, modelin, L1 ve L2 normlarını birleştirerek başta hat vanası değişkeni olmak üzere belirli değişkenlerin katsayılarını baskıladığını, diğerlerini ise maliyet üzerinde önemli bir etkiye sahip olacak şekilde optimize ettiğini göstermektedir. Denkleme göre boru çapı değişkeni kat sayısı en yüksek değere sahiptir. ER modelinin karakteristiğine uygun olacak şekilde model denkleminde katsayıların ÇDR'ye göre oldukça farklı değerler aldığı görülmektedir. Bu durum model oluşturma ve çapraz doğrulama ile hiperparametre ayarlaması yapılması süreçlerinde çoklu bağlantı ile mücadele edildiğini ve değişken katsayılarının LR ve RR mantığında cezalandırıldıklarını göstermektedir. Hiperparametre ayarlama işlemi sonrasında ER modeli tarafından tahmin edilen maliyet değerleri ile DGBH projelerinin gerçek maliyetlerinin karşılaştırıldığı grafik Şekil 5.10'da sunulmuştur.



Şekil 5.10. ER modeli gerçek ve tahmin edilen maliyetlerin karşılaştırılması

ER modelinin tahmin performansı genel olarak incelendiğinde, bazı projelerde modelin maliyet tahminlerinde oldukça tutarlı sonuçlar verdiği görülmektedir. Ancak, bazı projelerde tahmin edilen değerlerle gerçek maliyetler arasında sapmalar oluşmuştur. Bu projeler, modelin genelleme yeteneğinin test edildiği zorlu alanlar olarak değerlendirilebilir. Modelin belirli projelerde daha kararlı tahmin performansı sergileyebildiği, bazı projelerde hata payının arttığı ve bu projelerin modelin performans değerlendirmesinde dikkate alınması gereken sınırlar olabileceği değerlendirilmiştir.

ER modelinde ortaya çıkan tahmin hatalarının daha ayrıntılı bir şekilde gösterilmesi amacıyla oluşturulan kalıntı grafiği Şekil 5.11’de verilmiştir.



Şekil 5.11. ER modeli tahmin edilen maliyet ve hatalar

ER modeli için oluşturulan ve Şekil 5.11’de paylaşılan grafik tahmin edilen güncellenmiş maliyetlerin hata (residual) dağılımını özetleyerek modelin performans sınırlarını projelere göre görselleştirmektedir. Grafikte ÇDR ile benzer sayılarda ve yönlerde tahmin hatalarının yer aldığı açıkça görülmektedir. ER modelinin, gerçek maliyetten daha yüksek tahmin ettiği projelerin hata miktarlarının ÇDR’den daha düşük olduğu görülmektedir.

Şekil 5.10 ve Şekil 5.11’de yer alan grafiklerin birlikte değerlendirilmesi sonucunda ortaya çıkan sonuçlar şu şekilde sıralanabilir;

- ER modeli 12 projede gerçek maliyet değerinden daha düşük, 11 projede daha yüksek tahmin gerçekleştirmiştir.
- ER modeli 8 projede 10 M\$ altında, 5 projede ise 5 M\$ altında tahmin hatası ile tahmin yapmıştır.
- ER modeli 1 projede 125 M\$ üzerinde bir hata ile tahmin gerçekleştirmiştir.
- Bir adet proje haricinde kalan diğer tüm projelerde yaklaşık olarak ± 40 M\$ hata aralığında tahminler yapılmıştır.

Bu bulgular doğrultusunda, modelin tahmin performansı hakkında çeşitli çıkarımlar yapılabilir. ER modeli, bazı projelerde gerçek maliyete yakın tahminler üretmiş olmasına rağmen, belirli projelerde dikkate değer tahmin hataları gözlemlenmiştir. Özellikle yüksek maliyetli projelerde hata oranının daha belirgin olduğu görülmüştür. Bu analizlerden hareketle, modelin hiperparametre ayarlama işlemi sonrası elde edilen tahmin performansı ve başarı metriklerine dayalı daha kapsamlı değerlendirmeler yapılabilir. ER modeli başarı parametrelerinin değerlerini elde etmek amacıyla yazılan kod Resim 5.9’da sunulmuştur.

```
# Tune sonrası tahmin yapılması
y_train_pred_AT = best_elasticnet.predict(X_train)
y_test_pred_AT = best_elasticnet.predict(X_test)

# Tune sonrası model başarı metriklerinin hesaplanması (AT: After Tuning)
r2_train_AT, rmse_train_AT, mae_train_AT, mape_train_AT = calculate_metrics(y_train, y_train_pred_AT)
r2_test_AT, rmse_test_AT, mae_test_AT, mape_test_AT = calculate_metrics(y_test, y_test_pred_AT)
```

Resim 5.9. ER modelinde hiperparametre ayarlama işlemi sonrası başarı metriklerinin hesaplanması

Resim 5.9’da gösterilen Python kodu, ER modelinin hiperparametre ayarlama işlemi sonrasında elde edilen tahmin sonuçlarının, eğitim ve test veri setleri üzerindeki performansını ölçmek için kullanılan değerlendirme araçlarını hesaplamaktadır. Bu kod ile modelin genelleme kapasitesini ve tahmin performansını analiz etmek için R^2 , RMSE, MAE ve MAPE gibi başarı metrikleri hesaplanmıştır. Hesaplanan başarı metrikleri, modelin hem eğitim hem de test veri seti üzerindeki performansını detaylı bir şekilde değerlendirmek için kullanılmaktadır. Bu metriklerin hesaplanması sonucunda, modelin genel doğruluk düzeyi ve hatalarının dağılımı daha kapsamlı bir perspektiften analiz edilmiştir.

ER model sonucunda elde edilen başarı metriklerinin aldığı değerler Çizelge 5.5'te sunulmuştur.

Çizelge 5.5. ER model başarı metrikleri (hiperparametre ayarlama işlemi sonrası)

Başarı parametresi	Sonuç
R^2 (eğitim)	0,71
RMSE (eğitim)	43 448 801,92
MAE (eğitim)	26 931 265,38
MAPE (eğitim)	434,40
R^2 (test)	0,74
RMSE (test)	35 228 240,74
MAE (test)	23 334 860,30
MAPE (test)	314,74

Çizelge 5.5'te yer alan başarı metrikleri, test veri seti özelinde ER modelinin $R^2 = 0,74$ değerine ulaştığını göstermektedir. Başka bir ifadeyle, bağımsız değişkenler maliyet üzerindeki değişkenliği %74 oranında açıklayabilmektedir. Bu değer ÇDR modeli sonucunda elde edilen 0,61 değerinden yüksektir ve mühendislik problemleri açısından kabul edilebilir seviyenin bir miktar üstü; yani, iyi olarak nitelendirilebilecek düzeydedir. ER modelinin tahmin yeteneğinde ÇDR'ye göre belirgin bir iyileşme sağladığı görülmüştür. Bu gelişmede model algoritmasında yer alan L1 ve L2 normlarının yanı sıra hiperparametre ayarlama sürecinin etkili olduğu değerlendirilmektedir.

ER modelinin RMSE_test değeri yaklaşık 35,2 M\$ seviyesinde hesaplanmıştır. RMSE değerinde ÇDR'ye göre önemli bir düşüş gözlemlenmiştir. Böylece modelin maliyet tahminlerinde gerçek maliyet ile olan farkının görece azaldığı sonucu ortaya çıkmaktadır.

MAE ve MAPE açısından da modelin başarı düzeyi R^2 ve RMSE parametreleri ile benzerlik göstermektedir. Bu başarı metriklerinde de ÇDR'ye göre kısmi iyileşmeler sağlanmıştır.

Başarı metrikleri açısından modelin tahmin başarısı değerlendirildiğinde ilk model olan ÇDR'ye göre iyileşmeler gözlemlense de her iki doğrusal modelde de gelişime açık oldukça fazla yön olduğu açıktır. Bu nedenle veri seti ile doğrusal olmayan yöntemlerle model geliştirerek daha güçlü tahmin performansı elde edilmesi planlanmıştır.

5.5. K-En Yakın Komşu (KNN) Tahmin Modeli

Bu bölümde KNN modelinin oluşturulma süreci aktarılmaktadır. KNN, verilerin benzerliğine dayanan, yaygın olarak kullanılan bir makine öğrenmesi algoritmasıdır [9]. Bu yöntemde bir veri noktasının tahmini, veri setinde o noktaya en yakın K adet komşu veri noktasının yardımıyla yapılmaktadır. KNN modeli, özellikle doğrusal olmayan yapıları öğrenme kapasitesi ile öne çıkmaktadır. Önceki bölümlerde doğrusal ilişkilerin seviyesini ölçümleyebilmek amacıyla ÇDR ve ER algoritmaları aracılığıyla modeller oluşturulmuştur. Ancak elde edilen sonuçlar doğrultusunda, doğrusal olmayan modellerin, daha kararlı tahmin sonuçları verebilme potansiyeli olduğu değerlendirilmektedir.

KNN modeli, veri noktaları arasındaki benzerlikleri dikkate alarak, doğrusal olmayan ilişkiler üzerinden tahminler yapabilme kapasitesi ile bu çalışmada tercih edilmiştir. Bunun yanı sıra, KNN modeli, özellikle veri setinin farklı bölümlerinde çeşitli yapılar ve ilişkiler bulunabileceği durumlar için esneklik sağlamaktadır. ER modelinden farklı olarak, KNN'nin parametre ayarları daha basit bir yapı sunmakta ve model aşırı uyuma karşı nispeten daha dayanıklı olabilmektedir. Bu nedenle, KNN modeli, doğrusal modellerin ardından farklı bir bakış açısı sunmak ve elde edilen sonuçları karşılaştırmak amacıyla çalışmada yer almaktadır.

5.5.1. KNN modelinin oluşturulması

KNN modelinin Jupyter Notebook ortamında Python dili kullanılarak yazılan kodu Resim 5.10'da gösterilmiştir.

```
# Gerekli kütüphanelerin içeri aktarılması
from sklearn.neighbors import KNeighborsRegressor

# KNN modelinin kurulması (Tune Öncesi)
knn = KNeighborsRegressor()
knn.fit(X_train, y_train)

# Tune öncesi tahmin yapılması
y_train_pred_BT = knn.predict(X_train)
y_test_pred_BT = knn.predict(X_test)

# Tune öncesi model başarı metriklerinin hesaplanması (BT: Before Tuning)
r2_train_BT, rmse_train_BT, mae_train_BT, mape_train_BT = calculate_metrics(y_train, y_train_pred_BT)
r2_test_BT, rmse_test_BT, mae_test_BT, mape_test_BT = calculate_metrics(y_test, y_test_pred_BT)
```

Resim 5.10. KNN model nesnesi oluşturulması ve hiperparametre ayarlama işlemi öncesi başarı metriklerinin hesaplanması

KNN modelinin geliştirilmesi sürecinde Scikit-Learn kütüphanesinin KNeighborsRegressor sınıfı kullanılmıştır. Bu modelde, seçilen komşu sayısı (K) ve belirlenen mesafe ölçümü yardımıyla, bağımlı değişken ile bağımsız değişkenler arasındaki ilişkilerin tespit edilmesi amaçlanmıştır. Scikit-Learn'ün sunduğu bu sınıfta en yakın komşular, Öklidyen mesafesi formülü ile tespit edilmektedir.

KNN modelinin eğitim aşaması tamamlandıktan sonra, modelin tahmin performansı test verisi üzerinde değerlendirilmiştir. Hiperparametre ayarlama işlemi öncesinde, modelin başarısını ölçmek amacıyla R^2 , RMSE, MAE ve MAPE gibi başarı metrikleri kullanılarak modelin tahmin gücü değerlendirilmiştir. Hiperparametre ayarlama işlemi öncesi hesaplanan model başarı metrikleri Çizelge 5.6'da gösterilmiştir.

Çizelge 5.6. KNN model başarı metrikleri (hiperparametre ayarlama işlemi öncesi)

Başarı parametresi	Sonuç
R^2 (eğitim)	0,73
RMSE (eğitim)	42 406 643,71
MAE (eğitim)	12 579 906,46
MAPE (eğitim)	28,89
R^2 (test)	0,83
RMSE (test)	28 282 580,27
MAE (test)	11 227 757,01
MAPE (test)	29,51

5.5.2. KNN için hiperparametre ayarlaması ve GridSearchCV kullanımı

KNN modelinin performansını artırmak ve en uygun tahmin sonuçlarını elde edebilmek amacıyla modelin belirli hiperparametreleri optimize edilmiştir. KNN modelinde kullanılan temel hiperparametrelerden biri olan "*n_neighbors*" değeri, bir veri noktasının tahmininde dikkate alınacak komşu sayısını belirler. Bu parametre, modelin esnekliğini ve genelleme kapasitesini doğrudan etkiler. Küçük "*n_neighbors*" değerleri, modelin daha hassas ve yerel tahminler yapmasını sağlar, ancak bu durum modelin aşırı uyuma eğilimli olmasına yol açabilir. Öte yandan, daha yüksek "*n_neighbors*" değerleri, tahminlerin daha genel kalmasına ve komşular arasındaki farkların dengelenmesine olanak tanır, bu da modelin aşırı

uyumdan kaçınmasını sağlar. Böylece, "*n_neighbors*" parametresinin doğru seçimi, modelin doğruluğunu ve genellenebilirliğini optimize etmek için kritik bir rol oynar.

Ayrıca, modelin komşulara atadığı ağırlıkları belirlemek için "*weights*" hiperparametresi kullanılır. Bu parametre "*uniform*" ve "*distance*" olmak üzere iki farklı seçenek sunar. "*Uniform*" seçeneği, tüm komşulara eşit ağırlık verirken, "*distance*" seçeneği yakın komşulara daha yüksek ağırlık vererek daha etkili bir tahmin süreci sağlar.

KNN modelinin doğruluğunu en üst düzeye çıkarmak ve aşırı uyumu minimize etmek için GridSearchCV sınıfı kullanılarak hiperparametre ayarlama işlemi gerçekleştirilmiştir. Bu süreçte, farklı "*n_neighbors*" ve "*weights*" kombinasyonları denenmiş ve 5 katlı çapraz doğrulama kullanılarak modelin genel tahmin başarısını en üst seviyeye çıkaran hiperparametre değerleri belirlenmiştir. Bu sayede, KNN modelinin çeşitli veri bölümlerindeki tahmin doğruluğu optimize edilmiştir. KNN modelinde, GridSearchCV ile hiperparametre ayarlama işlemi için kullanılan Python kodu Resim 5.11'de sunulmuştur.

```
# Gerekli kütüphanelerin içeri aktarılması
from sklearn.model_selection import GridSearchCV

# KNN hiperparametre gridleri
knn_params = {
    'n_neighbors': [3, 4, 5, 6, 7, 8, 9, 10, 11],
    'weights': ['uniform', 'distance']
}

# GridSearchCV ile KNN modeli için en iyi hiperparametrelerin bulunması
knn_grid = GridSearchCV(KNeighborsRegressor(), knn_params, cv=5, scoring='r2')
knn_grid.fit(X_train, y_train)

# En iyi hiperparametreleri içeren tahminci için model nesnesi oluşturulması
best_knn = knn_grid.best_estimator_

# Modelin eğitilmesi
best_knn.fit(X_train, y_train)
```

Resim 5.11. KNN modelinde GridSearchCV kullanımı

ER modeli için hiperparametre ayarlama işlemi sonucunda ortaya çıkan en iyi hiperparametre kombinasyonunu görmek için kullanılan Python kodu ve bu kodun çalıştırılmasıyla ortaya çıkan sonuç, Resim 5.12'de sunulmuştur.


```
knn_grid.best_params_
{'n_neighbors': 4, 'weights': 'distance'}
```

Resim 5.12. KNN modeli için en iyi hiperparametre çağırma kodu ve cevap satırı

Mevcut veri seti ve önerilen hiperparametre seçenekleri için kod çalıştırıldığında en iyi kombinasyon “*n_neighbors*” = 4 ve “*weights*” = “*distance*” olarak hesaplanmıştır

5.5.3. KNN modeli sonuçları

KNN modeli, önceki bölümde GridSearchCV sınıfı kullanılarak belirlenen en uygun hiperparametre kombinasyonları ile eğitilmiştir. Eğitim süreci tamamlandıktan sonra, modelin tahmin performansını değerlendirmek üzere test verileri üzerinde uygulanmaya hazır hâle getirilmiştir. Hiperparametre ayarlama işlemi sonrasında KNN modeli tarafından tahmin edilen maliyet değerleri ile DGBH projelerinin gerçek maliyetlerinin karşılaştırıldığı grafik Şekil 5.12’de sunulmuştur.




Şekil 5.12. KNN modeli gerçek ve tahmin edilen maliyetlerin karşılaştırılması

Şekil 5.12’deki grafikte modelin maliyet tahminlerinin gayet başarılı ve gerçek değerlere oldukça yakın olduğu görülmektedir. Özellikle küçük ve orta ölçekli projelerde, tahmin edilen değerler ile gerçek maliyetler arasında büyük farklılıklar yoktur. Ancak, test verisi içinde yer alan ve açık bir şekilde diğer projelere göre yüksek bir tamamlanma maliyetine sahip olan 15’inci projede belirgin bir sapma meydana geldiği görülmektedir.

KNN modeli, çoğu proje için maliyet tahminlerinde gerçek maliyete oldukça yakın sonuçlar vermesine rağmen, 15 numaralı projede gözlemlenen tahmin hatası, bu projenin hayata geçirilmesi sırasında farklı süreç problemlerinin varlığına veya KNN modelinin belirli projelerde daha düşük performans gösterebildiğine işaret etmektedir. Model, 100 M\$ üzerinde gerçekleşme maliyeti olan 1 numaralı projede başarılı bir tahmin gerçekleştirmiş olsa da, 50 - 100 M\$ arasında maliyete sahip iki farklı projede belirgin tahmin hataları gözlemlenmiştir. Bu durum, KNN modelinin büyük projelerdeki karmaşık yapıları ve veri dağılımlarını tam anlamıyla yakalayamamasıyla ilişkilendirilebilir. Özellikle yüksek maliyetli projelerde, projeler arası benzerliklerin azaldığı ve komşuluk yapısının etkisinin zayıfladığı düşünülebilir. Bu da KNN modelinin büyük projelerde doğruluğunu azaltan bir etken olarak değerlendirilebilir.

Bu analiz, KNN modelinin küçük ve orta ölçekli projelerde doğruluk oranının daha yüksek olduğunu, ancak maliyeti yüksek projelerde tahmin hatalarının arttığını göstermektedir. Tahmin performansının daha detaylı incelenmesi için modelin tahmin hatalarının görselleştirildiği kalıntı grafiği Şekil 5.13'te verilmiştir.



Şekil 5.13. KNN modeli tahmin edilen maliyet ve hatalar

KNN modeli için oluşturulan ve Şekil 5.13'te paylaşılan grafik tahmin edilen güncellenmiş maliyetlerin hata (residual) dağılımını özetleyerek modelin performans sınırlarını projelere göre görselleştirmektedir. Modelin doğrusal modellere kıyasla daha yüksek bir başarı sergilediği ve tahmin performansında belirgin bir iyileşme olduğu açıktır. Özellikle, bir proje haricinde KNN modelinin tahmin hatalarının daha dar bir aralığa toplandığı gözlemlenmiş olup, bu durum, modelin tahmin kabiliyetini ve veri setinin algoritmanın yapısına uygunluğunu ortaya koymaktadır. Ayrıca, algoritmanın doğası gereği hiçbir tahmin değerinin negatif değer almaması, modelin tahmin çıktılarının tutarlı ve mantıklı sınırlar içinde kalması açısından önemlidir. Sunulan bu çıkarımlar doğrultusunda veri setinin doğrusal olmayan algoritmalarla daha iyi eşleştiği değerlendirilmektedir.

Şekil 5.12 ve Şekil 5.13 birlikte değerlendirildiğinde ortaya çıkan sonuçlar aşağıda açıklanmıştır;

- Bir proje haricinde tüm tahminler, -2 M\$ ila +22 M\$ arasında tahmin hatası göstermiştir.
- Modelin tahminlerinin gerçek maliyeti aştığı tüm projelerde, en fazla yaklaşık 2 M\$ fazla tahmin hatası gözlemlenmiştir.
- Modelin, gerçek maliyetten düşük tahmin yaptığı projelerde en fazla yaklaşık 140 M\$ tahmin hatası gerçekleşmiştir.

Bu bulgular, modelin özellikle küçük ve orta ölçekli projelerde daha sınırlı hata oranlarına sahip olduğunu, ancak büyük projelerde tahmin sapmalarının daha belirgin hâle geldiğini ortaya koymaktadır. Özellikle yüksek maliyetli projelerde hata oranının daha belirgin olduğu görülmüştür. Bu analizlerden hareketle, modelin hiperparametre ayarlama işlemi sonrası elde edilen tahmin performansı ve başarı metriklerine dayalı daha kapsamlı değerlendirmeler yapılabilir. KNN modelinde hiperparametre ayarlama işlemi sonrası başarı parametrelerinin değerlerini elde etmek amacıyla yazılan kod Resim 5.13'te sunulmuştur.

```
# Tune sonrası tahmin yapılması
y_train_pred_AT = best_knn.predict(X_train)
y_test_pred_AT = best_knn.predict(X_test)

# Tune sonrası model başarı metriklerinin hesaplanması (AT: After Tuning)
r2_train_AT, rmse_train_AT, mae_train_AT, mape_train_AT = calculate_metrics(y_train, y_train_pred_AT)
r2_test_AT, rmse_test_AT, mae_test_AT, mape_test_AT = calculate_metrics(y_test, y_test_pred_AT)
```

Resim 5.13. KNN modelinde hiperparametre ayarlama işlemi sonrası başarı metriklerinin hesaplanması

KNN model sonucunda elde edilen başarı metriklerinin aldığı değerler Çizelge 5.7’de sunulmuştur.

Çizelge 5.7. KNN model başarı metrikleri (hiperparametre ayarlama işlemi sonrası)

Başarı parametresi	Sonuç
R^2 (eğitim)	1,00
RMSE (eğitim)	0,00
MAE (eğitim)	0,00
MAPE (eğitim)	0,00
R^2 (test)	0,82
RMSE (test)	29 218 117,97
MAE (test)	9 967 553,86
MAPE (test)	23,65

KNN algoritması, eğitim verisindeki her bir veri noktasını hafızasında saklayarak tahminlerde bulunur ve her tahmin sırasında bu verileri doğrudan kullanır. Bu nedenle, modelin eğitim verisi üzerinde yüksek doğruluk ve sıfıra yakın hata oranları göstermesi olağan bir durumdur. Özellikle düşük komşu sayısı veya “weights” = “distance” gibi ağırlıklandırma kullanıldığında, eğitim verisi üzerinde mükemmel yakın tahminler yapılabilir. Ancak bu durum, test verisinde aynı doğruluk seviyesinde devam etmez. Eğitim setindeki yüksek başarı, KNN'nin doğasından kaynaklanmakta olup, bu başarının test setine tam olarak genellenememesi bu algoritmanın temel özelliklerinden biridir.

Çizelge 5.7’de yer alan başarı metrikleri, test veri seti özelinde KNN modelinin $R^2 = 0,82$ değerine ulaştığını göstermektedir. Bu değer ER modeli sonucunda elde edilen $R^2 = 0,74$ değerinden yüksektir. KNN modeline göre bağımsız değişkenler maliyet üzerindeki değişkenliği %82 oranında açıklayabilmektedir. Bu değer mühendislik problemleri kapsamında değerlendirildiğinde oldukça iyi olarak nitelendirilebilecek düzeydedir. KNN modelinin tahmin yeteneğinde doğrusal modellere göre belirgin bir iyileşme sağladığı görülmüştür.

KNN modelinin RMSE_test değeri yaklaşık 29.2 M\$ seviyesinde hesaplanmıştır. RMSE değerinde ER’ye göre önemli bir düşüş gözlemlenmiştir. Böylece modelin maliyet tahminlerinde gerçek maliyetle olan farkının görece azaldığı sonucu ortaya çıkmaktadır.

MAE ve MAPE açısından ise durum oldukça farklıdır. KNN bu başarı metriklerinde ER'ye göre inanılmaz düzeyde başarılı sonuçlar ortaya koymuştur. Bu bulgu, veri setinin doğrusal olmayan bir model yapısına daha uygun olduğu noktasında destekleyici niteliktedir.

Başarı metrikleri açısından modelin tahmin başarısı değerlendirildiğinde ÇDR ve ER'ye göre iyileşmeler gözlemlense de yüksek maliyetli projelerde KNN'in doğal yapısı gereği başarılı tahmin üretilmediği görülmektedir.

KNN modeli, diğer doğrusal modellerden farklı olarak, tahmin sonuçlarını eğitim sırasında oluşturduğu dinamik veri yapılarına dayalı olarak gerçekleştirmektedir. Bu nedenle, ÇDR ve ER modellerindeki gibi sabit bir matematiksel denklem sunulması mümkün olmamıştır. Ancak modelin tahmin performansı başarı metrikleri ve grafikler yardımıyla detaylı olarak değerlendirilmiştir. Ayrıca, KNN modelinin tahmin sonuçları, 6. bölümde açıklanan dijital tahmin platformu üzerinden erişilebilir hale getirilmiştir. Bu platform üzerinden farklı bağımsız değişken değerlerine göre KNN modelinin tahmin sonuçları elde edilebilmektedir. KNN modeli, sağladığı esneklik ile doğrusal olmayan yapılar için etkili bir çözüm sunmaktadır.

KNN modelinin eğitim setindeki yüksek doğruluğu, modelin yapısal özelliklerinden kaynaklanırken test setinde aynı seviyede performans sergilememesi, bu veri setinin KNN'nin temel aldığı yerel benzerlik yapısına uygun olduğunu düşündürmektedir. Bu bağlamda, KNN modelinin gösterdiği başarı, veri setinin yerel ilişkiler açısından güçlü olduğunu ve komşuluk tabanlı tahmin yöntemlerinin bu tür verilere uyum sağlayabileceğini göstermektedir. Ancak, daha karmaşık yapıdaki projelerde daha güçlü tahmin sonuçları elde edebilmek için ağaç tabanlı yöntemlerin de denenmesi planlanmıştır.

5.6. Rastgele Ormanlar (RF) Tahmin Modeli

RF, doğrusal olmayan yapıları ve karmaşık veri ilişkilerini modelleme kapasitesi nedeniyle tercih edilen bir topluluk öğrenme algoritmasıdır [55]. Bu model, birden fazla karar ağacının bir araya gelmesiyle oluşturulur ve her bir ağaç, veri setinin farklı alt kümeleri üzerinde eğitilerek modelin genellenebilirliğini artırmaya katkı sağlar.

RF modeli, DGBH projelerinin maliyet tahmini gibi çok boyutlu problemlerde, veriler arasındaki doğrusal olmayan ilişkileri etkin bir şekilde tanıyabilir. Ağaç tabanlı yapısı sayesinde her bir karar ağacı, veri yapısındaki bağımsız değişkenler ile maliyet arasındaki ilişkileri farklı bir bakış açısıyla değerlendirir. Bu yöntem, modelin aşırı uyum riskini azaltarak daha kararlı tahmin sonuçları üretmesini sağlar.

Bu çalışmada RF modelinin seçilmesinin bir diğer nedeni, hiperparametre ayarlarının geniş bir yelpazede uyarlanabilmesi ve modelin farklı veri yapılarıyla uyumlu sonuçlar üretebilmesidir. Modelin bu esnek yapısı, KNN ve diğer doğrusal modellerle elde edilen sonuçları karşılaştırarak, doğrusal olmayan yaklaşımların tahmin performansına katkısını analiz etme fırsatı sunmaktadır.

5.6.1. RF modelinin oluşturulması

RF modelinin Jupyter Notebook ortamında Python dili kullanılarak yazılan kodu Resim 5.14'te gösterilmiştir.

```
# Gerekli kütüphanelerin içeri aktarılması
from sklearn.ensemble import RandomForestRegressor

# RF modelinin kurulması (Tune Öncesi)
rf = RandomForestRegressor(random_state=42)
rf.fit(X_train, y_train)

# Tune öncesi tahmin yapılması
y_train_pred_BT = rf.predict(X_train)
y_test_pred_BT = rf.predict(X_test)

# Tune öncesi model başarı metriklerinin hesaplanması (BT: Before Tuning)
r2_train_BT, rmse_train_BT, mae_train_BT, mape_train_BT = calculate_metrics(y_train, y_train_pred_BT)
r2_test_BT, rmse_test_BT, mae_test_BT, mape_test_BT = calculate_metrics(y_test, y_test_pred_BT)
```

Resim 5.14. RF model nesnesi oluşturulması ve hiperparametre ayarlama işlemi öncesi başarı metriklerinin hesaplanması

RF modelinin geliştirilmesi sürecinde Scikit-Learn kütüphanesinin RandomForestRegressor sınıfı kullanılmıştır. Bu modelde belirlenen ağaç sayısı ve diğer hiperparametreler yardımıyla, bağımlı değişken ile bağımsız değişkenler arasındaki ilişkilerin tespit edilmesi amaçlanmıştır. Scikit-Learn'ün sunduğu bu sınıf, her bir ağaç için rastgele seçilmiş alt özellik kümeleri üzerinden modelleme yaparak genelleştirilebilir tahminler üretilmesini sağlamaktadır.

RF modelinin eğitim aşaması tamamlandıktan sonra, modelin tahmin performansı test verisi üzerinde değerlendirilmiştir. Hiperparametre ayarlama işlemi öncesinde, modelin başarısını ölçmek amacıyla R^2 , RMSE, MAE ve MAPE gibi başarı metrikleri kullanılarak modelin tahmin gücü değerlendirilmiştir. Hiperparametre ayarlama işlemi öncesi hesaplanan model başarı metrikleri Çizelge 5.8’de gösterilmiştir.

Çizelge 5.8. RF model başarı metrikleri (hiperparametre ayarlama işlemi öncesi)

Başarı parametresi	Sonuç
R^2 (eğitim)	0,95
RMSE (eğitim)	18 608 517,85
MAE (eğitim)	5 594 288,97
MAPE (eğitim)	17,21
R^2 (test)	0,56
RMSE (test)	46 026 625,86
MAE (test)	16 993 120,92
MAPE (test)	57,62

5.6.2. RF için hiperparametre ayarlaması ve GridSearchCV kullanımı

RF modelinin performansını artırmak ve en uygun tahmin sonuçlarını elde edebilmek amacıyla modelin belirli hiperparametreleri optimize edilmiştir. RF modelinde kullanılan temel hiperparametrelerden biri olan "*n_estimators*" değeri, algoritma ormanındaki karar ağaçlarının sayısını belirler. Daha yüksek "*n_estimators*" değerleri, modelin daha güçlü tahminler yapmasını sağlarken, bu durum hesaplama maliyetini artırabilir. Dolayısıyla, bu parametrenin doğru seçimi, modelin tahmin doğruluğunu ve işlem verimliliğini dengelemede önemli bir rol oynar. Bunun yanı sıra, "*max_features*" parametresi, her bir ağacı eğitmek için kullanılacak maksimum özellik sayısını belirler. Bu parametre, modelin çeşitliliğini artırarak aşırı uyumun önüne geçilmesine yardımcı olur. "*sqrt*" ve "*log2*" seçenekleri ile belirli bir oranda özellik seçimi yapılması sağlanır ve model, her bir ağaç için farklı özelliklerin alt kümelerini değerlendirerek daha genellenebilir bir yapı elde eder. Ek olarak, "*min_samples_split*" ve "*min_samples_leaf*" parametreleri, bir ağacın bölünmesi için gereken minimum örnek sayısını ve her bir yaprak düğümünde bulunması gereken minimum örnek sayısını belirler. Bu parametreler, ağaçların daha derin veya yüzeysel olmasını sağlayarak modelin genelleme kapasitesini ve doğruluğunu etkiler. Küçük değerler, modelin

eğitim verisine daha duyarlı olmasına yol açabilirken, daha büyük değerler aşırı uyumu engelleme yönünde modelin dayanıklılığını artırır.

RF modelinin doğruluğunu en üst düzeye çıkarmak ve aşırı uyumu minimize etmek amacıyla GridSearchCV sınıfı kullanılarak hiperparametre ayarlama işlemi gerçekleştirilmiştir. Bu süreçte, farklı "*n_estimators*", "*max_features*", "*min_samples_split*" ve "*min_samples_leaf*" kombinasyonları denenmiş ve 5 katlı çapraz doğrulama kullanılarak modelin genel tahmin başarısını en üst seviyeye çıkaran parametreler belirlenmiştir. RF modelinde, GridSearchCV ile hiperparametre ayarlama işlemi için kullanılan Python kodu Resim 5.15'te sunulmuştur.

```
# Gerekli kütüphanelerin içeri aktarılması
from sklearn.model_selection import GridSearchCV

# RF hiperparametre gridleri
rf_params = {
    'n_estimators': [10, 50, 100],
    'max_features': ['sqrt'],
    'min_samples_split': [5, 10],
    'min_samples_leaf': [2, 4]
}

# GridSearchCV ile RF modeli için en iyi hiperparametrelerin bulunması
rf_grid = GridSearchCV(RandomForestRegressor(random_state=42), rf_params, cv=5, scoring='r2')
rf_grid.fit(X_train, y_train)

# En iyi hiperparametreleri içeren tahminci için model nesnesi oluşturulması
best_rf = rf_grid.best_estimator_

# Modelin eğitilmesi
best_rf.fit(X_train, y_train)
```

Resim 5.15. RF modelinde GridSearchCV kullanımı

RF modeli için hiperparametre ayarlama işlemi sonucunda ortaya çıkan en iyi hiperparametre kombinasyonunu görmek için kullanılan Python kodu ve bu kodun çalıştırılmasıyla ortaya çıkan sonuç, Resim 5.16'da sunulmuştur.

```
rf_grid.best_params_


{'max_features': 'sqrt',
 'min_samples_leaf': 2,
 'min_samples_split': 5,
 'n_estimators': 100}
```

Resim 5.16. RF bölümü için en iyi hiperparametreleri çağırma kodu ve cevap satırı

Mevcut veri seti ve önerilen hiperparametre seçenekleri için kod çalıştırıldığında en iyi kombinasyon "*n_estimators*" = 100, "*max_features*" = "*sqrt*", "*min_samples_split*" = 5 ve "*min_samples_leaf*" = 2 olarak hesaplanmıştır.

5.6.3. RF modeli sonuçları

RF modeli, önceki bölümde GridSearchCV sınıfı kullanılarak belirlenen en uygun hiperparametre kombinasyonları ile eğitilmiştir. Eğitim süreci tamamlandıktan sonra, modelin tahmin performansını değerlendirmek üzere test verileri üzerinde uygulanmaya hazır hâle getirilmiştir. Hiperparametre ayarlama işlemi sonrasında RF modeli tarafından tahmin edilen maliyet değerleri ile DGBH projelerinin gerçek maliyetlerinin karşılaştırıldığı grafik Şekil 5.14'te sunulmuştur.




Şekil 5.14. RF modeli gerçek ve tahmin edilen maliyetlerin karşılaştırılması

Şekil 5.14'te paylaşılan grafikte genel anlamda başarılı tahmin sonuçlarının elde edildiği görülmektedir. Şimdiye kadar denemesi yapılmış olan diğer üç algoritmaya (ÇDR, ER ve KNN) göre test veri seti içerisinde gerçekleşme maliyeti en yüksek olan 15 numaralı projeye en yakın tahmin performansı RF modelinde elde edilmiştir. Düşük gerçekleşme maliyetine sahip projelerde modelin tahmin çizgisinin, gerçekleşme maliyeti çizgisi ile oldukça yakın bir şekilde ilerlediği açık bir şekilde görülmektedir. Ancak bazı orta düzey maliyetli projelerde oldukça yüksek tahmin hatalarının da ortaya çıktığı görülmektedir. Model, yaklaşık olarak 25 M\$ seviyelerinde gerçek maliyete sahip olan 22 numaralı projede

yaklaşık 100 M\$ fark ile bir tahmin gerçekleştirmiştir. Bu durum, RF modelinin büyük projelerdeki karmaşık veri yapıları ve dağılımları tam anlamıyla modelleyememesiyle ilişkilendirilebilir. Özellikle orta düzey ve yüksek maliyetli projelerde, projeler arası farklılıkların artmasıyla birlikte, RF modelinin her bir projenin özgün maliyet dinamiklerini yakalamakta zorlandığı söylenebilir. Bu da modelin büyük projelerdeki tahmin doğruluğunu etkileyen önemli bir faktör olarak değerlendirilebilir.

Bu analiz, RF modelinin düşük gerçekleşme maliyetine sahip projelerde oldukça başarılı tahminler yapmasına rağmen, orta düzey ve yüksek maliyetli projelerde daha yüksek sapma oranlarına sahip olduğunu göstermektedir. Tahmin performansının daha detaylı incelenmesi için modelin tahmin hatalarının görselleştirildiği kalıntı grafiği Şekil 5.15'te sunulmuştur.



Şekil 5.15. RF modeli tahmin edilen maliyet ve hatalar

RF modeli için oluşturulan ve Şekil 5.15'te paylaşılan grafik tahmin edilen güncellenmiş maliyetlerin hata (kalıntı) dağılımını özetleyerek modelin performans sınırlarını projelere göre görselleştirmektedir. Grafikte yer alan noktaların büyük çoğunluğu sıfır eksenine yakın bir şekilde konumlanmış olup, bu durum RF modelinin genel anlamda başarılı bir performans sergilediğini göstermektedir. Ayrıca RF modelinin KNN ile benzer şekilde,

doğrusal modellere kıyasla daha yüksek bir başarı sergilediği ve tahmin performansında belirgin bir iyileşme olduğu grafikten yapılabilecek çıkarımlardan birisidir. Ancak RF modelinde negatif hata (tahmin edilen maliyetin gerçek proje maliyetinden daha yüksek olması durumu) adedi ve hata aralıkları KNN ile kıyaslandığında daha yüksektir. Tüm test veri seti üzerinde genel bir değerlendirme yapıldığında ise benzer performanslar gösterdikleri söylenebilir.

Şekil 5.14 ve Şekil 5.15 birlikte değerlendirildiğinde ortaya çıkan sonuçlar aşağıda açıklanmıştır;

- 3 proje haricinde tüm tahminler yaklaşık -12 M\$ ve +4 M\$ aralığında tahmin hatalarına sahiptir.
- Test veri seti ile gerçekleştirilen tahminlerin yarısından fazlasının tahmin hata aralığı ± 2 M\$ şeklinde gerçekleşmiştir.
- 7 adet projenin tahmininde ± 1 M\$ tahmin hatası gözlemlenmiştir.
- Modelde 60 M\$'dan daha yüksek hata ile tahmin edilen 3 adet proje bulunmaktadır. Bunlardan ikisinde model gerçek maliyete göre daha yüksek, birinde ise gerçek maliyete göre daha düşük tahmin performansı göstermiştir.

Bu bulgular neticesinde RF modelinin özellikle orta ve yüksek maliyetli projelerde tahmin hata oranının daha yüksek olduğu görülmüştür. Bazı orta düzey ve düşük maliyetli projelerde ise gerçek maliyete oldukça yakın tahmin performansı ortaya çıkmıştır. Bu analizlerden hareketle, modelin hiperparametre ayarlama işlemi sonrası elde edilen tahmin performansı ve başarı metriklerine dayalı daha kapsamlı değerlendirmeler yapılabilir. RF modelinde hiperparametre ayarlama işlemi sonrası başarı parametrelerinin değerlerini elde etmek amacıyla yazılan kod Resim 5.17'de sunulmuştur.

```
# Tune sonrası tahmin yapılması
y_train_pred_AT = best_rf.predict(X_train)
y_test_pred_AT = best_rf.predict(X_test)

# Tune sonrası model başarı metriklerinin hesaplanması (AT: After Tuning)
r2_train_AT, rmse_train_AT, mae_train_AT, mape_train_AT = calculate_metrics(y_train, y_train_pred_AT)
r2_test_AT, rmse_test_AT, mae_test_AT, mape_test_AT = calculate_metrics(y_test, y_test_pred_AT)
```

Resim 5.17. RF modelinde hiperparametre ayarlama işlemi sonrası başarı metriklerinin hesaplanması

RF model sonucunda elde edilen başarı metriklerinin aldığı değerler Çizelge 5.9'da sunulmuştur.

Çizelge 5.9. RF model başarı metrikleri (hiperparametre ayarlama işlemi sonrası)


Başarı parametresi	Sonuç
R^2 (eğitim)	0,78
RMSE (eğitim)	38 177 899,02
MAE (eğitim)	11 162 007,35
MAPE (eğitim)	41,78
R^2 (test)	0,83
RMSE (test)	28 318 044,95
MAE (test)	12 536 326,16
MAPE (test)	41,24

Çizelge 5.9'da yer alan başarı metrikleri, test veri seti özelinde RF modelinin $R^2 = 0,83$ değerine ulaştığını göstermektedir. Bu değer KNN modeli sonucunda elde edilen $R^2 = 0,82$ değeri ile oldukça yakındır. RF modeline göre bağımsız değişkenler maliyet üzerindeki değişkenliği %83 oranında açıklayabilmektedir. Bu değer mühendislik problemleri kapsamında değerlendirildiğinde oldukça iyi olarak nitelendirilebilecek düzeydedir.

RF modelinin RMSE_test değeri yaklaşık 28,3 M\$ seviyesinde hesaplanmıştır. RMSE değeri de KNN modelinde elde edilen RMSE_test değeri ile oldukça benzerdir.

MAE ve MAPE açısından da durum diğer başarı metrikleri ile benzerlik göstermektedir. Bu bulgu veri setinin doğrusal olmayan bir model yapısına daha uygun olduğunu göstermektedir.

RF modeli, tahmin sonuçlarını eğitim sırasında oluşturduğu ağaç yapıları süreçlerine dayalı olarak gerçekleştirmektedir. Bu nedenle, ÇDR ve ER modellerindeki gibi sabit bir matematiksel denklem sunulması mümkün olmamıştır. Ancak, modelin tahmin performansı, başarı metrikleri ve grafikler yardımıyla detaylı olarak değerlendirilmiştir. Ayrıca RF ağaç yapısını temsilen 100 farklı karar ağacının 50'inci ağacını temsil eden karar ağacı Şekil 5.16'da sunulmuştur.



Şekil 5.16. RF modeli için örnek bir karar ağacı (50 numaralı ağaç)

RF modeli için oluşturulan karar ağacı, maliyet tahmininde kullanılan bağımsız değişkenlerin etkilerini sistematik bir şekilde değerlendiren ve karar alma sürecini açıklayan bir yapıdır. Karar ağacında her düğüm, belirli bir bağımsız değişkene dayalı olarak veri kümesinin ayrıldığı noktayı temsil etmektedir. Bu yapı sayesinde, modelin tahmin sürecinde hangi değişkenlerin daha kritik rol oynadığı kolaylıkla anlaşılabilir. Karar ağacı, kök düğümünden başlayarak, yaprak düğümlere doğru dallanarak ilerlemektedir.

Kök düğüm, modelin ilk ayrımını gerçekleştirdiği ve hangi bağımsız değişkene dayalı olarak gruplara ayrıldığını belirleyen başlangıç noktasıdır. 50 numaralı ağaç özelinde, kök düğümdeki ilk ayırım, boru çapı (diameter) değişkeni kullanılarak yapılmıştır. Boru çapının 32,606 değerinden küçük veya büyük olmasına bağlı olarak veri iki gruba ayrılmıştır.

Alt düğümler, karar ağacının daha detaylı ayırım yaptığı noktalardır. Her alt düğüm, belirli bir değişkene bağlı olarak veri kümesini daha küçük alt gruplara ayırır. Örneğin;

- "line_valve <= 1.5" düğümünde, hat vanalarının sayısı dikkate alınmış ve veri bu değere göre iki alt gruba ayrılmıştır.
- Başka bir alt düğümde, boru uzunluğunun 44 019 km'den büyük veya küçük olması kriteriyle ayırım yapılmıştır.

Yaprak düğümler, modelin tahmin sonuçlarını ürettiği son noktaları temsil etmektedir. Bu düğümlerde, tahmin edilen maliyet değeri, "value" ile ifade edilir. Bunun yanı sıra, modelin bu tahminleri oluştururken karşılaştığı hata (squared_error) ve bu gruba dâhil olan örnek sayısı (samples) bilgileri de yer almaktadır. Örneğin, Şekil 5.16'da verilen ağaç yapısında en solda ve en altta yer alan yaprak düğümde, tahmin edilen maliyet değeri yaklaşık 977 000 \$ olarak belirtilmiş ve bu tahmin 2 örnek üzerinde gerçekleştirilmiştir.

Karar ağacında her bir yol, veri setindeki bağımsız değişkenlerin etkilerinin bir zincir hâlinde nasıl birbirini takip ettiğini ortaya koymaktadır. Bu yapı, hem modelin tahmin sürecini şeffaflaştırmakta hem de modelin bağımsız değişkenlere dayalı karar alma mekanizmasını görselleştirmektedir. RF modelinin sunmuş olduğu ağaç şeklindeki bu karar verme algoritması, modelin karar verme sürecinde nasıl dallandığını ve tahminlerini hangi kriterlere göre oluşturduğunu detaylı olarak göstermektedir.

Genel olarak RF modelinin başarısı değerlendirildiğinde, doğrusal modeller olan ÇDR ve ER'ye göre oldukça iyi sonuçlar gözlemlenmiştir. RF modelinde, KNN modelinden farklı olarak birkaç orta düzey ve yüksek maliyetli projede yüksek tahmin hataları ortaya çıkmıştır. Bunun yanında 6. bölümde detayları açıklanan dijital tahmin platformu üzerinden RF modelinin tahmin sonuçlarına da erişilebilir. Bu platform üzerinden RF modelinin tahmin sonuçları kullanıcılar tarafından karşılaştırmalı olarak değerlendirilebilmektedir. RF modeli, sunduğu esneklik ile doğrusal olmayan yapılar ve büyük veri setleri için etkili bir çözüm sunmaktadır.

Bu bulgular, doğrusal modeller olan ÇDR ve ER'ye kıyasla daha güçlü tahmin performansı sergileyen RF modelinin, doğrusal olmayan yapıları öğrenme kapasitesine sahip bir algoritma olarak veri setinin dinamiklerini daha iyi yakaladığını göstermektedir. Özellikle KNN modeline benzer şekilde, RF modeli de veri setindeki karmaşık ilişkileri başarılı bir şekilde modellemiş, ancak bazı orta düzey ve yüksek maliyetli projelerde tahmin performansında belirgin sapmalar gözlemlenmiştir. Bu durum, maliyet tahminindeki doğruluğun artırılabilmesi adına daha gelişmiş ve optimize edilebilir ağaç tabanlı algoritmaların, özellikle de gradyan artırma gibi tekniklerin, dikkate alınabileceğini göstermektedir. Bu doğrultuda, XGB gibi yöntemlerin kullanımıyla daha güçlü tahmin performansının elde edilmesi planlanmaktadır.

5.7. XGBoost (XGB) tahmin modeli

XGB, doğrusal olmayan yapıları ve karmaşık veri ilişkilerini modelleme kapasitesi nedeniyle tercih edilen güçlü bir topluluk öğrenme algoritmasıdır. RF modelinde olduğu gibi, birden fazla karar ağacı kullanılarak verideki karmaşık ilişkiler öğrenilmeye çalışılmaktadır. Ancak, RF modelinden farklı olarak XGB, ardışık şekilde kurulan karar ağaçlarının her birinin, bir önceki ağacın yaptığı hataları azaltmaya odaklanması üzerine yapılandırılmıştır.

XGB modelinin geniş hiperparametre ayar yelpazesi, modelin doğrusal olmayan ilişkileri öğrenme yeteneğini güçlendirmektedir. Bu özellik, bu algoritmayı maliyet tahmini gibi çok boyutlu problemlerde, veriler arasındaki karmaşık ilişkileri yakalamada etkin bir araç hâline getirmektedir.

Bu çalışmada XGB modelinin tercih edilmesinin bir diğer nedeni, özellikle maliyeti yüksek projelerdeki tahmin doğruluğunu artırabilme potansiyelidir. Modelin ardışık yapısı, özellikle bu tarz veri setlerinde farklı değişkenler arasındaki karmaşık ilişkilerin daha etkili bir şekilde öğrenilmesine olanak sağlamaktadır. RF ve diğer doğrusal olmayan modellerle karşılaştırıldığında, XGB'nin daha esnek bir yapı sunması, bu modelin doğrusal olmayan veri yapılarında güçlü bir tahmin aracı olarak öne çıkmasını sağlamaktadır.

5.7.1. XGB modelinin oluşturulması

XGB modelinin Jupyter Notebook ortamında Python dili kullanılarak yazılan kodu Resim 5.18'de gösterilmiştir.

```
# Gerekli kütüphanelerin içeri aktarılması
from xgboost import XGBRegressor

# XGB modelinin kurulması (Tune Öncesi)
xgb = XGBRegressor(random_state=42)
xgb.fit(X_train, y_train)

# Tune öncesi tahmin yapılması
y_train_pred_BT = xgb.predict(X_train)
y_test_pred_BT = xgb.predict(X_test)

# Tune öncesi model başarı metriklerinin hesaplanması (BT: Before Tuning)
r2_train_BT, rmse_train_BT, mae_train_BT, mape_train_BT = calculate_metrics(y_train, y_train_pred_BT)
r2_test_BT, rmse_test_BT, mae_test_BT, mape_test_BT = calculate_metrics(y_test, y_test_pred_BT)
```

Resim 5.18. XGB model nesnesi oluşturulması ve hiperparametre ayarlama işlemi öncesi başarı metriklerinin hesaplanması

XGB modelinin geliştirilmesi sürecinde Scikit-Learn kütüphanesinden bağımsız olarak kullanılan XGBoost kütüphanesinin XGBRegressor sınıfı kullanılmıştır. Bu modelde belirlenen ağaç sayısı ve diğer hiperparametreler yardımıyla bağımlı değişken ile bağımsız değişkenler arasındaki ilişkilerin tespit edilmesi XGBoost kütüphanesinin sunduğu bu sınıf, modeldeki her bir ağacı önceki ağacın hatalarını minimize edecek şekilde sıralı olarak eğiterek doğrusal olmayan ilişkilerde yüksek tahmin performansı elde edilmesini hedeflemektedir.

XGB modelinin eğitim aşaması tamamlandıktan sonra, modelin tahmin performansı test verisi üzerinde değerlendirilmiştir. Hiperparametre ayarlama işlemi öncesinde, modelin başarısını ölçmek amacıyla R^2 , RMSE, MAE ve MAPE gibi başarı metrikleri kullanılarak

modelin tahmin gücü değerlendirilmiştir. Hiperparametre ayarlama işlemi öncesi hesaplanan model başarı metrikleri Çizelge 5.10'da gösterilmiştir.

Çizelge 5.10. XGB model başarı metrikleri (hiperparametre ayarlama işlemi öncesi)

Başarı parametresi	Sonuç
R ² (eğitim)	1,00
RMSE (eğitim)	11 809,87
MAE (eğitim)	8 225,09
MAPE (eğitim)	0,12
R ² (test)	0,89
RMSE (test)	23 286 460,18
MAE (test)	11 612 283,51
MAPE (test)	44,74

5.7.2. XGB için hiperparametre ayarlaması ve GridSearchCV kullanımı

XGB modelinin performansını artırmak ve en uygun tahmin sonuçlarını elde edebilmek amacıyla modelin belirli hiperparametreleri optimize edilmiştir. XGB modelinde kullanılan temel hiperparametrelerden biri olan "*n_estimators*" değeri, RF modelinde yer alan hiperparametre ile aynı anlama gelmektedir. Ek olarak, XGB'nin doğruluğunu etkileyen bir diğer önemli hiperparametre "*learning_rate*" hiperparametresidir. Bu hiperparametre modelin her bir aşamada ne kadar "öğreneceğini" belirler. Küçük bir "*learning_rate*" değeri, modelin her bir adımda daha az güncelleme yapmasına neden olur, bu da modelin daha fazla ağaç kullanarak hataları gidermesine olanak sağlar ve genelleme başarısını artırır. Bu nedenle "*learning_rate*", özellikle modelin doğruluğunu artırmak ve aşırı uyumu önlemek için dikkatlice ayarlanması gereken bir parametredir.

XGB modelinde kullanılan "*max_depth*" parametresi, ağaçların derinliğini belirler ve modelin karmaşık ilişkileri yakalayabilme yeteneğini artırır. Daha derin ağaçlar, modelin doğruluğunu artırabilir; ancak aşırı derin ağaçlar, modelin aşırı uyum göstermesine yol açabilir. Bu nedenle, "*max_depth*" parametresi doğru bir seviyede seçilmelidir.

Ayrıca, XGB'nin tahmin başarısını etkileyen "*subsample*" ve "*colsample_bytree*" hiperparametreleri de bulunmaktadır. "*subsample*", her bir ağacın eğitimi sırasında

kullanılacak veri yüzdesini belirlerken, "colsample_bytree" ise her bir ağacın eğitiminde kullanılan özellik yüzdesini belirler. Bu parametreler, modelin çeşitliliğini artırarak aşırı uyumun önlenmesine katkı sağlar. XGB modelinin doğruluğunu en üst düzeye çıkarmak ve aşırı uyumu minimize etmek amacıyla hiperparametre ayarlama işlemi, GridSearchCV sınıfı kullanılarak gerçekleştirilmiştir. Bu süreçte, farklı "n_estimators", "learning_rate", "max_depth", "subsample" ve "colsample_bytree" kombinasyonları denenmiş ve 5 katlı çapraz doğrulama kullanılarak modelin genel tahmin başarısını en üst seviyeye çıkaran parametreler belirlenmiştir. Bu işlem sırasında GridSearchCV'ye ait "n_jobs" parametresi "-1" olarak ayarlanarak, tüm işlemcilerin paralel olarak çalışması sağlanmış ve arama süreci hızlandırılmıştır. Böylece, XGB modelinin çeşitli veri bölümlerindeki tahmin doğruluğu optimize edilmiştir. XGB modelinde, GridSearchCV ile hiperparametre ayarlama işlemi için kullanılan Python kodu Resim 5.19'da sunulmuştur.

```
# Gerekli kütüphanelerin içeri aktarılması
from sklearn.model_selection import GridSearchCV

# XGBoost hiperparametre gridleri
xgb_params = {
    'n_estimators': [10, 50, 100, 200, 500],
    'learning_rate': [0.01, 0.05, 0.1, 0.2, 0.3],
    'max_depth': [3, 5, 7, 10],
    'subsample': [0.7, 0.85, 1.0],
    'colsample_bytree': [0.7, 0.85, 1.0]
}

# GridSearchCV ile XGB modeli için en iyi hiperparametrelerin bulunması
xgb_grid = GridSearchCV(XGBRegressor(random_state=42), xgb_params, cv=5, scoring='r2', n_jobs=-1)
xgb_grid.fit(X_train, y_train)

# En iyi hiperparametreleri içeren tahminci için model nesnesi oluşturulması
best_xgb = xgb_grid.best_estimator_

# Modelin eğitilmesi
best_xgb.fit(X_train, y_train)
```

Resim 5.19. XGB modelinde GridSearchCV kullanımı

XGB modeli için hiperparametre ayarlama işlemi sonucunda ortaya çıkan en iyi hiperparametre kombinasyonunu görmek için kullanılan Python kodu ve bu kodun çalıştırılmasıyla ortaya çıkan sonuç, Resim 5.20'de sunulmuştur.


```
xgb_grid.best_params_
{'colsample_bytree': 1.0,
 'learning_rate': 0.2,
 'max_depth': 3,
 'n_estimators': 50,
 'subsample': 1.0}
```

Resim 5.20. XGB bölümü için en iyi hiperparametreleri çağırma kodu ve cevap satırı

5.7.3. XGB modeli sonuçları

XGB modeli, önceki bölümde GridSearchCV sınıfı kullanılarak belirlenen en uygun hiperparametre kombinasyonları ile eğitilmiştir. Eğitim süreci tamamlandıktan sonra, modelin tahmin performansını değerlendirmek üzere test verileri üzerinde uygulanmaya hazır hâle getirilmiştir.

XGB modelinin tahmin sonuçları, test verileri üzerinde yapılan maliyet tahminleri ile gerçek maliyet değerlerinin karşılaştırıldığı grafik Şekil 5.17’de sunulmuştur. Bu grafikte, XGB modelinin projeler üzerindeki tahmin performansı detaylı olarak incelenmiştir. Modelin farklı projelerdeki tahmin doğruluğu ve sapmaları bu grafik yardımıyla daha belirgin bir şekilde gözlemlenmiştir.




Şekil 5.17. XGB modeli gerçek ve tahmin edilen maliyetlerin karşılaştırılması

Şekil 5.17’de verilen grafik incelendiğinde, XGB modelinin en dengeli maliyet tahmin performansına sahip olduğu açıkça görülmektedir. Çoğu proje için modelin tahminlerinin gerçek maliyetlere oldukça yakın olduğu dikkat çekmektedir. Bu sonuçlar, XGB modelinin DGBH proje maliyet tahmininde yüksek doğruluk sağlayabilecek potansiyelde olduğunu

ortaya koymaktadır. Özellikle en fazla 50 M\$ gerçekleşme maliyetine sahip olan projelerin neredeyse tamamında gerçeğe oldukça yakın tahminler yapıldığı açıkça görülmektedir. RF modelinde olduğu gibi XGB modelinde de 22 numaralı proje özelinde oldukça yüksek bir tahmin hatası gerçekleşmiştir. Modelin diğer gözlemlerde elde ettiği tahmin başarısı göz önünde bulundurulduğunda 22'inci proje sürecinde, algoritmaların yakalayamadığı farklı inşai ve/veya süreç problemlerinin gerçekleşmiş olabileceği değerlendirilmiştir.

Bu analiz, XGB modelinin oldukça başarılı tahminler yaptığını ve sınırlı sapma miktarlarına sahip olduğunu göstermektedir. Tahmin performansının daha detaylı incelenmesi için modelin tahmin hatalarının görselleştirildiği kalıntı grafiği Şekil 5.18'de sunulmuştur.



Şekil 5.18. XGB modeli tahmin edilen maliyet ve hatalar

Şekil 5.17 ve Şekil 5.18 birlikte değerlendirildiğinde ortaya şu sonuçlar çıkmıştır;

- 5 proje haricinde kalan tüm tahminler yaklaşık olarak -5 M\$ ila +3 M\$ aralığında tahmin hatalarına sahiptir.
- 7 adet projenin tahmininde ± 1 M\$ tahmin hatası gözlemlenmiştir.

- Yalnızca iki proje özelinde 60 M\$ dolardan yüksek tahmin hataları ortaya çıkmıştır.
- Modelde 60 M\$'dan daha yüksek hata ile tahmin edilen 2 adet proje bulunmaktadır. Bunlardan birinde model gerçek maliyete göre daha yüksek, diğerinde ise gerçek maliyete göre daha düşük tahmin performansı göstermiştir.

Bu bulgular neticesinde XGB modelinin diğer modellere kıyasla daha kararlı ve düşük hata miktarları ile tahmin performansı gösterdiği söylenebilir. Bu analizlerden hareketle, modelin hiperparametre ayarlama işlemi sonrası elde edilen tahmin performansı ve başarı metriklerine dayalı daha kapsamlı değerlendirmeler yapılabilir. XGB modelinde hiperparametre ayarlama işlemi sonrası başarı parametrelerinin değerlerini elde etmek amacıyla yazılan kod Resim 5.21'de sunulmuştur.

```
# Tune sonrası tahmin yapılması
y_train_pred_AT = best_xgb.predict(X_train)
y_test_pred_AT = best_xgb.predict(X_test)

# Tune sonrası model başarı metriklerinin hesaplanması (AT: After Tuning)
r2_train_AT, rmse_train_AT, mae_train_AT, mape_train_AT = calculate_metrics(y_train, y_train_pred_AT)
r2_test_AT, rmse_test_AT, mae_test_AT, mape_test_AT = calculate_metrics(y_test, y_test_pred_AT)
```

Resim 5.21. XGB modelinde hiperparametre ayarlama işlemi sonrası başarı metriklerinin hesaplanması

XGB model sonucunda elde edilen başarı metriklerinin aldığı değerler Çizelge 5.11'de sunulmuştur.

Çizelge 5.11. XGB model başarı metrikleri (hiperparametre ayarlama işlemi sonrası)


Başarı parametresi	Sonuç
R ² (eğitim)	1,00
RMSE (eğitim)	3 160 671,28
MAE (eğitim)	2 075 899,48
MAPE (eğitim)	17,15
R ² (test)	0,89
RMSE (test)	23 472 275,50
MAE (test)	10 240 110,15
MAPE (test)	34,95

Çizelge 5.11’de yer alan başarı metrikleri, test veri seti özelinde XGB modelinin $R^2 = 0,89$ değerine ulaştığını göstermektedir. Bu değer, RF modelinde elde edilen 0,83’lük R^2 değerinden yüksektir ve XGB modelinin bağımsız değişkenler yardımıyla maliyet değişkenliğini %89 oranında açıklayabildiğini göstermektedir. Mühendislik projeleri bağlamında, bu oranın oldukça iyi bir tahmin performansına işaret ettiği söylenebilir.

XGB modelinin RMSE_test değeri yaklaşık olarak 23,5 M\$ olarak hesaplanmıştır ve önceki bölümlerde ele alınan algoritmalarla kıyaslandığında en düşük hata oranını sağlamıştır. Bu sonuç, XGB modelinin tahmin performansında diğer modellere kıyasla daha yüksek doğruluk sunduğunu göstermektedir.

MAE ve MAPE metrikleri incelendiğinde, XGB modelinin performansının oldukça başarılı olduğu, ancak düşük maliyetli projelerde yer yer daha düşük hata oranları sunan modellerin de mevcut olduğu görülmektedir.

XGB modeli maliyet tahminlerini eğitim sırasında kademeli olarak “hataları düzeltme” prensibiyle hareket ederek oluşturduğu ağaç yapılarına dayalı olarak gerçekleştirmektedir. Bu nedenle, ÇDR ve ER modellerindeki gibi sabit bir matematiksel denklem sunulması mümkün olmamıştır. Ancak, modelin tahmin performansı, başarı metrikleri ve grafikler yardımıyla detaylı olarak değerlendirilmiştir. Ayrıca XGB ağaç yapısını temsilen 50 farklı karar ağacının 1’inci ağacını temsil eden karar ağacı Şekil 5.19’da sunulmuştur.



Şekil 5.19. XGB modeli için örnek bir karar ağacı (1 numaralı ağaç)

XGB modeli için oluşturulan ve Şekil 5.19’da sunulan karar ağacı, bağımsız değişkenlerin modelin tahmin sürecindeki etkilerini görselleştiren ve modelin karar alma mekanizmasını açıklayan bir yapıdır. XGBoost kütüphanesi alt sınıfları kullanılarak oluşturulmuş olan ağaç yapısı, bu algoritmaya özgü görselleştirme özellikleri ile RF karar ağacından farklı bir yapıda sunulmuştur. XGB, ardışık şekilde inşa edilen karar ağaçlarıyla önceki ağaçların hatalarını minimize etmeyi hedefler ve bu nedenle karar alma süreçlerinde yüksek performans ve doğruluk sunar.

Kök düğüm, modelin ilk ayrımını gerçekleştirdiği noktadır. Şekil 5.19’daki XGB karar ağacında kök düğüm, hat vanalarının sayısını temsil eden "line_valve" değişkenine dayalı bir ayrım yapmaktadır. Bu düğümde, hat vanalarının sayısının 9’dan küçük olup olmadığına göre veri kümesi iki gruba ayrılmaktadır.

Alt düğümler, modelin daha detaylı ayrımlar yaptığı ve bağımsız değişkenlerin etkilerini daha spesifik olarak analiz ettiği düğümlerdir. Örneğin;

- "diameter < 33.57" düğümünde, boru çapı değişkenine göre bir ayrım yapılmış ve veriler iki gruba bölünmüştür.
- Diğer bir alt düğümde, boru hattı uzunluğunun (length) 80.46 değerine göre alt gruplara ayrıldığı gözlemlenmektedir.

Yaprak düğümler, modelin tahmin sonuçlarını ürettiği son noktaları temsil eder. Bu düğümlerde, tahmin edilen maliyet değerleri "leaf" ile ifade edilmiştir. Ayrıca, XGB'nin karar yapısında, eksik veri durumlarının nasıl ele alındığını gösteren görselleştirmeler, bu yapının RF’den farklı olan yönlerinden biridir. Örneğin, "leaf = -5843404.5" düğümü, belirli kriterlere göre verilerin ayrıldığı ve tahmin edilen maliyet değerinin sağlandığı bir yaprak düğümdür.

Genel olarak XGB modelinin başarısı değerlendirildiğinde, doğrusal modeller olan ÇDR ve ER’ye göre oldukça iyi sonuçlar gözlemlenmektedir. XGB modeli, RF modelinden farklı olarak hataları minimize etmeye odaklanan ardışık yapısı sayesinde doğruluk oranlarını artırmayı başarmıştır. Bununla birlikte, XGB’nin geniş hiperparametre yelpazesi ve güçlü öğrenme kapasitesi, özellikle karmaşık ve doğrusal olmayan veri ilişkilerinde etkin bir performans sergilemesine olanak tanımaktadır. Ayrıca, XGB modelinin tahmin sonuçları, 6.

bölümde açıklanan dijital tahmin platformu üzerinden erişilebilir hale getirilmiştir. Bu platform üzerinden XGB modelinin tahmin sonuçları, kullanıcılar tarafından karşılaştırmalı olarak değerlendirilebilmektedir. XGB modeli, esnek yapısı ve ardışık öğrenme yöntemiyle doğrusal olmayan yapılar için etkili bir çözüm sunmaktadır.

Özellikle düşük maliyetli projelerde daha hassas tahminler yapılmasına olanak tanıyan modellerde bu metrikler daha düşük seviyelerde hesaplanmış olsa da XGB, veri setinin genel yapısına yüksek uyum sağlayarak geniş bir maliyet aralığında dengeli bir performans sunmaktadır. Bu durum, XGB'nin karmaşık veri yapılarına uyum sağlama kapasitesinin güçlü olduğunu göstermektedir.


5.8. Model Sonuçlarının Karşılaştırılması ve Dijital Tahmin Platformu

Bu bölümde, beş farklı makine öğrenmesi modelinin maliyet tahmini performanslarının karşılaştırmalı analizi sunulmuştur. Çalışmada kullanılan doğrusal ve doğrusal olmayan algoritmaların test veri seti üzerindeki tahmin doğrulukları, hata oranları ve genel başarıları, grafik ve tablolar eşliğinde değerlendirilmiştir. Ayrıca, ÇDR ve ER modellerinde, tahmin işlemleri, modellerin sabit matematiksel denklemleri sayesinde kullanıcıların ellerindeki parametrelerle kolayca hesaplanabilmektedir. Ancak, KNN, RF ve XGB modellerinde sabit bir matematiksel denklem bulunmadığı için, benzer bir tahmin imkânı sağlamak amacıyla bu üç modelin sonuçlarını kullanıcıların erişimine açık hâle getiren dijital tahmin platformu geliştirilmiştir. Bu platform, kullanıcıların bağımsız değişkenlere dayalı olarak maliyet tahminlerini interaktif bir şekilde gerçekleştirebilmesine olanak tanıyarak, yapılan çalışmayı daha erişilebilir hale getirmeyi hedeflemektedir.

5.8.1. Maliyet tahminlerinin karşılaştırılması

Maliyet tahmini üzerine geliştirilen modellerin performanslarını değerlendirmek, modellerin farklı durumlara nasıl tepki verdiğini anlamak ve projelerdeki tahmin başarısını analiz etmek için her modelin gerçek maliyet değerleri ile tahmin edilen değerleri önceki bölümlerde görselleştirilmiştir. Grafiksel analiz, modellerin düşük, orta ve yüksek maliyetli projelerdeki tahmin doğruluğunu kıyaslamada etkili bir araç sunmaktadır. Ayrıca, test veri seti üzerinde tahmin edilen maliyetlerin, özellikle sapmaların ve tutarlılık düzeylerinin incelenmesi, her modelin avantajlarını ve sınırlamalarını belirlemeye olanak tanımaktadır. Bu kapsamda

oluşturulan, her bir modelin proje bazında tahmin ettiği maliyet değerleri ile gerçek maliyet değerlerini aynı grafikte karşılaştırmalı olarak ortaya koyan görsel Şekil 5.20’de sunulmuştur.



Şekil 5.20. Tüm modeller gerçek ve tahmin edilen maliyetlerin karşılaştırılması

Şekil 5.20’de paylaşılan grafik, özellikle doğrusal olmayan modellerin (KNN, RF ve XGB) düşük ve orta maliyetli projelerde gösterdiği yüksek başarıyı ortaya koyarken, doğrusal modellerin (ÇDR ve ER) daha sınırlı doğrulukta performans sergilediğini açık bir şekilde göstermektedir. 1, 15 ve 22 numaralı projelerde farklı algoritmaların düşük kalıntılar ile tahmin yapmakta zorlandığı görülmüştür. Ayrıca bütün projelerde farklı algoritmaların gerçek proje tamamlanma maliyetinden daha yüksek veya düşük tahminler gerçekleştirdiği bir ortamda 15 numaralı proje özelinde hiçbir algoritma gerçek maliyet değerinden daha yüksek bir tahmin gerçekleştirememiştir.

Veri seti incelendiğinde 15 numaralı projenin, tez kapsamında verilerine erişilebilmiş en eski proje olduğu görülmüştür. Boru çapı 48 inç olan, hat uzunluğu yaklaşık 291 km olan ve hat boyunca toplamda 10 hat vanası, 4 take-off vanası ve 2 pig istasyonu tesis edilen bu projenin hacmi düşünüldüğünde, algoritmaların yakalayamayacağı/eşleşemeyeceği düzeyde inşaat süreçlerine tâbi olmuş olabileceği değerlendirilmektedir.

5.8.2. Performans başarı metriklerinin karşılaştırılması

Bu çalışmada kullanılan farklı makine öğrenmesi modellerinin tahmin performansları, doğruluk, hata oranları ve genel başarı metrikleri açısından karşılaştırılmıştır. Modellerin eğitim ve test veri setleri üzerindeki performansları, özellikle test verisi üzerindeki R^2 ve RMSE değerleri vurgulanarak analiz edilmiştir. R^2 , modelin bağımlı değişken üzerindeki varyansı ne kadar iyi açıkladığını gösterirken, RMSE modelin tahminleri ile gerçek değerler arasındaki ortalama hatayı ölçmektedir ve bu nedenle test verisinde kritik bir öneme sahiptir. Bunun yanı sıra MAE ve MAPE gibi diğer metrikler de bilgi amaçlı sunulmuş olup, model performansını tamamlayıcı nitelikte değerlendirilmiştir. Bu kapsamda, modellerin başarı metrikleri Çizelge 5.12’de sunulmuştur.

Çizelge 5.12. Tüm modellerin başarı metrikleri (hiperparametre ayarlama işlemi sonrası)

Başarı parametresi	ÇDR	ER	KNN	RF	XGB
R^2 (eğitim)	0,75	0,71	1,00	0,78	1,00
RMSE (eğitim)	40 091 313,32	43 448 801,92	0,00	38 177 899,02	3 160 671,28
MAE (eğitim)	24 707 889,55	26 931 265,38	0,00	11 162 007,35	2 075 899,48
MAPE (eğitim)	373,39	434,40	0,00	41,78	17,15
R^2 (test)	0,61	0,74	0,82	0,83	0,89
RMSE (test)	43 370 642,30	35 228 240,74	29 218 117,97	28 318 044,95	23 472 275,50
MAE (test)	30 486 681,79	23 334 860,30	9 967 553,86	12 536 326,16	10 240 110,15
MAPE (test)	335,94	314,74	23,65	41,24	34,95

Test verisi üzerinde R^2 ve RMSE sonuçları, modellerin performansını değerlendirmede temel kriterler olarak öne çıkmaktadır. Bu bağlamda, XGB modeli, $R^2 = 0,89$ ve RMSE = 23 472 275,50 \$ ile en iyi performansı sergileyen model olarak dikkat çekmektedir. XGB'nin test verisi üzerindeki yüksek R^2 değeri, bağımlı değişkenin varyansını %89 oranında doğru bir şekilde açıklayabildiğini göstermektedir. Bununla birlikte, RMSE değerinin diğer modellere göre düşük olması, modelin tahmin edilen değerlerle gerçek değerler arasında minimal sapma ürettiğini ortaya koymaktadır.

RF modeli ise test verisi üzerinde $R^2 = 0,83$ ve RMSE = 28 318 044,95 \$ değerleriyle ikinci sırada yer almaktadır. Bu sonuçlar, RF'nin tahmin performansında oldukça güçlü bir model olduğunu, ancak XGB kadar yüksek doğruluk sağlayamadığını göstermektedir. RF'nin bu

performansı, özellikle doğrusal olmayan ve karmaşık ilişkileri yakalama kapasitesiyle ilişkilendirilebilir.

KNN modeli de $R^2 = 0,82$ ve $RMSE = 29\ 218\ 117,97$ \$ ile tatmin edici bir performans sergilemektedir. Ancak, KNN'nin daha küçük veri kümelerine daha iyi uyum sağladığı ve büyük veri setlerinde performansının sınırlı kalabileceği dikkate alınmalıdır.

Doğrusal modellerden ÇDR ve ER, test verisi üzerindeki R^2 ve RMSE değerleriyle diğer modellerin gerisinde kalmıştır. Özellikle ÇDR'nin $R^2 = 0,61$ ve $RMSE = 43\ 370\ 642,30$ \$ değerleri, modelin bağımlı değişkenin varyansını açıklama kapasitesinin sınırlı olduğunu ortaya koymaktadır. Benzer şekilde, ER modeli de $R^2 = 0,74$ ve $RMSE = 35\ 228\ 240,74$ \$ ile nispeten düşük bir doğruluk sergilemiştir. Bu durum, doğrusal modellerin karmaşık veri yapılarında ve doğrusal olmayan ilişkilerde sınırlı kalabileceğini göstermektedir.

Genel olarak, XGB ve RF gibi doğrusal olmayan modellerin test verisi üzerinde daha üstün performans sergilediği görülmüştür. Bu modeller, özellikle maliyet varyansının yüksek olduğu projelerde daha güvenilir tahminler sunma potansiyeline sahiptir. ÇDR ve ER ise, daha basit ilişkileri içeren veri setlerinde daha uygun sonuçlar verebilecek doğrusal modeller olarak nitelendirilebilir..

5.8.3. Dijital tahmin platformu

Makine öğrenmesi modellerinin tahmin sonuçlarını erişilebilir kılmak amacıyla geliştirilen dijital tahmin platformu, kullanıcıların bağımsız değişkenlere dayalı olarak maliyet tahminlerini interaktif bir şekilde gerçekleştirmesine olanak tanıyan bir internet adresidir. Platform, <https://pipelinecostestimator-production.up.railway.app/> adıyla çevrimiçi olarak erişime açıktır ve özellikle sabit matematiksel denklemleri bulunmayan KNN, RF ve XGB modelleri için kullanıcıların tahmin hesaplamalarını yapmalarına imkân sağlamaktadır.

Platform, basit bir ara yüz sunmaktadır. Kullanıcılar, aşağıdaki değişkenleri girerek tahmin sonuçlarını hızlı bir şekilde elde edebilirler;

- Boru Çapı (Pipe Diameter - inches): Borunun çapı inç cinsinden girilir.

- Boru Hattı Uzunluğu (Pipeline Length - km): Borunun uzunluğu kilometre cinsinden belirtilir.
- Hat Vanaları Sayısı (Number of Line Valves): Boru hattındaki vana sayısı girilir.
- Take-off vana sayısı (Number of Take-Off Valves): Take-off vana sayısı belirtilir.
- Pig İstasyonları Sayısı (Number of Pigging Stations): Pig istasyonlarının toplam sayısı girilir.

Platform, girdi değerlerine göre KNN, RF ve XGB modelleri için tahmin edilen maliyet değerlerini ve bu değerlerin belirsizlik aralıklarını (MAPE) ekranda kullanıcıya sunmaktadır. Platformun ara yüzü ve örnek bir girdi ile ortaya çıkan sonuç ekranı Resim 5.22’de sunulmuştur.

Pipeline Cost Estimator

Pipe Diameter (inches):

Pipeline Length (km):

Number of Line Valves:

Number of Take-Off Valves:

Number of Pigging Stations:

Tahmin Sonuçları:

Random Forest Tahmini: 12484185.16 \$ ($\pm$ %41.24) (7335695.91 - 17632674.41)

XGBoost Tahmini: 10407213.00 \$ ($\pm$ %34.95) (6770169.39 - 14044256.61)

KNN Tahmini: 9243987.90 \$ ($\pm$ %23.65) (7057763.77 - 11430212.03)

Resim 5.22. Dijital tahmin platformu örnek sonuç çıktısı

Resim 5.22’de gösterilen örnek girdi sonuçlarına göre proje bilgileri;

- Boru çapı = 16 inç,
- Hat uzunluğu = 57,65 km,
- Hat vanası sayısı = 3 adet

- Take-off vanası sayısı = 1 adet
- Pig istasyonu sayısı = 2 adet

olan bir DGBH için maliyet tahmin değerleri dijital tahmin platformu aracılığıyla hesaplanmıştır. Verilen değerler ile yapılan tahminlerde;

- RF → 12 484 185,16 \$,
- XGB → 10 407 213,00 \$,
- KNN → 9 243 987,90 \$

sonuçlarına ulaşılmıştır. Ayrıca tahminlerin belirsizlik aralıkları da bilgi amacıyla tahmin değerlerinin hemen yanında kullanıcının bilgisine sunulmaktadır.

6. SONUÇ VE ÖNERİLER

Bu çalışmada DGBH proje maliyetlerinin ön tahmini için farklı algoritmalar üzerinden modeller üretilmiştir. Bu kapsamda ülke sınırları içerisinde yapımı ve/veya ihale süreci tamamlanmış 113 adet DGBH projesi incelenmiştir. Bu projelerden yola çıkılarak doğrusal model denemeleri ile maliyet tahmin süreci planlanmıştır. ÇDR ve ER ile oluşturulan model denklemlerinin ardından KNN, RF ve XGB gibi doğrusal olmayan, ağaç tabanlı ve topluluk öğrenme algoritmaları ile modeller oluşturulmuş ve bu modeller ile yapılan tahmin sonuçlarının elde edilebilmesi için internet tabanlı bir dijital tahmin platformu geliştirilmiştir.

Çalışma sonucunda, XGB modeli $R^2 = 0,89$ belirleme katsayısı ve $RMSE = 23\ 472\ 275,50$ değeri ile diğer algoritmalara kıyasla daha dengeli sonuçlar vererek en yüksek tahmin doğruluğunu sağlamıştır. KNN ve RF modelleri ise sırasıyla $R^2 = 0,82$ ve $R^2 = 0,83$; $RMSE = 29\ 218\ 117,97$ ve $RMSE = 28\ 318\ 044,95$ değerleri ile görece başarılı sonuçlar ortaya koymuşlardır. Bu iki model, yüksek maliyetli projelerde daha yüksek hata oranları ile dikkat çekerken, genel olarak doğrusal olmayan algoritmaların doğrusal modellere göre daha üstün tahmin performansı gösterdiği tespit edilmiştir.

Çalışma kapsamında yapılan analizler doğrultusunda aşağıdaki sonuçlar elde edilmiştir:

1. XGB modeli, R^2 ve RMSE metriklerinde en iyi performansı göstererek diğer algoritmalarından daha üstün bir tahmin doğruluğu sağlamıştır.
2. Doğrusal modeller olan ÇDR ve ER, basit maliyet yapılarını açıklamada kısmen yeterli performans gösterse de, yüksek bütçeli projelerde doğrusal olmayan modeller kadar başarılı olamamıştır.
3. Ağaç tabanlı ve topluluk öğrenme algoritmalarının, veri setindeki karmaşık ve doğrusal olmayan ilişkileri yakalamada daha etkili olduğu gözlemlenmiştir.
4. Modellerin sunduğu tahmin performansları, DGBH projelerinin bütçelendirme ve maliyet yönetimi süreçlerine önemli katkılar sağlayabilir.
5. Henüz detaylı uygulama projelerinin hazır olmadığı aşamalarda bile, özellikle XGB modeli ile güvenilir maliyet tahminlerinin yapılabileceği değerlendirilmektedir.

Yapılmış olan çalışmaya ek olarak ileride aşağıda belirtilen çalışmaların gerçekleştirilmesi önerilmektedir:

- Daha çeşitli ve geniş veri setleri kullanılarak, modellerin genelleme kapasitesi artırılabilir.
- Projelerin coğrafi, çevresel ve sosyo-ekonomik parametreleri gibi ek değişkenlerin modele dâhil edilmesi, tahmin doğruluğunu artırabilir.
- Çalışmanın farklı algoritmalarla tekrarlanması ve yeni parametrelerin eklenmesi, mevcut sonuçların sağlamlaştırılmasına yardımcı olabilir.

KAYNAKLAR

1. Etienne, C., Furukawa, T., Molnár, G. ve Frederick, R. (2024). Gas market report, q1-2024. IEA. Paris, 1-88.
2. Langenbrunner, B. (2023). Global gas pipeline expansion : nearly us \$ 200 billion under construction, with asia building over 80%. GEM. California, 1-18.
3. Özmaden, M. Ş. ve Erdal, M. (2020). Konut yapılarının maliyet tahmininde kullanılan yöntemlerin performans analizi. *Konya Mühendislik Bilimleri Dergisi*, 8(4), 970–985.
4. Agyekum, B., Kissi, E., Yamoah Agyemang, D. ve Badu, E. (2018). Examining barriers for the utilization of non-traditional cost estimating models in developing countries. *Journal of Engineering, Design and Technology*, 16(6), 814–827.
5. Fazil, M. W., Lee, C. K. ve Tamyez, M. F. P. (2021). Cost estimation performance in the construction projects: a systematic review and future directions. *International Journal of Industrial Management*, 11(1), 217–234.
6. Chan, S. L. ve Park, M. (2005). Project cost estimation using principal component regression. *Construction Management and Economics*, 23(3), 295–304.
7. Mahamid, I. (2015). Factors affecting cost estimate accuracy: evidence from palestinian construction projects. *International Journal of Management Science and Engineering Management*, 10(2), 117–125.
8. Arif, F., Lodi, S. H. ve Azhar, N. (2015). Factors influencing accuracy of construction project cost estimates in pakistan: perception and reality. *International Journal of Construction Management*, 15(1), 59–70.
9. Zhang, S., Li, X., Zong, M., Zhu, X. ve Wang, R. (2018). Efficient knn classification with different numbers of nearest neighbors. *IEEE Transactions on Neural Networks and Learning Systems*, 29(5), 1774–1785.
10. Swei, O., Gregory, J. ve Kirchain, R. (2017). Construction cost estimation: a parametric approach for better estimates of expected cost and variation. *Transportation Research Part B: Methodological*, 101 295–305.
11. Doloi, H. K. (2011). Understanding stakeholders' perspective of cost estimation in project management. *International Journal of Project Management*, 29(5), 622–636.
12. Akintoye, A. (2000). Analysis of factors influencing project cost estimating practice. *Construction Management and Economics*, 18(1), 77–89.
13. Sridarran, P., Keraminiyage, K. ve Herszon, L. (2017). Improving the cost estimates of complex projects in the project-based industries. *Built Environment Project and Asset Management*, 7(2), 173–184.

14. Tayefeh Hashemi, S., Ebadati, O. M. ve Kaur, H. (2020). Cost estimation and prediction in construction projects: a systematic review on machine learning techniques. *SN Applied Sciences*, 2(10), 1–27.
15. Ugur, L. O. *et al.* (2019). Enhanced predictive models for construction costs: a case study of turkish mass housing sector. *Computational Economics*, 53(4), 1403–1419.
16. Kim, G. H., An, S. H. ve Kang, K. I. (2004). Comparison of construction cost estimating models based on regression analysis, neural networks, and case-based reasoning. *Building and Environment*, 39(10), 1235–1242.
17. Khalaf, T. Z., Çağlar, H., Çağlar, A. ve Hanoon, A. N. (2020). Particle swarm optimization based approach for estimation of costs and duration of construction projects. *Civil Engineering Journal (Iran)*, 6(2), 384–401.
18. Zhao, J. (2000). Interim report ir-00-054 diffusion, costs and learning in the development of international gas transmission lines. IIASA. Laxenburg, 1-29.
19. Parker, N. C. (2004). Using natural gas transmission pipeline costs to estimate hydrogen pipeline costs. UC ITS. California, 1-87.
20. Yılmaz, N. F. (2005). Petrol ve doğal gaz boru hatları üzerine genel bir değerlendirme. *Tesisat Mühendisliği Dergisi*, 87 4–14.
21. Rui, Z., Metz, P. A., Reynolds, D. B., Chen, G. ve Zhou, X. (2011). Regression models estimate pipeline construction costs. *Oil and Gas Journal*, 109(14), 120–127.
22. Rui, Z., Metz, P. A., Reynolds, D. B., Chen, G. ve Zhou, X. (2011). Historical pipeline construction cost analysis. *International Journal of Oil, Gas and Coal Technology*, 4(3), 244–263.
23. Rui, Z., Metz, P. A. ve Chen, G. (2012). An analysis of inaccuracy in pipeline construction cost estimation. *International Journal of Oil, Gas and Coal Technology*, 5(1), 29–46.
24. Rui, Z., Metz, P., Wang, X., Chen, G., Zhou, X. ve Reynolds, D. (2012). *Inaccuracy in Pipeline Compressor Station Construction Cost Estimation*, SPE Annual Technical Conference and Exhibition, Texas, 4219–4234.
25. Thaduri, R. K. (2012). *Oil and gas pipeline construction cost analysis and developing regression models for cost estimation*. Yüksek Lisans Tezi, Texas A&M University Chemical Engineering, Texas.
26. Bai, B., Li, X. ve Yuan, Y. (2013). A new cost estimate methodology for onshore pipeline transport of co 2 in china selection and/or peer-review under responsibility of ghgt. *Energy Procedia*, 37, 7633–7638.
27. Matthews, J. C., Allouche, E. N. ve Sterling, R. L. (2015). Social cost impact assessment of pipeline infrastructure projects. *Environmental Impact Assessment Review*, 50, 196–202.

28. Tayefeh Hashemi, S., Ebadati, O. M. ve Kaur, H. (2020). Cost estimation and prediction in construction projects: a systematic review on machine learning techniques. *SN Applied Sciences*, 2(10), 1–27.
29. Kaiser, M. J. (2021). A review of onshore and offshore pipeline construction and decommissioning cost in the usa - part 1: specifications, cost estimation and onshore construction. *International Journal of Oil, Gas and Coal Technology*, 27(3), 247–285.
30. Erdal, H., *Prediction of pipeline projects construction costs utilizing machine learning techniques*, International Marmara Sciences Congress (Spring 2021) Proceedings E-Book, Kocaeli, 218–223.
31. Sueri, M. ve Erdal, M. (2022). Early estimation of sewerage line costs with regression analysis. *Gazi University Journal of Science*, 35(3), 822–832.
32. Elhegazy, H., Chakraborty, D., Elzarka, H., Ebid, A. M., Mahdi, I. M., Aboul Haggag, S. Y. ve Abdel Rashid, I. (2022). Artificial intelligence for developing accurate preliminary cost estimates for composite flooring systems of multi-storey buildings. *Journal of Asian Architecture and Building Engineering*, 21(1), 120-132.
33. Zou, C., Zhao, Q., Zhang, G. ve Xiong, B. (2016). Energy revolution: from a fossil energy era to a new energy era. *Natural Gas Industry B*, 3(1), 1–11.
34. Erkan, A. Ç. (2013). *Enerji arzı güvenliği bakımından Avrupa'nın Rusya Federasyonu'na bağımlılığı*. Yüksek Lisans Tezi. Adnan Menderes Üniversitesi Sosyal Bilimler Enstitüsü, Aydın.
35. İnternet: BOTAŞ. (2024). Doğal gaz. Web: <https://www.botas.gov.tr/Sayfa/dogalgaz/12> Son Erişim Tarihi: 17.11.2024.
36. İnternet: BOTAŞ. (2024). Doğalgaz ve petrol boru hatları haritası. Web: <https://enerji.gov.tr/bilgi-merkezi-haritalar> Son Erişim tarihi: 10.06.2024.
37. Folga, S. M. (2007). Natural gas pipeline technology overview. *ANL*. Illinois, 1-55.
38. İnternet: HyNet North West Hydrogen Pipeline. (2024). The construction process. Web: <https://www.hynethydrogenpipeline.co.uk/dco-project/the-construction-process/> Son Erişim Tarihi: 17/11/2024.
39. İnternet: Vemak İnşaat. (2024). Manavgat - Alanya - Gazipaşa - Anamur ilçeleri faz-1 doğal gaz boru hattı projesi. Web: <https://www.youtube.com/watch?v=BlHpUdGGMvQ>. Son Erişim Tarihi: 17.11.2024.
40. Sharma, S. K. ve Maheshwari, S. (2017). A review on welding of high strength oil and gas pipeline steels. *Journal of Natural Gas Science and Engineering*, 38, 203–217.

41. Di Luch, A. C. ve Oyarzábal, N. Di Luch, A. *Structural Integrity of Pipelines BT. Proceedings of the 3rd Pan American Materials Congress*, Cham, 297–304.
42. Adin, H., Doğan, A. ve Adin, M. Ş. (2021). Şehir içi doğalgaz borularındaki kaynak hatalarının tahribatsız ve tahribatlı muayene yöntemleri ile incelenmesi. *Journal of Science, Technology and Engineering Research*, 2(1), 46–57.
43. Yılmaz, V. (2020). *Yüksek basınçlı bir doğal gaz boru hattı montajında iş güvenliği bakımından risk değerlendirmesi*. Yüksek Lisans Tezi, Çukurova Üniversitesi Fen Bilimleri Enstitüsü, Adana.
44. Gülensoy, B. A. (2006). *Doğalgaz boru hatlarında uygulanan korozyon tedbirleri ve kayseri doğalgaz hatlarındaki uygulamaların incelenmesi*. Yüksek Lisans Tezi, Erciyes Üniversitesi Fen Bilimleri Enstitüsü, Kayseri.
45. Wininger, G. A. (2011). Pipeline construction. *Pipeline Planning and Construction Field Manual*, 341–355.
46. Bahadori, A. (2017). Construction guidelines for onshore transportation pipelines applications. *Oil and Gas Pipelines and Piping Systems*, 29–64.
47. İnternet: BOTAŞ. (2024). BOTAŞ canlı sözlük. Web: <https://www.botas.gov.tr/Sozluk?Kelime=658> Son Erişim Tarihi: 05.06.2024.
48. Boskin, M. J., Dulberger, E. R., Gordon, R. J., Griliches, Z. ve Jorgenson, D. W. (1998). Consumer prices, the consumer price index, and the cost of living. *Journal of Economic Perspectives*, 12(1), 3–26.
49. İnternet: Türkiye Cumhuriyet Merkez Bankası. (2024). Elektronik veri dağıtım sistemi. Web: https://evds2.tcmb.gov.tr/index.php?/evds/serieMarket/#collapse_2 Son Erişim Tarihi: 01.12.2024.
50. Draper, N. ve Smith, H. (1998). *Applied regression analysis* (3. Baskı). New Jersey: John Wiley & Sons, 15-46.
51. Wang, W., & Lu, Y. (2018). *Analysis of the mean absolute error (MAE) and the root mean square error (RMSE) in assessing rounding model*. IOP conference series: materials science and engineering IOP Publishing, Kuala Lumpur, 1-11.
52. Kanit, R., ve Baykan U. N. (2004). Bina yaklaşık maliyetinin çoklu doğrusal regresyon ile belirlenmesi. *Journal of Polytechnic*, 7(4), 359–369.
53. Vergili, M., & Orhan, H. (2022). Genomik veri setlerinin lasso ve elastik net regresyon yöntemleri ile analizi. *Süleyman Demirel Üniversitesi Sağlık Bilimleri Dergisi*, 13(3), 485-496.
54. Bentley, J. L. (1975). Multidimensional binary search trees used for associative searching. *Communications of the ACM*, 18(9), 509–517.

55. Ho, T. K. (1995). *Random decision forests*. Proceedings of 3rd International Conference on Document Analysis and Recognition, Montreal, 278–282.
56. Chen, T. ve Guestrin, C. (2016). *XGBoost: A Scalable Tree Boosting System*, Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, New York, 785–794.
57. Van Rossum, G. ve Drake, F. L. (2009) *Introduction To Python 3: Python Documentation Manual Part 1*. Kaliforniya: CreateSpace Scotts Valley, 1-264.
58. Oliphant, T. E. (2007). Python for scientific computing. *Computing in Science & Engineering*, 9(3), 10–20.
59. İnternet: Yeni Şafak. (2005). Enerjide devletin 55 trilyonluk zaferi. Web: <https://www.yenisafak.com/gundem/enerjide-devletin-55-trilyonluk-zaferi-2687992> Son Erişim Tarihi: 02.07.2024.
60. Papageorgiou, G. ve Marshall, B. C. (2020). Bayesian semiparametric analysis of multivariate continuous responses, with variable selection. *Journal of Computational and Graphical Statistics*, 29(4), 896–909.
61. Ying, X. (2019). An overview of overfitting and its solutions. *Journal of Physics: Conference Series*, 1168(2), 1-6.
62. Kidwell, J. S. ve Brown, L. H. (1982). Ridge regression as a technique for analyzing models with multicollinearity. *Journal of Marriage and Family*, 44(2), 287–299.
63. Weerts, H. J. P., Mueller, A. C. ve Vanschoren, J. (2020). Importance of tuning hyperparameters of machine learning algorithms. *Arxiv*, 1-17.
64. Pedregosa, F. ve diğerleri. (2011). Scikit-learn: machine learning in python. *Journal of Machine Learning Research*, 12, 2825–2830.
65. Berrar, D. (2019). Cross-validation. *Encyclopedia of Bioinformatics and Computational Biology*, 1, 542-545.



Gazili olmak ayrıcalıktır